





دانشگاه آزاد اسلامی
واحد نجف آباد
دانشکده فنی مهندسی

رساله برای دریافت دکتری در رشته مهندسی کامپیوتر

گرایش: هوش مصنوعی و رباتیکز

عنوان:

**پیش‌بینی پارامترهای کیفی هوا مرتبط با آلودگی ریزگرد با
استفاده از یادگیری عمیق و ماشین تورینگ عصبی**

نگارنده

زهرا سادات عصایی معمم

استادان راهنما

دکتر فرامرز صافی اصفهانی

دکتر سید علی میرجلیلی

ماه و سال: 1402/05



يَرْفَعُ اللَّهُ الَّذِينَ آمَنُوا مِنْكُمْ وَالَّذِينَ أُوتُوا الْعِلْمَ دَرَجَاتٍ «قرآن کریم»

تصویب نامه

پایان نامه خانم..... دانشجوی مقطع رشته گرایش با عنوان

در جلسه مورخ تحت نظارت شورای پایان نامه متشکل از استادان زیر با درجه

..... و نمره مورد تأیید قرار گرفت.

1-استاد راهنما: جناب آقای دکتر فرامرز صافی اصفهانی امضاء

2- استاد راهنما: جناب آقای سید علی میرجلیلی امضاء

3- استاد داور داخل گروه: جناب آقای امضاء

4- استاد داور خارج گروه: جناب آقای دکتر امضاء

معاون آموزشی و پژوهشی دانشکده

نام و نام خانوادگی

تاریخ و امضاء

مدیر گروه تحصیلات تکمیلی

نام و نام خانوادگی

تاریخ و امضاء

واگذاری حقوق

کلیه حقوق مادی و معنوی برگرفته از مطالعات،

ابتکارات و نوآوری های این پایان نامه متعلق به

دانشگاه آزاد اسلامی واحد نجف آباد است.



معاونت پژوهش و فن آوری

به نام خدا

مشور اخلاق پژوهش

بیایم از خداوند سبحان و اعتقاد به این که عالم محضر خداست و همواره ناظر بر اعمال انسان و به منظور پاس داشت مقام بلند دانش و پژوهش و نظریه ابیست جایگاه دانشگاه در
اعتلای فرهنگ و تمدن بشری، مادیان و اعضای هیئت علمی واحد های دانشگاه آزاد اسلامی متعهد می گردیم اصول زیر را در انجام فعالیت های پژوهشی مد نظر قرار داده
و از آن تخطی نکنیم:

- 1- اصل حقیقت جویی: تلاش در راستای پی جویی حقیقت و وفاداری به آن و دوری از هرگونه پنهان سازی حقیقت.
- 2- اصل رعایت حقوق: التزام به رعایت کامل حقوق پژوهشگران و پژوهشگران (انسان، حیوان و نبات) و سایر صاحبان حق.
- 3- اصل مالکیت مادی و معنوی: تعهد به رعایت کامل حقوق مادی و معنوی دانشگاه و کلیه بکاران پژوهش.
- 4- اصل منافع ملی: تعهد به رعایت مصالح ملی و در نظر داشتن پیشبرد و توسعه کشور و کلیه بکاران پژوهش.
- 5- اصل رعایت انصاف و امانت: تعهد به اجتناب از هرگونه جانب داری غیر علمی و حفاظت از اموال، تجهیزات و منابع در اختیار.
- 6- اصل رازداری: تعهد به صیانت از اسرار و اطلاعات محرمانه افراد، سازمان ها و کشورهای کلیه افراد و نهاد های مرتبط با تحقیق.
- 7- اصل احترام: تعهد به رعایت حریم ها و حرمت ها در انجام تحقیقات و رعایت جانب نقد و خودداری از هرگونه حرمت شکنی.
- 8- اصل ترویج: تعهد به رواج دانش و اشاعه نتایج آن به بکاران علمی و دانشجویان به غیر از مواردی که منع قانونی دارد.
- 9- اصل برانست: التزام به برانست جویی از هرگونه رفتار غیر حرفه ای و اعلام موضع نسبت به کسانی که حوزه علم و پژوهش را به شائبه های غیر علمی می آلائند.

امضاء استادان راهنما:

امضاء پژوهشگر:



دانشگاه آزاد اسلامی

واحد نجف آباد

این جانب زهرا سادات عصایی معمم دانش آموخته ی مقطع دکتری تخصصی در رشته هوش مصنوعی و رباتیکز که در تاریخ ----- از پایان نامه/رساله ی خود با عنوان ”پیش بینی پارامترهای کیفی هوا مرتبط با آلودگی ریزگرد با استفاده از یادگیری عمیق و ماشین عصبی تورینگ“ با کسب نمره ی ---- و درجه ی ----- دفاع نموده ام، بدین وسیله متعهد می شوم:

این پایان نامه/رساله حاصل تحقیق و پژوهش انجام شده توسط این جانب بوده و در مواردی که از دستاوردهای علمی و پژوهشی دیگران (اعم از پایان نامه، کتاب، مقاله و ...) استفاده نموده ام، مطابق ضوابط و رویه ی موجود، نام منبع به کار رفته و سایر مشخصات آن را در فهرست مربوطه ذکر و درج کرده ام.

- 1) این پایان نامه/رساله پیش از این برای دریافت هیچ مدرک تحصیلی (هم سطح، پایین تر یا بالاتر) در سایر دانشگاه ها و موسسات آموزش عالی ارایه نشده است.
- 2) چنان چه پس از فراغت از تحصیل قصد استفاده و هر گونه بهره برداری اعم از چاپ کتاب، ثبت اختراع و ... از این پایان نامه داشته باشم، از حوزه ی معاونت پژوهشی واحد مجوزهای مربوطه را بگیرم.
- 3) چنان چه در هر زمانی خلاف موردهای بالا ثابت شود، عواقب ناشی از آن را می پذیرم و واحد دانشگاهی مجاز است با این جانب مطابق ضوابط و مقررات رفتار نموده و در صورت ابطال مدرک تحصیلی ام هیچ گونه ادعایی نخواهم داشت.

نام و نام خانوادگی:

تاریخ و امضا:

تقدیم به

خانواده عزیزم

که در سختی‌ها و دشواری‌های زندگی همواره یآوری دلسوز و فداکار
و پشتیبانی محکم و مطمئن برایم بوده‌اند...

سپاسگزاری

حال که در سایه الطاف پروردگار یکتا این پروژه به پایان رسیده است، بر خود واجب می‌دانم که از زحمات کلیه کسانی که از آغاز تا به امروز مرا در انجام این تحقیق، تشویق و یاری نموده‌اند، کمال تشکر و قدردانی را به عمل آورم. تقدیر و تشکر خاص خود را، تقدیم به استاد علم و اخلاق، جناب آقای دکتر **فرامرز صافی اصفهانی** می‌نمایم. بی‌شک بدون راهنمایی‌های ارزشمند، دلسوزی‌ها و حمایت‌های همه‌جانبه ایشان پیمودن این راه میسر نبود.

زهرا سادات عصایی معمم

فهرست مطالب

صفحه	عنوان
1	چکیده.....
فصل اول کلیات	
2	1-1- مقدمه
3	2-1- بیان مساله
6	4-1- روش تحقیق
8	5-1- نوآوری تحقیق
8	6-1- اهداف مشخص تحقیق
8	7-1- سؤال‌های تحقیق
9	8-1- دستاوردهای تحقیق
9	9-1- فصل‌های رساله
فصل دوم مبانی نظری و پیشینه تحقیق	
10	1-2- مقدمه
10	2-2- مبانی نظری
10	1-2-2- شاخص AQI
12	2-2-2- یادگیری عمیق
13	3-2-2- شبکه عصبی کوتاه‌مدت ماندگار عمیق
14	4-2-2- شبکه‌های مولد تخصصی (GAN)
14	5-2-2- ماشین تورینگ عصبی
15	1-2-2-5- اعمالی که کنترلر از طریق هداها انجام می‌دهد
16	2-2-2-5- خواندن و نوشتن
17	2-2-2-5- مکانیسم آدرس‌دهی
18	2-2-2-5- شبکه کنترلر
19	2-3- پیشینه تحقیق
20	2-3-1- بخش الف- ماشین‌های تورینگ عصبی (NTM)
22	2-3-2- بخش ب- پیش‌بینی پارامترهای کیفیت هوا
26	2-3-3- بخش پ- شبکه متخاصم مولد (GAN)

26..... 4-2- جمع بندی

فصل سوم روش پیشنهادی

27..... 1-3- مقدمه

29..... 2-3- عملکرد 1: پیش پردازش داده ها

30..... 3-3- عملکرد 2-1: راه اندازی پارامترهای شبکه LSTM

30..... 4-3- عملکرد 2-2: تنظیم پارامترهای GAN

31..... 5-3- عملکرد 3: آموزش شبکه متخاصم مولد (GAN)

32..... 6-3- عملکرد 4: آموزش شبکه عصبی برای روش های DAerosol.NTM و DAerosol.GAN.NTM

33..... 7-3- عملکرد 5: دقت، صحت، RMSE، MAPE، و محاسبه TIBAAE

35..... 8-3- جریان اطلاعات در چارچوب پیشنهادی

36..... 9-3- مطالعه موردی

فصل چهارم ارزیابی و نتایج روش پیشنهادی

38..... 1-4- مقدمه

38..... 2-4- مجموعه داده تجربی، محیط و طراحی

38..... 1-2-4- مجموعه داده

39..... 1-1-2-4- درک محیط

39..... 2-1-2-4- درک داده ها

41..... 3-1-2-4- پاک سازی داده ها

42..... 3-1-2-4- آماده سازی داده ها

42..... 1-3-1-2-4- طبقه بندی و برآورد AQI نواحی مربوطه

44..... 2-3-1-2-4- یکپارچه سازی داده ها

45..... 3-3-1-2-4- کاهش ابعاد داده

45..... 4-3-1-2-4- انتخاب و تخصیص ویژگی داده و تعیین درجه همبستگی

46..... 5-3-1-2-4- تجزیه و تحلیل حساسیت

50..... 2-2-4- محیط آزمایش

51..... 4-2-3- طراحی و راه اندازی آزمایشها

52..... 4-2-4- آزمایشها

1-4-2-4-1: ارزیابی DAerosol.NTM پیشنهادی در مقایسه با مقالات پایه از نظر $PM_{2.5}$ ،	52
..... AQI و PM_{10}	
2-4-2-4-2: ارزیابی DAerosol.GAN.NTM پیشنهادی در مقایسه با	54
..... AQI و PM_{10} ، $PM_{2.5}$ از نظر DAerosol.NTM	
3-4-2-4-3: مقایسه فاصله زمانی قبل و بعد از پیش‌بینی رویداد آئروسل (TIBAAE)	55
..... DLSTM و DAerosol.NTM با DAerosol.GAN.NTM	
3-4-3: بحث تجربی	61

فصل پنجم نتیجه‌گیری و پژوهش‌های آینده

1-5- نتیجه‌گیری	63
2-5- پیشنهادات	64
فهرست منابع	65

فهرست شکل ها

عنوان	صفحه
شکل 1-1: مراحل اجرای پژوهش	6
شکل 1-2: تفاوت بین دو روش یادگیری ماشین و یادگیری عمیق	13
شکل 2-2: ساختار شبکه GAN [18]	14
شکل 3-2: ساختار ماشین تورینگ عصبی (الف) به صورت کلی (ب) به صورت جزئی [21]	15
شکل 4-2: نحوه دسترسی به حافظه خارجی [19]	16
شکل 5-2: عملیات خواندن و نوشتن در NTM، [19]	16
شکل 6-2: نمودار جریان مکانیسم آدرس دهی [21]	18
شکل 7-2: جدول زمان بندی پیش بینی پارامترهای کیفیت هوا	20
شکل 8-2: نمودار ذهنی-نقشه و جریان اصلی این تحقیق در بین روش های پایه	23
شکل 1-3: استفاده از یادگیری عمیق و ماشین تورینگ عصبی به همراه شبکه GAN در (DAerosol.GAN.NTM:)	28
شکل 3-2: ساختار تمرین (DAerosol-NTM)	29
شکل 3-3: پیش پردازش مجموعه داده با استفاده از روش های DAerosol.NTM و DAerosol.GAN.NTM	30
شکل 4-3: شبه کد آماده سازی شبکه عصبی GAN برای روش DAerosol.GAN.NTM	31
شکل 5-3: شبه کد برای مقداردهی اولیه روش های DAerosol.NTM و DAerosol.GAN.NTM	30
شکل 6-3: شبه کد برای پیاده سازی GAN	32
شکل 7-3: شبه کد اجرای ترکیب شبکه GAN با NTM با کنترل کننده شبکه عصبی عمیق LSTM	33
شکل 8-3: با داده های یک روز تا پنج روز قبل از رویداد، احتمال چهار روز بعد، پنج روز بعد وجود دارد	34
شکل 9-3: شبه کد محاسبه دقت، دقت، RMSE، MAPE و TIBAAE مورد استفاده در DAerosol.NTM	35
شکل 10-3: نمودار جریان DAerosol.GAN.NTM	35
شکل 11-3: ساختار آموزش شبکه	37
شکل 1-4: مراحل پیش پردازش داده ها	39
شکل 2-4: مناطق شهری تهران [65]	39
شکل 3-4: میانگین شاخص کیفیت هوای AQI کلیه دسته های مورد مطالعه در شهر تهران	43
شکل 4-4: محیط آزمایشی	50
شکل 5-4: مقایسه نمودار میله ای DAerosol.NTM و مقالات پایه بر حسب PM _{2.5}	53

- شکل 4-6: مقایسه نمودار میله ای DAerosol.NTM و مقالات پایه بر حسب PM_{10} 53
- شکل 4-7: مقایسه نمودار میله ای DAerosol.NTM و مقالات پایه بر حسب AQI 54
- شکل 4-8: مقایسه TIBAAEbefore=96(H) و TIBAAEafter=24(H) برای DAerosol.NTM با DLSTM با پیش‌بینی روزانه غلظت آئروسول بر اساس $PM_{2.5}$ ، PM_{10} و شاخص کنترل کیفیت (AQI) .. 57

فهرست جدول ها

صفحه	عنوان
4	جدول 1-1: معرفی متغیرهای وابسته و مستقل
11	جدول 1-2: سطوح مختلف (AQI) [12]
24	جدول 2-2: مقایسه روش های به کارگیری شده در مقاله های معرفی شده با روش این پژوهش
40	جدول 4-1: نمونه کوچکی از مجموعه داده های مورد استفاده در آزمایش ها
40	جدول 4-2: محدوده متغیرهای آلودگی هوا
42	جدول 4-3: نام نمونه های آماری منتخب
42	جدول 4-4: اعداد در نظر گرفته شده برای روزهای هفته در جدول داده ها
45	جدول 4-5: دسته بندی مناطق از نظر ایستگاه های هواشناسی
46	جدول 4-6: میزان همبستگی بین متغیرهای مستقل و متغیرهای وابسته
47	جدول 4-7: درصد تأثیر متغیرهای ورودی بر خروجی
48	جدول 4-8: تجزیه و تحلیل حساسیت برای PM _{2.5}
49	جدول 4-9: تجزیه و تحلیل حساسیت برای PM ₁₀
51	جدول 4-10: طراحی آزمایش ها
52	جدول 4-11: تنظیم آزمایش ها
52	جدول 4-12: مقایسه DAerosol.NTM و مقالات پایه بر حسب PM _{2.5}
53	جدول 4-13: مقایسه DAerosol.NTM و مقالات پایه بر حسب PM ₁₀
54	جدول 4-14: مقایسه DAerosol.NTM و مقالات پایه بر حسب AQI
55	جدول 4-15: نتایج پیش بینی داده های آلودگی هوا در روش DAerosol.NTM
55	جدول 4-16: نتایج پیش بینی داده های آلودگی هوا در روش DAerosol.GAN.NTM
56	جدول 4-17: پیش بینی یک روزه بعدی PM _{2.5} آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آژورسل
56	جدول 4-18: پیش بینی یک روزه بعدی PM ₁₀ آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آژورسل
57	جدول 4-19: پیش بینی یک روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آژورسل
58	جدول 4-20: نتایج پیش بینی حداقل TIBAAE _{after} = 3(H) و حداکثر TIBAAE _{after} = 24(H) داده های آلودگی هوا بر اساس TIBAAE _{before} = 24(H) تا (120H) در چارچوب پیشنهادی

جدول 4-21: پیش‌بینی یک روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آئروسل	59
جدول 4-22: پیش‌بینی دو روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آئروسل	60
جدول 4-23: پیش‌بینی سه روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آئروسل	60
جدول 4-24: پیش‌بینی چهارروزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آئروسل	60
جدول 4-25: پیش‌بینی پنج روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آئروسل	61
جدول 4-26: خلاصه نتایج تجربی (آزمایش-1) در حمایت از فرضیه-1.....	61
جدول 4-27: خلاصه نتایج تجربی (آزمایش-2) در حمایت از فرضیه-2.....	61
جدول 4-28: خلاصه نتایج تجربی (آزمایش-3) در حمایت از فرضیه-3.....	62

چکیده

در مناطق شهری کشورهای مختلف، مسئله ذرات معلق (آئروسول) و اثرات آن بر سلامتی انسان نگران کننده است. ذرات آئروسول با اندازه‌های بین 1 نانومتر تا 100 میکرومتر به راحتی به بافت‌های زیستی نفوذ می‌کنند و از ترکیبات گازی و مواد معدنی سمی مانند مونواکسید کربن، اوزون، دی‌اکسید نیتروژن و دی‌اکسید گوگرد تشکیل شده‌اند. ذرات آئروسول اثرات مختلفی در جنبه‌های محیطی، اقتصادی، بهداشتی و اجتماعی دارند که باید برای بهبود کیفیت زندگی مردم، کنترل شوند. در این مطالعه، چارچوب عمیق DAerosol.GAN.NTM را معرفی می‌کنیم که از جدیدترین پیشرفت‌های ماشین‌های تورینگ عصبی برای دسترسی به حافظه خارجی در قالب یک چارچوب یادگیری عمیق استفاده می‌کند و به تغییرات در ساختار شبکه با استفاده از شبکه GAN تمرکز می‌کند. در مقایسه با چهار مطالعه پایه، از جمله پرسپترون چندلایه، شبکه‌های عصبی عمیق، حافظه کوتاه مدت طولانی - شبکه‌های عصبی عمیق، حافظه کوتاه مدت طولانی عمیق، روش DAerosol-NTM برتری داشته است. DAerosol.GAN.NTM در مقایسه با روش برتر DAerosol-NTM دقت پیش‌بینی را به میزان 1-19٪، صحت را به میزان 2-30٪، خطای میانگین مربعات ریشه را به میزان 33-80٪ و خطای میانگین درصدی مطلق را به میزان 14-78٪ بهبود می‌بخشد. بیشترین نکته قابل توجه، قابلیت DAerosol.GAN.NTM برای ذخیره تا 20 سال از داده‌های ذرات معلق در حافظه خارجی آن است که آن را به اولین مدل قابلیت پیش‌بینی افزایش آلودگی آئروسول در ساعت‌های آینده (24 تا 120 ساعت) تبدیل می‌کند. این مدل با توجه به بازه زمانی بهینه قبل و بعد از رویداد آئروسول، پیش‌بینی رویدادهای آئروسول در آینده را فراهم می‌کند و در محیط‌های زمان واقعی، اثرات منفی طوفان‌های آئروسول سمی را بر جامعه و اقتصاد شهری کاهش می‌دهد.

کلمات کلیدی: ماشین‌های تورینگ عصبی (NTM)، شبکه‌های متخاصم مولد (GAN)، یادگیری عمیق (DL)، شاخص کیفیت هوا (AQI)، ذرات معلق 2.5 (PM_{2.5})، ذرات معلق 10 (PM₁₀) آئروسول؛

فصل اول

کلیات

1-1- مقدمه

ذرات معلق که به عنوان آئروسول نیز شناخته می‌شوند، از ذرات ریز معلق در هوا از تقریباً 1 نانومتر تا 100 میکرومتر تشکیل شده‌اند [1][2]. ذرات معلق به اندازه‌ای بزرگ هستند که ترکیبات گازی سمی، مواد معدنی و بیماری‌های عفونی را حمل کنند، اما به اندازه‌ای کوچک هستند که بتوانند به بافت‌های ریه و ارگانیک نفوذ کنند و عناصر مضر را به بدن حمل کنند و واکنش‌های سمی ایجاد کنند. شاخص کیفیت هوا AQI¹ یک شاخص پرکاربرد است که پارامترهای اصلی را در نظر می‌گیرد که کیفیت و ایمنی هوا را شکل می‌دهد. این شاخص روزانه بر شش آلاینده هوا متکی است: مونوکسید کربن (CO)، ازن (O₃)، دی‌اکسید نیتروژن (NO₂)، دی‌اکسید گوگرد (SO₂)، ذرات معلق 2.5 میکرون (PM_{2.5})² و ذرات معلق 10 میکرون (PM₁₀)³ [3][4]. آلاینده‌هایی با بالاترین غلظت در نهایت مقدار AQI را تعیین می‌کنند، که در میان آن‌ها PM_{2.5} و PM₁₀ معمولاً پیشرو هستند. جهت پیش‌بینی AQI، PM_{2.5} و PM₁₀، بیست‌ودو پارامتر هواشناسی به اضافه CO، O₃، NO₂ و SO₂ ارزیابی می‌شوند. شاخص AQI در مقیاس پیوسته از 0 تا 500 گزارش شده و برای سهولت در اطلاعیه‌های عمومی به شش دسته آلودگی تقسیم می‌شود تا تأثیر کیفیت هوا بر سلامت انسان را نشان دهد و یک مرجع عددی ساده برای مدیریت ریسک فعالیت‌های خارج از منزل ارائه دهد. همچنین ایده‌های طراحی بهتری برای گسترش شهرها ارائه می‌دهد. تلاش‌های قبلی برای تخمین و پیش‌بینی

¹ Air Quality Index

² Particulate Matter 2.5

³ Particulate Matter 10

پارامترهای اصلی AQI یا خود ارزش AQI با استفاده از روش‌های یادگیری ماشین و شبکه عصبی و مقایسه عملکرد رویکردهای مختلف انجام شده است.

1-2- بیان مساله

آلودگی آئروسل یکی از مشکلات اساسی در شهرها است که به طور مستقیم و غیرمستقیم بر سلامت افراد و اقتصاد جامعه تأثیر منفی می‌گذارد. ذرات معلق آئروسل اندازه‌های مختلفی بین 1 نانومتر تا 100 میکرومتر دارند که می‌توانند به راحتی در بافت‌های آلی و نفوذ کننده به بدن انسان قرار بگیرند. این ذرات دارای ترکیبات گازی سمی و مواد معدنی از جمله مونوکسید کربن، ازن، دی اکسید نیتروژن و دی اکسید گوگرد هستند که هر کدام می‌توانند به طور مستقیم یا غیرمستقیم بر سلامت بدن انسان و همچنین بر تعادل اقتصادی جامعه تأثیر منفی بگذارند. پیش‌بینی و کنترل آلودگی هوا با استفاده از شبکه‌های عصبی به دلیل پیشرفت‌های اخیر در زمینه هوش مصنوعی و یادگیری عمیق امکان‌پذیر است. این شبکه‌ها می‌توانند مدل‌های پیچیده را بر اساس داده‌های آماری، جغرافیایی و مشاهدات درون شهری، ساختار جمعیتی و فرهنگی تحلیل کرده و نتایج تحلیل را جهت برنامه‌ریزی و کنترل آلودگی هوا استفاده کنند. با یادگیری عمیق بیشتر، دقت و قدرت پیش‌بینی این شبکه‌ها نیز تقویت می‌شود. اما قبل از اینکه از شبکه‌های عصبی عمیق برای پیش‌بینی آلودگی هوا استفاده کنیم، لازم است مقالات پایه را مرور کرده و مشکلات و چالش‌های موجود را شناسایی کنیم.

در ابتدا مقالات [5] و [6] چارچوب‌ها را با استفاده از Deep Autoencoder (DAE)، شبکه‌های عصبی عمیق (DNN) و (DLSTM) در پیش‌بینی پیاده‌سازی و مقایسه کردند. پارامترهای AQI در فواصل زمانی 24 ساعته (روزانه)، یعنی $PM_{2.5}$ و PM_{10} ، در منطقه شهری سئول. داده‌ها در 25 ایستگاه آلودگی و هواشناسی جمع‌آوری شد. روش DLSTM به دلیل عدم نرمال‌سازی و پردازش شفاف داده‌ها، میزان خطای مدل‌های DAE و DNN را کاهش داد. هر دو مطالعه به داده‌های هواشناسی از یک ایستگاه هواشناسی منفرد که برای پیش‌بینی پارامترهای آئروسل در ناحیه پرکاربرد سئول ناکافی در نظر گرفته شد، اعمال شد. علاوه بر این، ارزیابی تنها $PM_{2.5}$ و PM_{10} از میان شش آلاینده هوا برای به دست آوردن یک دیدگاه جامع از شاخص AQI نیز کافی نیست.

مقاله [7] با روندهای فصلی قبلی در پارامترهای AQI متفاوت است. تعداد قابل توجهی از داده‌ها سری زمانی را از مرکز کنترل آلودگی هند پیاده‌سازی می‌کند. داده‌ها ارزش کل AQI (به جای اجزای آن) را تخمین می‌زند. این مقاله از یک معماری شبکه عصبی عمیق استفاده می‌کند که در آن شبکه‌های عصبی بازگشتی (RNN) و DLSTM با میانگین متحرک یکپارچه اتورگرسیو³ (ARIMA) مقایسه می‌شوند [8]. DLSTM بار دیگر از مدل‌های دیگر پیشی گرفته است، این بار با مزیت عدم حساسیت نسبت به طول فاصله مشابه روش‌های پایه بالا، این چارچوب از داده‌های هواشناسی مناطق متعدد بدون پیش‌پردازش واضح و نرمال‌سازی داده‌ها استفاده نمی‌کند.

¹ Deep Neural Networks

² Deep Long Short-Term Memory

³ Autoregressive

این رویکرد [9] مدل DNN را پس از پردازش دقیق داده‌ها و عادی‌سازی برای پیش‌بینی PM_{2.5} در منطقه ووهان اعمال می‌کند. مدل‌های Super Vector Machine (SVM) و یک شبکه پس انتشار سستی با سه لایه پنهان برای تجزیه و تحلیل داده‌ها استفاده شد. نتایج نشان داد که مدل DNN نسبت به روش‌های یادگیری سطحی در پیش‌بینی، در نظر گرفتن خطا و محاسبه نرخ رگرسیون برتری دارد. این مطالعه از داده‌های هواشناسی استفاده نمی‌کند و فقط از داده‌های آلودگی از ووهان استفاده می‌کند. مدل انتخاب‌شده به دلیل کمبود حافظه که منجر به کاهش وزن می‌شد برای داده‌های سری زمانی مناسب نبود.

در نهایت تمام مطالعات پایه [7][9][5] و [6] از چندین کاستی رنج می‌برند که به شرح زیر است: (1) عدم استفاده از پارامترهای هواشناسی و آلودگی محلی به عنوان شاخص‌های مؤثر در تخمین کیفیت هوا، (2) استفاده از یک ایستگاه هواشناسی واحد برای یک شهر بزرگ و نداشتن ایستگاه‌های هواشناسی محلی در مناطق مختلف، (3) دقت پایین مدل به دلیل عدم حفظ تاریخچه داده‌ها و نداشتن حافظه بلندمدت در مدل‌ها و (4) عدم ایجاد مدل مناسب برای تخمین داده‌های از دست‌رفته و تولید داده‌ها برای روزهای آینده.

برای غلبه بر کسری‌های بالا و پیش‌بینی دقیق آئروسول و شاخص‌های AQI بر این اساس، وظیفه اصلی این مطالعه ارائه چارچوبی است که بتواند داده‌های از دست‌رفته را تخمین بزند و داده‌های آینده را به موقع پیش‌بینی کند. بیست‌وشش متغیر مستقل وجود دارد که بیست‌ودو مورد آن داده‌های هواشناسی هستند و چهار متغیر کیفیت هوا را توصیف می‌کنند. یک نمای سطح بالا از متغیرهای مستقل شامل مقدار مونوکسید کربن، CO₂، ازن O₃، دی‌اکسید نیتروژن NO₂، دی‌اکسید گوگرد SO₂، وضعیت آسمان، دید افقی، فشار، باد، رطوبت نسبی و دما است. متغیرهای وابسته در این مطالعه عبارت‌اند از: دقت، صحت، ریشه میانگین مربعات خطا (RMSE)¹ و میانگین درصد مطلق خطا (MAPE)² [10][11] از نظر اندازه ذرات معلق شاخص کنترل کیفیت PM_{2.5}، PM₁₀ و AQI. پارامتر (TIBAAE)³ پیش‌بینی رویدادهای آئروسول در آینده را با توجه به فاصله زمانی قبل و بعد از رویداد آئروسول تعریف می‌کند. در جدول 1-1 متغیرهای وابسته و مستقل تحقیق معرفی شده است.

جدول 1-1: معرفی متغیرهای وابسته و مستقل

عنوان متغیر	نقش متغیر	نوع متغیر	مقیاس
تاریخ و ساعت / date	مستقل	مستقل کمی / پیوسته	ثانیه
قابل مشاهده پایین‌ترین ابر / h	مستقل	کمی / پیوسته	متر
دید افقی / vv	مستقل	کمی / پیوسته	درجه
ابرناکی / n	مستقل	کمی / پیوسته	درجه
جهت باد / dd	مستقل	کمی / پیوسته	درجه
سرعت باد / ff	مستقل	کمی / پیوسته	درجه

¹ Root Mean Square Error

² Mean Absolute Percentage Error

³ Time Interval Before and After the Aerosol Event

عنوان متغیر	نقش متغیر	نوع متغیر	مقیاس
دما / t	مستقل	کمی / پیوسته	درجه
نقطه شبنم / Td	مستقل	کمی / پیوسته	درجه
فشار سطح دریا / P	مستقل	کمی / پیوسته	کیلوگرم بر سانتی متر مربع
فشار ایستگاه / p0	مستقل	کمی / پیوسته	درجه
پایین ترین لایه میزان ابر / Nh	مستقل	کمی / پیوسته	درجه
ابر لایه پایین / Cl	مستقل	کمی / پیوسته	درجه
ابر لایه متوسط / Cm	مستقل	کمی / پیوسته	درجه
لایه ابر میزان پوشش اولین / nl1	مستقل	کمی / پیوسته	درجه
نوع اولین لایه ابر / tl1	مستقل	کمی / پیوسته	km
اولین لایه ابر ارتفاع پایه / hl1	مستقل	کمی / پیوسته	متر
لایه ابر میزان پوشش دومین / nl2	مستقل	کمی / پیوسته	میلی بار
نوع دومین لایه ابر / tl2	مستقل	کمی / پیوسته	km
لایه ابر ارتفاع پایه دومین / hl2	مستقل	کمی / پیوسته	متر
رطوبت نسبی / U	مستقل	کمی / پیوسته	درجه سلسیوس
دمای تر / Twet	مستقل	کمی / پیوسته	درجه
فشار بخار / Ew	مستقل	کمی / پیوسته	درجه
QNH فشار / Pqnh	مستقل	کمی / پیوسته	درجه
اوزن / O3	مستقل	کمی / پیوسته	ppb
مونوکسید کربن / CO	مستقل	کمی / پیوسته	ppm
دی اکسید نیتروژن / NO2	مستقل	کمی / پیوسته	ppb
دی اکسید گوگرد / SO2	مستقل	کمی / پیوسته	ppb
کمتر ذرات جامد با قطر / PM 10 یا برابر 10 میکرون	وابسته	کمی / پیوسته	ug/m3
قطر کمتر ذرات جامد با / PM 2.5 یا برابر 2.5 میکرون	وابسته	کمی / پیوسته	ug/m3
شاخص کیفیت هوا / AQI	وابسته	کیفی / اسمی	پاک / سالم / ناسالم برای گروه حساس / ناسالم / بسیار ناسالم / خطرناک

1-3- فرضیه تحقیق

اولین فرضیه تحقیق بیان می کند که استفاده از یک حافظه خارجی در شبکه عصبی یادگیری عمیق، به دلیل سابقه طولانی اطلاعات هواشناسی، دقت و صحت $PM_{2.5}$ ، PM_{10} و شاخص کنترل کیفیت AQI را بهبود می بخشد.

فرضیه دوم تحقیق بیان می‌کند که اگر لایه مبتنی بر GAN¹ برای تخمین داده‌های ازدست‌رفته و داده‌های روزهای آینده همراه با شبکه (NTM)² برای پیش‌بینی اندازه ذرات PM_{2.5}، PM₁₀ و AQI استفاده شود، دقت بالاتری بدست می‌آید، همچنین فاصله زمانی رخداد AQI را زودتر پیش‌بینی می‌کند.

1-4- روش تحقیق

در ابتدا با مطالعات کتابخانه‌ای حول محوریت موضوع عنوان‌شده بر اساس مجلات و کنفرانس‌های معتبر اقدام به گردآوری اطلاعات نمودیم. سپس به بررسی راه‌حل‌های ارائه‌شده در مقالات و پیاده‌سازی آن‌ها پرداختیم. از آنجایی که نگرش پژوهش حاضر پایین به بالا است؛ به این شکل که از کار با داده‌ها شروع شده و سعی بر کشف مدلی برای پیش‌بینی بوده که قبلاً آگاهی نسبت به آن وجود نداشته، بنابراین از روش کشف دانش استفاده نموده است؛ پژوهش حاضر از نظر هدف، کاربردی-تحقیق و توسعه‌ای، از نظر بعد زمانی گذشته‌نگر، از نظر روش پژوهش، توصیفی از نوع پس‌رویدادی و نوع داده‌ها کمی است.

در این رساله برای ترکیب شبکه GAN با DAerosol-NTM چارچوب DAerosol.GAN.NTM پیشنهاد می‌شود. الگوریتم‌های پیشنهادی در ابتدا مورد ارزیابی کیفی قرار گرفته، سپس تحلیل نظری روش پیشنهادی ارائه می‌شود. در ادامه، روش پیشنهادی در یک ابزار شبیه‌ساز مناسب پیاده‌سازی می‌شود و آزمون‌های موردنیاز برای ارزیابی روش پیشنهادی به انجام خواهد رسید. برای ارزیابی الگوریتم ترکیبی از داده‌های برچسب‌دار استفاده می‌شود. کارهایی که در ادامه انجام خواهد گرفت، توسعه و اعمال الگوریتم‌های پیشنهادی جهت بررسی کاربردهای احتمالی آن خواهد بود.

شروع
مطالعه متدولوژی Crisp-DM و بکارگیری در پیش‌پردازش و فعالیت‌های داده‌کاوی
آماده‌سازی داده‌ها
بررسی داده‌ها بر اساس ساعت، ماه و روزهای آخر هفته و تعطیلات رسمی
طبقه‌بندی مناطق انتخاب‌شده داده‌های آلودگی هوای مرکز کنترل کیفیت هوا در چهار دسته؛ بر اساس ایستگاه‌های هواشناسی واقع در شهر تهران
تحلیل داده‌های هواشناسی و آلودگی هوا
محاسبه شاخص کیفیت هوای شهر تهران با استفاده از داده‌کلی برای کل شهر تهران
تقسیم داده‌های نمونه به سه مجموعه داده‌های آموزشی، داده‌های اعتبارسنجی و داده‌های آزمایشی
تخمین Miss Value با استفاده از شبکه GAN
تخمین پارامترهای جدید برای روزهای آینده با استفاده از شبکه GAN جهت پیش‌بینی میزان رخداد آبروسل در آینده
طراحی و مدل‌سازی با استفاده از داده‌های آموزشی به وسیله تشکیل شبکه عمیق با استفاده از شبکه عصبی با حافظه پیرونی (NTM) و شبکه GAN
آزمون مدل با مجموعه داده‌های تست
اندازه‌گیری متغیرهای وابسته و تحلیل نتایج و بررسی پشتیبانی نتایج از فرضیه‌ها
پایان

شکل 1-1: مراحل اجرای پژوهش

الف: داده‌های پژوهش:

¹ Generative Adversarial Network

² Neural Turing Machines

داده‌های این پژوهش شامل اعداد مربوط به 15 سنسور از سنسورهای کنترل کیفیت مربوط به شرکت کنترل کیفیت هوای تهران و اعداد مربوط به ایستگاه‌های هواشناسی سازمان هواشناسی کشور، در بازه زمانی 20 ساله 30 دسامبر 1999 تا 4 می 2019 می‌باشد.

ب: ابزار گردآوری داده‌ها (مشاهده و آزمون، پرسشنامه، مصاحبه، فیش‌برداری، پایگاه داده و غیره)

گردآوری داده‌ها از دو طریق صورت پذیرفته است. نخست داده‌های ساعتی که اعداد مربوط به شاخص‌های آلودگی هوای شهر تهران بوده است از سایت مرکز کنترل کیفیت هوای تهران به‌دست‌آمده است و دوم داده‌های هواشناسی که اعداد مربوط به شاخص‌های هواشناسی است از سازمان هواشناسی کشور به‌صورت رایگان اتخاذ گردید بازه جمع‌آوری این داده‌ها از 30 دسامبر 1999 تا 4 می 2019 به مدت 20 سال می‌باشد. نکته قابل ذکر این است، به دلیل در دسترس نبودن داده‌های مورد استفاده در مقالات پایه [7][9][5] و [6] این مطالعه کنونی روش‌های پایه را روی مجموعه داده ارائه‌شده برای ارزیابی $PM_{2.5}$ ، PM_{10} و AQI اجرا می‌کند.

ج: قلمرو مکانی و زمانی پژوهش:

روش جمع‌آوری اطلاعات پژوهش روش کتابخانه‌ای است که اهداف آن کسب اطلاعات اولیه راجع به موضوع مورد تحقیق، اخذ تصمیم در مورد این‌که چه محلی و چه اشخاصی باید مورد مطالعه قرار گیرند، یافتن اطلاعات از سوابق موضوع مورد تحقیق و کسب تجربه از آنچه تا به حال انجام شده است. انجام این مرحله مستلزم استفاده از مقالات معتبر علمی و پژوهشی داخلی و خارجی است. همچنین برای جمع‌آوری داده‌های پژوهش از روش مطالعه اسناد و مدارک مربوط به شرکت کنترل کیفیت هوای تهران و اعداد مربوط به ایستگاه‌های هواشناسی سازمان هواشناسی کشور استفاده شده است.

د: مراحل اجرای پژوهش:

با توجه به اینکه ماهیت پژوهش داده محور بوده و پایه اصلی پژوهش حاضر بر پیش‌بینی پارامترهای کیفی هوای شهر تهران بنا شده است. از این رو استاندارد جهانی **Crisp_DM** جهت انجام فرایند پژوهش؛ مورد استفاده قرار گرفته است؛ که ساختار اجرایی پژوهش بر اساس مراحل این استاندارد تشریح شده است. به‌طور کلی با استفاده از روش‌های آمار توصیفی و استنباطی، اطلاعات استخراج‌شده مورد تحلیل قرار خواهد گرفت. به‌منظور مدل‌سازی، بر اساس نوع خروجی و به‌تناسب نیاز تحقیق از الگوریتم‌های پیش‌بینی کننده در حوزه یادگیری عمیق استفاده خواهد شد.

ه: نحوه اجرای پژوهش (شامل مواد، تجهیزات و استانداردهای مورد استفاده در قالب مراحل اجرایی تحقیق

به تفکیک)

کلیه روش‌ها در نرم‌افزار Matlab R2018a و در سیستم با مشخصات حافظه 8 گیگابایت، واحد پردازش مرکزی Core7 و گرافیک GeForce435m پیاده‌سازی شده‌اند. سپس در نرم‌افزار Anaconda و زبان برنامه‌نویسی

Python مجدداً اجرا شدند. ابزار پردازش گر برای شبکه‌های عصبی عمیق Keras API است که از چارچوب Tensorflow بر اساس GPU استفاده می‌کند. بستر کد نویسی google colab و Spyder خواهد بود.

1-5- نوآوری تحقیق

هدف این مطالعه افزایش کیفیت زندگی افراد با تمرکز بر پیش‌بینی آئروسول است. در این مطالعه، چارچوب‌هایی به نام DAerosol.NTM¹ و DAerosol.GAN.NTM² پارامترهای کیفیت هوا را با استفاده از یادگیری عمیق پیش‌بینی می‌کند. در نهایت، DAerosol.NTM و DAerosol.GAN.NTM، در مقایسه با سایر روش‌ها امیدوار است با به حداکثر رساندن استفاده از داده‌های هواشناسی موجود و رویکرد چارچوب مدرن مانند GAN و NTM، درک خود را از آلودگی هوا از نظر AQI بهبود بخشد تا از مدل‌های پایه قبلی پیشی بگیرد و به کاهش موارد مضر کمک کند. رویدادهای آب و هوایی که می‌توانند وضعیت اجتماعی-اقتصادی و بهداشت عمومی قابل توجهی را در هر محیط شهری داشته باشند.

در عمل، چارچوب‌های پیشنهادی باید با داده‌های محلی قبلی آموزش داده شود. پس از نصب حسگرها در مکان‌های موردنظر، داده‌های زنده نشانگرهای آلودگی استخراج شده و سپس داده‌ها به عنوان مجموعه داده آزمایشی به شبکه ارائه شده ارسال می‌شود. متعاقباً، روش پیشنهادی آلودگی را به دقت پیش‌بینی می‌کند. سپس شبکه می‌تواند مجموعه داده آموزشی خود را با داده‌های زنده تکمیل کند تا پیش‌بینی‌های جدید انجام دهد.

1-6- اهداف مشخص تحقیق

الف: هدف اصلی:

بهبود دقت و کارایی سیستم‌های تشخیص آلودگی هوا با استفاده از هوش مصنوعی

(1) پیش‌بینی ذرات جامد معلق از جمله PM₁₀ و PM_{2.5}

(2) پیش‌بینی شاخص کنترل کیفیت هوا (AQI)

(3) پیش‌بینی پارامترهای کنترل کیفیت در زمان آینده

ب: اهداف فرعی:

این تحقیق قادر است پیش‌بینی وضعیت آلودگی هوا را در سازمان‌های ذی ربط در مناطقی که خطر آلودگی وجود دارد برای مدیران ارشد با دقت بالا فراهم آورد.

1-7- سؤال‌های تحقیق

الف: سؤال اصلی:

¹ Deep Aerosol - Neural Turing Machines

² Deep Aerosol - Generative Adversarial Networks - Neural Turing Machines

- آیا تکنیک یادگیری عمیق همراه با حافظه بیرونی منجر به نتایج بهتری در پیش‌بینی پارامترهای کیفی هوا از جمله میزان $(PM_{10})^1$ (ذرات جامد با قطر کمتر یا برابر 10 میلی‌متر) و $(PM_{2.5})^2$ (ذرات جامد با قطر کمتر یا برابر 2.5 میلی‌متر) و شاخص کنترل کیفیت (AQI) می‌گردد؟

ب: سؤال‌های فرعی:

- آیا تکنیک یادگیری عمیق با ترکیب $(NTM)^3$ و شبکه $(GAN)^4$ ، منجر به ساختار جدید و کارآمدتر می‌گردد؟
- آیا تکنیک یادگیری عمیق در ساختار جدید $(NTM+GAN)$ قادر است داده‌های مربوط به پارامترهای کیفی هوا $(PM_{10}, PM_{2.5})$ در زمان آینده را پیش‌بینی کند؟
- آیا دسته‌بندی اطلاعات مربوط به هر کدام از ایستگاه‌های هواشناسی با ایستگاه‌های کنترل کیفیت منطقه مربوطه؛ منجر به تولید داده‌هایی با دقت و صحت بیشتری از نظر استانداردسازی هوا خواهد شد.

8-1- دستاوردهای تحقیق

پژوهش حاضر در راستای هدف داشتن شهری پاک و هوشمند می‌تواند در تسهیل تصمیم‌گیری‌ها و طراحی استراتژی سازمان محیط‌زیست، سازمان هواشناسی، مرکز تحقیقات مسکن، مرکز کنترل کیفیت هوا و دیگر سازمان‌های مرتبط یاری رساند. در ضمن این پژوهش می‌تواند راهگشای دیگر پژوهشگران جهت ادامه و توسعه‌ی ایده مطرح‌شده و دستیابی به روش‌های مطلوب‌تر و پیش‌بینی میزان آلودگی هوا باشد.

9-1- فصل‌های رساله

در این فصل پس از ارائه کلیات تحقیق، به بیان مسئله و متغیرها، روش‌ها و نوآوری، اهداف، سؤالات و در نهایت دستاوردهای تحقیق پرداختیم. بقیه رساله به شرح زیر سازماندهی شده است: فصل 2 به مبانی نظری و پیشینه تحقیق می‌پردازد. چارچوب توسعه یافته در مطالعه حاضر در بخش 3 و چندین آزمایش را برای ارزیابی و نتایج روش پیشنهادی همراه با طرح آزمایش در بخش 4 ارائه شده است. بخش 5 نتیجه‌گیری و پیشنهاداتی را برای تحقیقات آتی ارائه می‌دهد.

¹ Particulate Matter 10 (PM_{10})

² Particulate Matter 2.5 ($PM_{2.5}$)

³ Neural Turing Machines

⁴ Generative Adversarial Networks

فصل دوم

مبانی نظری و پیشینه تحقیق

2-1- مقدمه

این بخش به مسائل نظری و فنی و اصطلاحات تخصصی مورد استفاده در مطالعه می پردازد، از جمله شاخص AQI، یادگیری عمیق، شبکه عصبی کوتاه مدت عمیق و ماشین تورینگ عصبی.

2-2- مبانی نظری

2-2-1- شاخص AQI

یک شاخص کیفیت هوا است که وضعیت کیفیت هوا را بازتاب و ارزیابی می کند. با اشاره به استانداردهای کیفیت جدید هوا محاسبه می گردد. غلظت چندین آلاینده را به شکل یک عدد مجزا بیان می کند. آلاینده ها شامل: دی اکسید گوگرد SO_2 ، دی اکسید نیتروژن NO_2 ، ذرات معلق $PM_{2.5}$ و PM_{10} ، ازن O_3 و مونوکسید کربن CO را شامل می شود [3]. برای تخمین شاخص کنترل کیفیت هوا AQI از بین شش آلاینده نام برده شده غلظت هر کدام بیشتر باشد

مقدار مربوط به آن آلاینده به عنوان AQI کلی انتخاب می‌گردد. PM₁₀ و PM_{2.5} آلاینده‌هایی هستند که بیشترین عامل اصلی آلودگی هوا و همچنین فرسایش می‌باشند. برای عموم مردم AQI یک شاخص مهم است تا بتوانند به راحتی درک کنند که آیا کیفیت هوا بد است یا خیر. همچنین در تفسیر داده‌ها برای تصمیم‌گیری‌های مرتبط با اقدامات کاهش آلودگی و مدیریت کیفیت هوا مفید است. با توجه به استانداردهای کیفیت هوا و تأثیرات مختلف بر سلامت انسان، AQI به شش طبقه تقسیم می‌شود [4]. که هر دسته را به سطوح مختلف سلامت انسان مربوط می‌سازد؛ این شش دسته در جدول 1-2 نشان داده شده است.

جدول 1-2: سطوح مختلف (AQI) [12]

<i>Air Quality Index (AQI) Values</i>	<i>Levels of Health Concern</i>	<i>Colors</i>
<i>AQI</i>	<i>Air quality conditions:</i>	<i>Symbol</i>
0 to 50	Good	Green
51 to 100	Moderate	Yellow
101 to 150	Unhealthy for Sensitive Groups	Orange
151 to 200	Unhealthy	Red
201 to 300	Very Unhealthy	Purple
301 to 500	Hazardous	Maroon

خوب^۱: میزان AQI در این حالت بین 0 و 50 است. در این شرایط کیفیت هوا رضایت‌بخش و دارای ریسک سلامتی ناچیز و یا فاقد ریسک سلامتی است. این حالت را بارنگ سبز نشان می‌دهند. در کشور ایران معمولاً به این حالت، وضعیت پاک اطلاق می‌شود.

در ردیف متوسط^۲: میزان AQI در این حالت بین 51 و 100 است. کیفیت هوا در این شرایط قابل قبول است؛ اگرچه آلودگی در این سطح ممکن است برای تعداد بسیار کمی از افراد با ملاحظات بهداشتی خاص همراه باشد. در این شرایط افرادی که نسبت به ذرات معلق، دی‌اکسید نیتروژن و ازن حساسیت ویژه‌ای دارند ممکن است علائم تنفسی در آن‌ها مشاهده شود. این حالت را بارنگ زرد نشان می‌دهند. در کشور ما معمولاً به این حالت، وضعیت «سالم» اطلاق می‌شود.

وضعیت ناسالم برای گروه‌های حساس^۳: میزان AQI در این حالت بین 101 و 150 است. بعضی از افراد گروه‌های حساس در این شرایط ممکن است اثرات بهداشتی خاصی را تجربه کنند اما عموم مردم تحت تأثیر قرار نمی‌گیرند. این حالت را بارنگ نارنجی نشان می‌دهند.

ناسالم^۴: میزان AQI در این حالت بین 151 و 200 است. در این شرایط هر فردی ممکن است اثرات بهداشتی را تجربه کند. اعضای گروه‌های حساس بیش از سایرین اثرات جدی را بر سلامت خود تجربه می‌کنند. این حالت بارنگ قرمز نشان داده می‌شود.

¹ good

² Moderate

³ Unhealthy for sensitive groups

⁴ Unhealthy

خیلی ناسالم^۱: در این حالت AQI بین 201 و 300 قرار دارد و هشدار برای سلامتی به حساب می‌آید و بدین معنی است که در این شرایط هرکسی ممکن است اثرات جدی سلامت را تجربه کند. این حالت را به رنگ بنفش نشان می‌دهند[12].

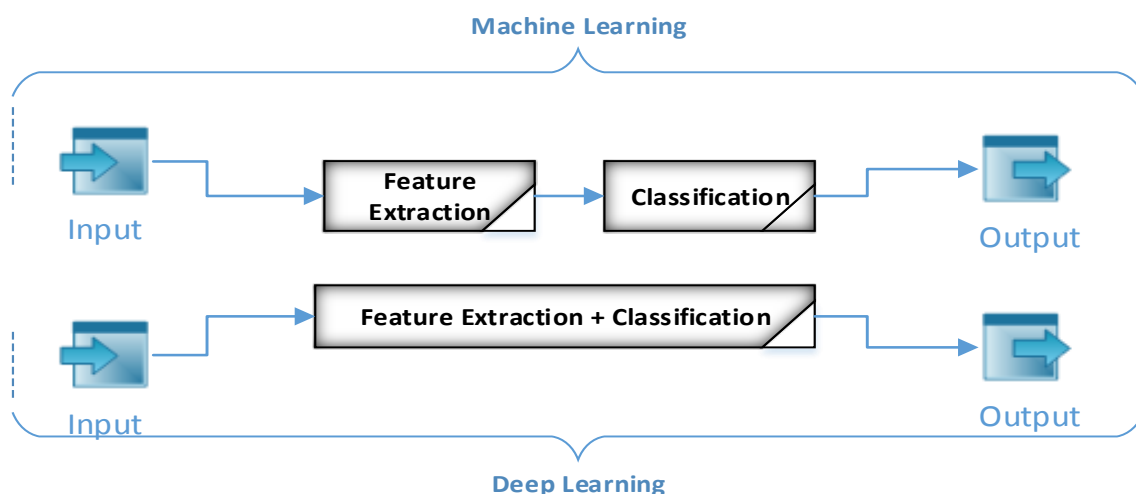
در نهایت در ردیف خطرناک^۲: AQI در این وضعیت از 300 بالاتر است و اختطاری جدی برای سلامت انسان و بیانگر شرایط اضطراری است. در این وضعیت تمام افراد جامعه تحت تأثیر اثرات بهداشتی جدی قرار می‌گیرند. این حالت را بارنگ خرمایی نشان می‌دهند.

2-2-2- یادگیری عمیق

یادگیری عمیق درواقع همان یادگیری ماشین است اما در نوع عمیق‌تر و پیشرفته‌تر به‌طوری‌که عملکرد آن، شباهت بیشتری به عملکرد مغز انسان دارد. به عبارتی بخشی از خانواده‌ی بزرگ‌تر یادگیری ماشین است که بر روش‌هایی تمرکز دارد که مبتنی بر شبکه‌های عصبی مصنوعی هستند. این نوع از یادگیری یکی از عناصر مهم در علم داده هست که ورودی خام را دریافت کرده و در چندین لایه به استخراج ویژگی‌های سطح بالا می‌پردازد. شامل آمار و مدل‌سازی پیش‌بینی است. یادگیری عمیق برای دانشمندان داده که وظیفه جمع‌آوری، تجزیه و تحلیل و تفسیر مقادیر زیادی از داده‌ها را دارند، بسیار مفید است. در کل روند را سریع‌تر و آسان‌تر می‌کند. به عبارتی موجب پردازش دقیق‌تر و سریع‌تر داده‌ها می‌گردد و این به دلیل پیچیدگی و توانایی آن در یادگیری است و در زمینه‌های مختلف از قبیل پردازش تصویر، شناخت الگو و بینایی کامپیوتر کاربرد داشته و قابلیت آموزش پایدار و تعمیم دادن و مقیاس‌پذیری داده‌های عظیم را دارد[13]. یادگیری عمیق یک روش قدرتمند یادگیری ماشین است که توابع تقریب، طبقه‌بندی و قابلیت پیش‌بینی را فراهم می‌کند[14][15]. در شکل 2-1 تفاوت بین دو روش یادگیری ماشین و یادگیری عمیق را می‌توان به‌خوبی درک کرد.

¹ Very unhealthy

² Hazardous



شکل 2-1: تفاوت بین دو روش یادگیری ماشین و یادگیری عمیق [14][15]

3-2-2- شبکه عصبی کوتاه مدت ماندگار عمیق

نوعی معماری خاص از شبکه عصبی بازگشتی است [13]. بهتر از شبکه‌های عصبی مرسوم برای وظایف طولانی مدت عمل می‌کند [15]. با استفاده از طراحی معماری Lstm به صورت عمیق، یک شبکه عصبی کوتاه مدت ماندگار عمیق خواهیم داشت. به این ترتیب دنباله خروجی شبکه عصبی کوتاه مدت ماندگار پایین تر، دنباله ورودی شبکه عصبی کوتاه مدت ماندگار بالاتر خواهد بود [16]. یک نوع معماری Lstm عمیق که در این تحقیق از آن استفاده کرده ایم به صورت زیر است [17][7].

$$\sigma(x) = \frac{1}{1 + \exp(-x)} \quad (2-1)$$

$$h_t^l = o_t^l \tanh(S_t^l) \quad (2-2)$$

$$i_t^l = \sigma(W_i^l [X_t; h_{t-1}^l; h_t^{l-1}] + b_i^l) \quad (2-3)$$

$$f_t^l = \sigma(W_f^l [X_t; h_{t-1}^l; h_t^{l-1}] + b_f^l) \quad (2-4)$$

$$s_t^l = f_t^l s_{t-1}^l + i_t^l \tanh(W_s^l [X_t; h_{t-1}^l; h_t^{l-1}] + b_s^l) \quad (2-5)$$

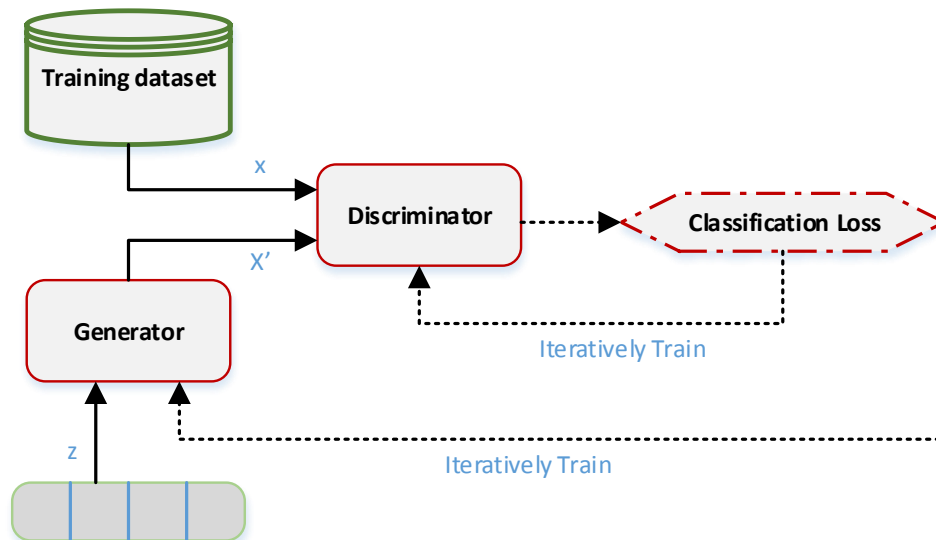
$$o_t^l = \sigma(W_o^l [X_t; h_{t-1}^l; h_t^{l-1}] + b_o^l) \quad (2-6)$$

$$S_N = \{a \in R^N : a_i \in [0,1], \sum \sum^N a_i = 1\} \quad (2-7)$$

که در آن l نشان دهنده نمایه لایه‌ها، فرمول، تابع سیگموئید دودویی و به ترتیب فرمول‌های 2-1 تا 2-6 $(\sigma(x), h_t^l, i_t^l, f_t^l, s_t^l, o_t^l)$ نشان دهنده بردارهای فعالیت دروازه‌های مخفی، ورودی، فراموشی، وضعیت و خروجی هستند و تابع فعالیت سافت ماکس برای یک مسئله ساده N بعدی به صورت فرمول 2-7 تعریف شده است.

2-2-4- شبکه‌های مولد تخصصی (GAN)

شبکه مولد تخصصی (GAN) رویکردی برای مدل‌سازی مولد با استفاده از روش‌های یادگیری عمیق¹ مانند شبکه‌های عصبی پیچشی² است. مدل‌سازی مولد یک فعالیت نظارت‌نشده³ در یادگیری ماشین است که شامل اکتشاف خودکار و یادگیری قواعد یا الگوهای موجود در داده‌های ورودی می‌شود. این کار به صورتی انجام می‌شود که از مدل می‌توان برای تولید یا خروجی دادن نمونه‌های جدیدی که به شکل قابل‌باوری از مجموعه داده اصلی قابل برگرفته شدن هستند استفاده کرد. شبکه‌های مولد تخصصی راهکاری هوشمندانه برای آموزش دادن یک مدل مولد هستند. آن‌ها این کار را با قاب‌بندی مسئله به عنوان یک مسئله یادگیری نظارت شد، **Learning Supervised** با دو زیر مدل انجام می‌دهند. این دو زیر مدل عبارت‌اند از مدل مولد⁴ که برای تولید نمونه‌های جدید آموزش داده می‌شود و مدل متمایز گر⁵ که تلاش می‌کند تا نمونه‌ها را به عنوان نمونه واقعی (از دامنه) یا جعلی (تولیدشده) دسته‌بندی کند. هر دو مدل با یکدیگر در یک بازی مجموع صفر تخصصی آموزش داده می‌شوند و این کار تا جایی ادامه پیدا می‌کند که مدل متمایز گر بالغ‌بر نیمی از دفعات گول بخورد؛ بدین معنا که مدل مولد، نمونه‌های قابل‌باور تولید کرده است [18].



شکل 2-2: ساختار شبکه GAN [18]

2-2-5- ماشین تورینگ عصبی

یک روش مشتق شده از ماشین تورینگ و شبکه عصبی است. این مدل متشکل از شبکه‌های عصبی بازگشتی RNN به همراه یک حافظه خارجی آدرس پذیر است. این کار باعث بهبود عملکرد و توانایی (قابلیت‌های) شبکه‌های عصبی بازگشتی برای اجرای وظایف الگوریتمیک از قبیل مرتب‌سازی، طبقه‌بندی، کپی کردن، N-gram است.

¹ Deep Learning

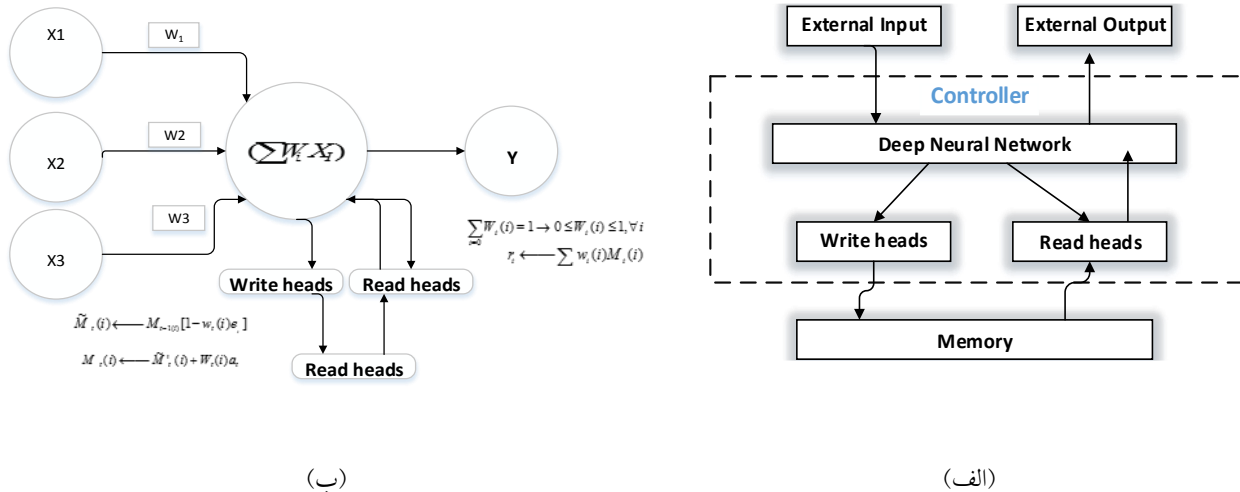
² Convolutional Neural Networks

³ Unsupervised Learning

⁴ Generator Model

⁵ Discriminator Model

به‌طورکلی، یک بانک حافظه، یک کنترل‌کننده و هدهای خواندن و نوشتن از اجزای اصلی این روش هستند. وظیفه کنترلر این است که داده‌ها را از بیرون دریافت و خروجی‌ها را در طول چرخه به‌روزرسانی تولید کند. بعلاوه، روش ماشین تورینگ عصبی NTM در قالب یک برنامه، هدهای خواندن و نوشتن را جهت ارتباط مستقیم با حافظه خارجی به شکل یک نوار هدایت می‌کند [19][20]. شکل 2-3 ساختار ماشین تورینگ عصبی به‌صورت کلی در بخش (الف) و به‌صورت جزئی در بخش (ب) نشان می‌دهد [21].

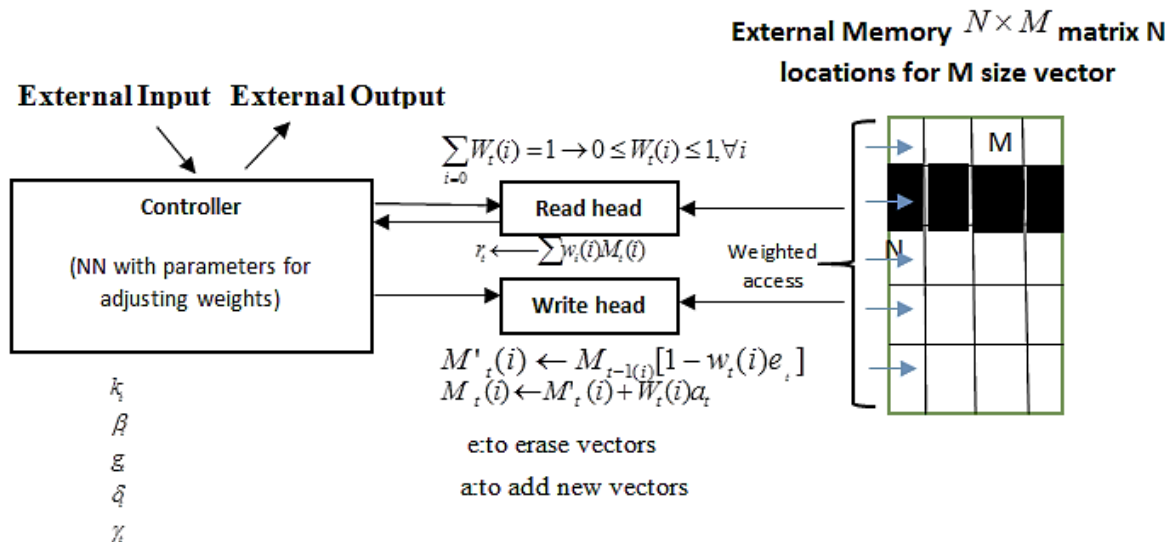


شکل 2-3: ساختار ماشین تورینگ عصبی (الف) به‌صورت کلی (ب) به‌صورت جزئی [21]

1-5-2-2- اعمالی که کنترلر از طریق هدها انجام می‌دهد

شامل پنج عمل اصلی خواندن، نوشتن، پاک کردن، رفتن به سلول حافظه بعدی و رفتن به سلول حافظه قبلی هست، در طی هر چرخه به‌روزرسانی، کنترلر شبکه، ورودی‌ها را از محیط خارجی دریافت کرده و خروجی‌ها را در پاسخ منتشر می‌کند. همچنین این شبکه با استفاده از مجموعه‌هایی از هدهای خواندن و نوشتن موازی، از یک ماتریس حافظه شروع به خواندن و نوشتن می‌کند. خط نقطه‌چین در شکل (2-3-الف) نشان‌دهنده تقسیم بین مدار NTM و جهان خارج است هر جزء ساختار، قابل تشخیص و تمایز است و شبکه را برای آموزش با نزول گرادیان، آسان می‌کند. این کار با تعریف عملیات خواندن و نوشتن «تار یا غیرواضح» انجام می‌گیرد. با تمام عناصر حافظه (به‌جای در نظر گرفتن یک عنصر به‌عنوان یک ماشین معمولی تورینگ یا رایانه دیجیتال) به میزان بیشتر یا کمتر ارتباط برقرار می‌کند، درجه تار شدگی با یک مکانیسم «تمرکز» تعیین می‌شود که هر یک از عملیات خواندن و نوشتن را وادار می‌کند تا با بخش کوچکی از حافظه ارتباط برقرار کند و بقیه را نادیده بگیرد، از آنجاکه تعامل با حافظه کم و بسیار پراکنده است. NTM بر اساس ذخیره داده‌ها و بدون مداخله است. خروجی هدها تعیین می‌کند که کدام مکان حافظه، مورد توجه بیشتری قرار می‌گیرد، این خروجی‌ها، یک وزن دهی نرمال شده بر روی ردیف‌های ماتریس حافظه را تعریف می‌کنند (اشاره به مکان‌های حافظه) هر وزن دهی، به ازای هر خواندن و نوشتن هد، درجه‌ای که هد در هر مکان می‌خواند یا می‌نویسد

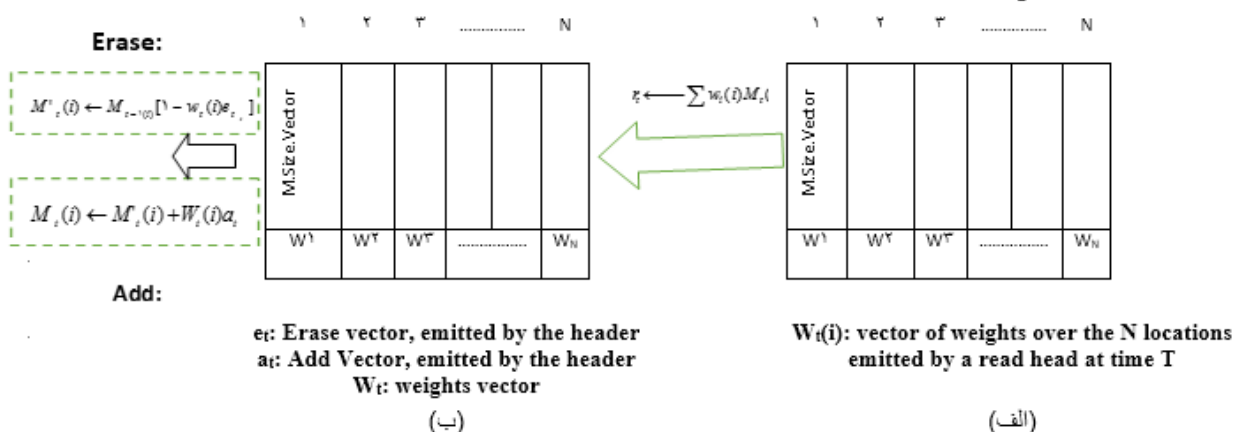
را تعریف می‌کند، به این ترتیب، یک هد می‌تواند به طور دقیق به یک مکان واحد از حافظه و یا به طور ضعیف به بسیاری از مکان‌های حافظه توجه کند.



شکل 2-4: نحوه دسترسی به حافظه خارجی [19]

2-5-2-2 خواندن و نوشتن

عملیات خواندن و نوشتن، توابع وزن دهی نرمال شده بر روی مکان‌های حافظه، مشابه مکانیسم‌های توجه هستند. این وزن دهی‌ها توزیع پیوسته‌ای را بر روی مکان‌های حافظه تعریف می‌کنند تا عملیات را متمایز کنند. عملیات خواندن یک ترکیب خطی ساده از مکان‌های حافظه است:



شکل 2-5: عملیات خواندن و نوشتن در NTM، [19]

شکل 2-5-2-2 عملیات خواندن و نوشتن در NTM [19] را در بخش‌های (الف) و (ب) نشان می‌دهد.

شکل 2-5-2-2 الف، N امین عنصر $W_t(i)$ را با توجه به حدود معادله 2-8 نشان می‌دهد:

$$\sum_{i=0} W_t(i) = 1 \rightarrow 0 \leq W_t(i) \leq 1, \forall i \quad (2-8)$$

M_t محتویات ماتریس حافظه $M*N$ در زمان t است؛ که در آن N تعداد مکان‌های حافظه و M اندازه بردار در هر مکان است. W بردار وزن‌ها در مکان‌های N است که با خواندن هد در زمان t منتشر می‌شود زیرا همه وزن‌ها نرمال شده‌اند. بردار خوانده شده یک ترکیب محدب وزنی از مکان حافظه است. طول M بردار r_t بازگشتی را توسط هد می‌خواند که به عنوان ترکیبی از بردارهای ردیف $M_t(i)$ در حافظه تعریف شده است، همانطور که در معادله 2-9 نشان داده شده است، قابل تفکیک از نظر حافظه و وزن است.

$$r_t \leftarrow \sum w_i(i) M_t(i) \quad (2-9)$$

شکل 2-6-ب، نشان می‌دهد که عملیات نوشتن ترکیبی محدب از پاک کردن و نوشتن در مکان‌های حافظه است. خروجی هد نوشتن هر دو بردار پاک کردن (e) و اضافه کردن (a) است. پس با پاک کردن مکان‌های تعریف‌شده توسط بردار وزن‌دهی نوشتن و سپس اضافه کردن به مکان‌های مشخص شده توسط همان بردار وزن، نوشتن در حافظه انجام می‌شود. مجدداً توجه کنید که پاک کردن و نوشتن مکان‌های کلی در نسبت‌های مختلف کل عملیات را متمایز می‌کند، جایی که بخش‌هایی از حافظه مطابق بردار وزن پاک می‌شوند، همانطور که در معادله 2-10 نشان داده شده است:

$$M'_t(i) \leftarrow M_{t-1(i)} [1 - w_t(i) e_t] \quad (2-10)$$

ضرب آن در محل حافظه به صورت هم‌تا به هم‌تا کار می‌کند؛ بنابراین، عناصر مکان حافظه در جایی که وزن است صفر می‌شوند و عنصر پاک‌کننده 1 است. اگر عنصر وزن یا فاصله صفر باشد، حافظه بدون تغییر باقی می‌ماند. هنگامی که چندین هد نوشتن وجود دارد، پاکسازی را می‌توان به هر ترتیبی انجام داد، جایی که اطلاعات جدید به مکان‌های تعیین شده توسط وزن‌ها اضافه می‌شود، همانطور که در معادله 2-11 نشان داده شده است:

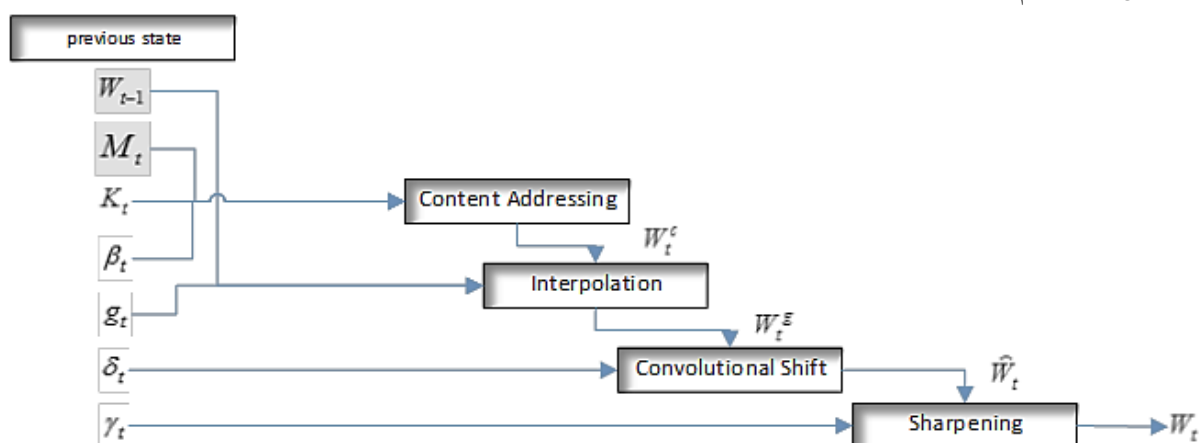
$$M_t(i) \leftarrow M'_t(i) + W_t(i) a_t \quad (2-11)$$

ترکیب عملیات پاکسازی و افزودن، محتوای حافظه نهایی را در زمان t تولید می‌کند. از آنجا که حذف و افزودن متفاوت است، عملیات نوشتن ترکیبی نیز قابل تشخیص است. توجه داشته باشید که هر دو بردار جمع و تفریق دارای مؤلفه‌های مستقل از M هستند. باز هم عملکرد توالی بردارهای اضافه شده توسط هدهای متعدد بی‌اهمیت است؛ بنابراین، امکان کنترل دقیق بر عناصر اصلاح شده در هر مکان حافظه را فراهم می‌کند.

2-2-5-3- مکانیسم آدرس‌دهی

اگرچه در بخش قبل، معادلات خواندن و نوشتن نشان داده و بررسی شده است؛ اما توضیحی در مورد اینکه چگونه وزن دهی‌ها تولید می‌شوند، داده نشده است. این وزن دهی‌ها با ترکیب دو مکانیسم آدرس‌دهی با امکانات مکمل به وجود می‌آیند. اولین مکانیسم، «آدرس‌دهی مبتنی بر محتوا» هست که به مکان‌ها بر اساس شباهت بین مقادیر فعلی و مقادیر منتشرشده توسط کنترلر توجه می‌کند. این مربوط به آدرس‌دهی مبتنی بر محتوای شبکه‌های هاپفیلد

می‌باشد. مزیت آدرس‌دهی مبتنی بر محتوا این است که بازیابی ساده است و فقط نیاز به کنترلر برای تولید یک تقریب از بخشی از داده‌های ذخیره‌شده دارد. بعداً آن را با حافظه برای دستیابی به مقدار ذخیره‌شده دقیق مقایسه کند. باین‌وجود، آدرس‌دهی مبتنی بر محتوا برای حل تمامی مسائل مناسب نیست. در برخی از کارها، محتوای یک متغیر به صورت دلخواه است، اما متغیر هنوز نیاز به یک نام یا آدرس قابل تشخیص دارد، مسائل محاسباتی از این قبیل هستند: متغیر X و متغیر Y می‌توانند هر دو مقدار را بگیرند، اما روند $f(x, y) = x \times y$ باید همچنان تعریف شود، یک کنترلر برای این کار قادر به مقداردهی متغیرهای x, y ذخیره کردن آن‌ها در آدرس‌های مختلف و سپس بازیابی آن‌ها و انجام یک الگوریتم ضرب هست. در این حالت، متغیرها با موقعیت مکانی و نه محتوا آدرس‌دهی می‌شوند، این شکل آدرس دادن را «آدرس‌دهی مبتنی بر مکان» نامیده می‌شود. آدرس‌دهی مبتنی بر محتوا متداول‌تر از آدرس‌دهی مبتنی بر مکان است؛ زیرا محتوای یک مکان حافظه می‌تواند اطلاعات مکان درون آن را در برداشته باشد. باین‌حال در آزمایش‌ها، ارائه آدرس‌دهی مبتنی بر مکان به عنوان یک عملیات اولیه برای برخی از فرم‌های تعمیم، ضروری است. در نتیجه، هر دو مکانیسم باهم استفاده می‌شوند. نمودار جریان مکانیسم آدرس‌دهی، نشانگر ترتیب عملیات برای ساخت یک بردار وزن دهی در هنگام خواندن و نوشتن هست.



شکل 2-6: نمودار جریان مکانیسم آدرس‌دهی [21]

لازم به ذکر است در ساختار شبکه Neural Turing Machine (NTM) از شبکه‌های انجمنی استفاده شده است. NTM همانطور که توضیح داده شد یک نوع شبکه عصبی برای مدل کردن وظایف مرتبط با حافظه است که قادر به عملیات مانند خواندن، نوشتن و حذف داده‌ها در حافظه است. بخش حافظه NTM در واقع یک نوع از حافظه نهان خارجی است که در کنار شبکه عصبی درونی تشکیل می‌شود. این حافظه توسط شبکه‌های انجمنی که توابع قابل آموزشی را ارائه می‌دهند، مدیریت می‌شود. در واقع شبکه‌های انجمنی در NTM وظیفه مدیریت و نظارت بر تغییرات حافظه و همچنین تصمیم‌گیری در مورد انجام عملیات‌های مرتبط با آن (مانند خواندن و نوشتن) را بر عهده دارند.

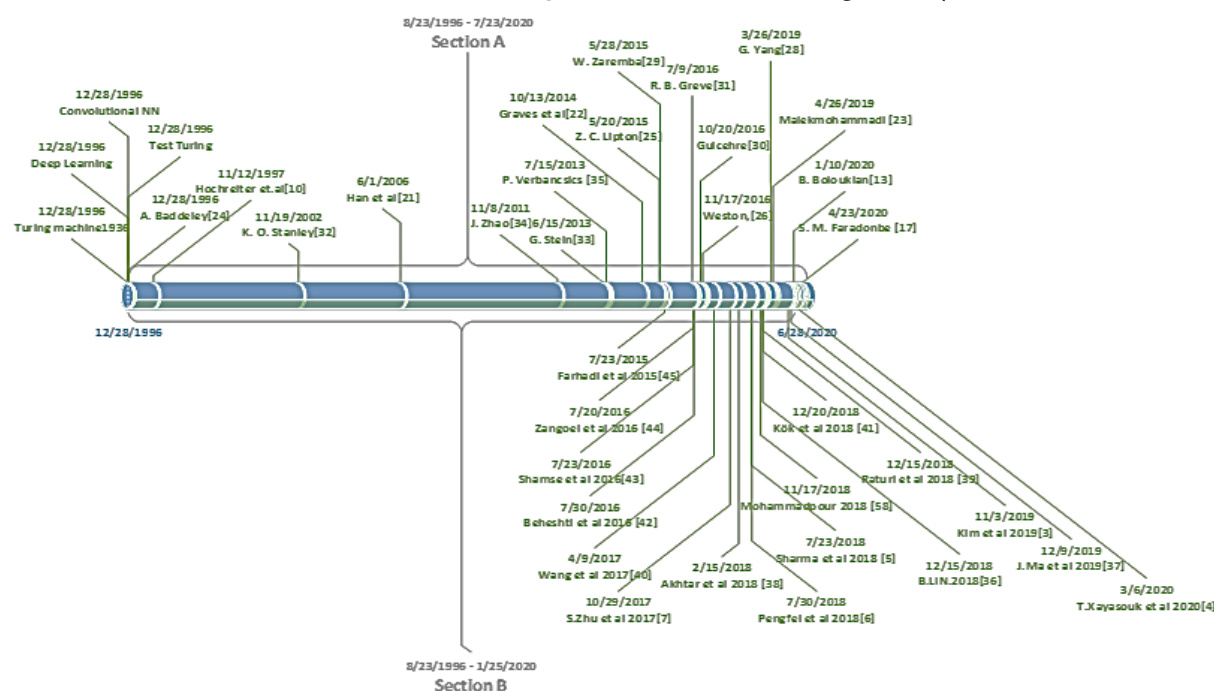
2-5-4- شبکه کنترلر

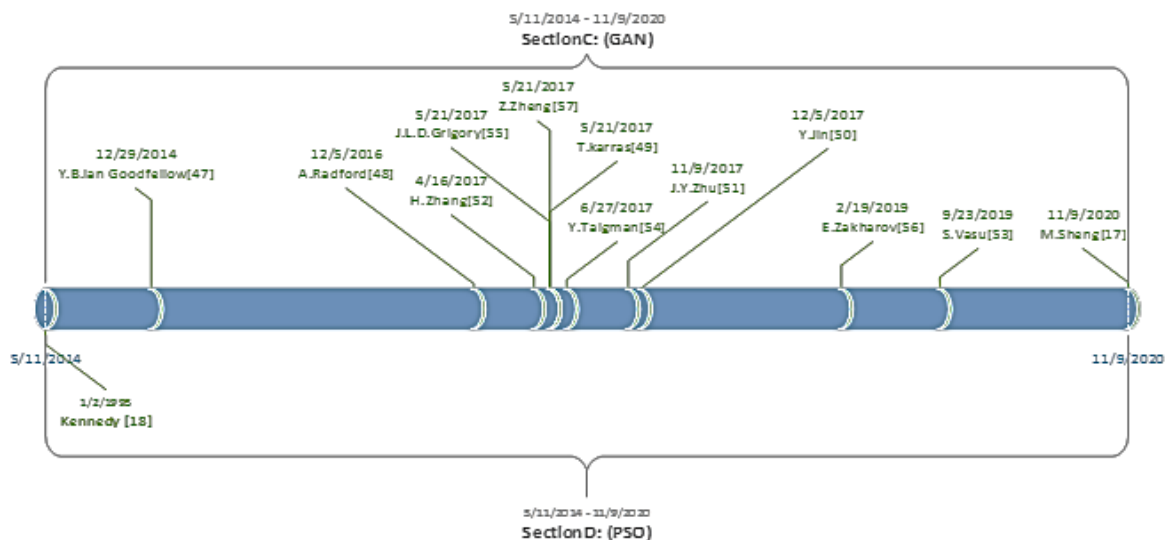
ساختار NTM که در بالا توضیح داده شد. دارای چندین پارامتر آزاد: اندازه حافظه، تعداد هدهای خواندن و نوشتن و حد مجاز تغییرات مکان است اما شاید مهم‌ترین ساختار، نوع شبکه عصبی استفاده‌شده به عنوان کنترلر باشد،

مخصوصاً وقتی که باید تصمیم گرفته شود که آیا از یک بازگشتی استفاده شود و یا از یک شبکه پیش‌خور، یک کنترلر بازگشتی مانند LSTM دارای حافظه داخلی درون خود است که می‌تواند ماتریس بزرگ‌تری را تکمیل کند. اگر یک کنترلر واحد پردازش مرکزی در یک کامپیوتر دیجیتال (ولو اینکه با دستورالعمل‌های تطبیق‌پذیر به جای دستورالعمل‌های از پیش تعریف‌شده باشد) را با ماتریس حافظه RAM مقایسه کنیم، متوجه می‌شویم که فعال‌سازی‌های پنهان کنترلر بازگشتی، شبیه به رجیستری‌ها در پردازنده هستند. آن‌ها به کنترلر اجازه می‌دهند تا اطلاعات را در سرتاسر مراحل زمانی مختلف عملیات، ترکیب کند. از سوی دیگر، یک کنترلر پیش‌خور می‌تواند یک شبکه بازگشتی را با خواندن و نوشتن در مکان یکسان در حافظه، در هر مرحله تقلید کند، علاوه بر این، کنترلرهای پیش‌خور اغلب شفافیت بیشتری به عملیات شبکه می‌دهند، زیرا الگوی خواندن و نوشتن بر روی ماتریس حافظه، معمولاً ساده‌تر از حالت داخلی یک RNN تفسیر می‌شود. باین وجود، یکی از محدودیت‌های یک کنترلر پیش‌خور این است که تعداد هدهای خواندن و نوشتن هم‌زمان باعث تنگی (عملیات محدودکننده) در نوع محاسباتی می‌شود که NTM می‌تواند انجام دهد. با یک هد خواندن واحد، فقط می‌توان یک تبدیل یکانی بر روی یک بردار حافظه‌ی واحد در هر مرحله زمانی انجام داد یا دو هد خواندن می‌توان تبدیل‌های دودویی انجام داد و غیره. کنترلرهای بازگشتی می‌توانند به‌طور داخلی بردارهای خواندن را از مراحل زمانی قبلی ذخیره کنند، بنابراین از این محدودیت رنج نمی‌برند.

3-2- پیشنهاد تحقیق

در شکل 3-8 جدول زمان‌بندی پیش‌بینی پارامترهای کیفیت هوا در این بخش مورد بررسی و ارزیابی قرار می‌گیرد و در سه زمینه پیش‌بینی پارامترهای کیفی هوا و ماشین عصبی تورینگ و شبکه‌های GAN ترسیم شده است. بخش الف و بخش ب و بخش پ از شکل 7-2 به تفکیک مورد بررسی قرار گرفته است.





شکل 2-7: جدول زمان‌بندی پیش‌بینی پارامترهای کیفیت هوا

2-3-1- بخش الف- ماشین‌های تورینگ عصبی (NTM)

اساس تحقیقات در مورد ماشین‌های هوشمند است که به بیش از 70 سال برمی‌گردد هم‌زمان با ایجاد اولین رایانه‌های الکترونیکی [22] طراحی الگوریتم‌ها همیشه یکی از اهداف عمومی و بلندمدت هوش مصنوعی بوده است. [21] یکی از اولین تلاش‌ها برای ایجاد یک ماشین هوشمند در زمان اختراع ماشین تورینگ توسط آلن تورینگ در سال 1936 مشاهده شد. در ابتدا، برنامه تورینگ تأثیر عمده‌ای بر روانشناسی و فلسفه شناختی داشت. هر دوی این زمینه‌ها رایانه را استعاره‌ای از مدل عملکردی مغز می‌دانستند. این استعاره به دلیل عدم تشابه معماری ماشین تورینگ در مقایسه با مغز انسان، به سرعت توسط علوم اعصاب کنار گذاشته شد. [23]

هوش مصنوعی AI در اصل به معنای هوش ماشین یا قابلیت ادراک یا یادگیری ماشین است، ماشین اینجا به معنای هر دستگاه هوشمند است که دارای پردازنده باشد و بتواند داده‌های ورودی را از محیط بگیرد و روی آن‌ها پردازش انجام دهد و احیاناً تصمیم‌گیری هم کند. هدف اصلی و نهایی در هوش مصنوعی شبیه‌سازی و درک رفتار انسان است. در نهایت قرار است ربات‌هایی یا دستگاه‌هایی ساخته شوند که بتوانند جایگزین انسان شوند که کار برای انسان سخت یا خطرناک است. یکی از مهم‌ترین ابزارها و شاید می‌شود گفت از مهم‌ترین ابزارهای هوش مصنوعی یادگیری ماشین است که هسته اصلی هوش مصنوعی است یعنی بخش یادگیری را شامل می‌شود. یادگیری ماشین یا ML شامل انواع مختلفی از روش‌ها و الگوریتم‌هایی می‌شود که هر کدام به یک نحوی کار می‌کند. از آنجاکه یادگیری عمیق زیرمجموعه ML است و این دو زیرمجموعه‌ای از هوش مصنوعی AI می‌باشند؛ بنابراین تمام مباحث در حوزه این علوم معرفی می‌شود. اگر بخواهیم یک تاریخچه مختصری از روند شکل‌گیری مبحث یادگیری عمیق بگویم اولین نمونه‌های آن شبکه‌های عصبی کانالوشنی در دهه 1990 میلادی مطرح شدند. در سال 1993 میلادی اولین نمونه موفقیت‌آمیز شبکه‌های عصبی کانالوشنی طراحی شد. چند سال بعد شبکه‌های عصبی بازگشتی یا RNN طراحی شدند که اصطلاحاً به این مدل LSTM گفته می‌شود ولی بعد از آن طی یک دوره‌ای چند سال ما در مبحث هوش مصنوعی

و یادگیری عمیق دچار رکود شدیم. علت آن به خاطر محدودیت و کمبود داده و سخت‌افزار و مشکلات آموزش بود در سال 2006 این سال عبور از این رکود نامیده شد زیرا در این سال یک روش جدید آموزش شبکه‌های عمیق ارائه شد [24] و تا سال 2014 تعداد دانشمندان زیادی در این حوزه شروع به کار کردند و تعداد مقالات و کتاب‌ها رو به رشد بودند و از سال 2012 تا 2020 روند تعداد پروژه‌هایی که در حوزه یادگیری عمیق مطرح شد به سرعت در حال افزایش است.

NTM برای اولین بار توسط Grave و همکاران در سال 2014 ارائه شد [25] در واقع یک شبکه عصبی است که توانایی خواندن و نوشتن روی ماتریس حافظه خارجی، مشابه حافظه تصادفی در رایانه معمولی را دارد. شبکه عصبی NTM از حافظه خود برای نمایش و دست‌کاری ساختارهای پیچیده داده استفاده می‌کند و هم‌زمان، همان شبکه عصبی می‌تواند از داده‌ها بیاموزد. در ادامه به مرور کارهای شاخص قبلی در زمینه‌ی ماشین عصبی تورینگ که انجام شده، می‌پردازیم. در مقاله [25][26]، مطالعات تحقیقاتی بسیاری با استفاده از روش‌های یادگیری ماشین و یادگیری عمیق انجام شده است، که می‌توان با استفاده از ماشین تورینگ و شبکه عصبی که این مدل متشکل از شبکه‌های عصبی بازگشتی RNN به همراه یک حافظه خارجی آدرس پذیر است. این کار به بهبود عملکرد و توانایی شبکه‌های عصبی بازگشتی برای اجرای وظایف الگوریتمیک می‌پردازد [27]، در مقایسه با ماشین تورینگ روش NTM یک کنترلر عصبی، هدهای خواندن و نوشتن را جهت ارتباط مستقیم با حافظه خارجی به شکل یک نوار هدایت می‌کند [28]. در مقاله [29]، یک مدل یادگیری ماشین برگرفته از NTM به تغییر معماری حافظه پرداخته و مدلی به نام کامپیوتر عصبی قابل تفکیک DNC¹ ارائه داده‌اند. در این مدل از معماری مشابه کنترلر شبکه عصبی با دسترسی هد خواندن_نوشتن به ماتریس حافظه استفاده شده است که مکانیسم دسترسی و ارتباط آن با حافظه متفاوت است. همچنین برای رفع محدودیت حافظه، از حافظه دینامیک استفاده شده است و اطلاعات تنها در صورتی حفظ می‌شوند که به تعداد دفعات مشخصی تکرار شوند. با استفاده از این روش تاکنون با یادگیری نظارت‌شده نشان داده شده است که می‌تواند به پرسش‌های ترکیبی طراحی شده جهت تقلید از مسائل و استنتاج در زبان طبیعی (با استفاده از دیتاست bAbI) پاسخ دهد. در مقاله [30] توانایی انجام وظایفی از قبیل پیدا کردن کوتاه‌ترین مسیر بین نقاط مشخص شده (مانند شبکه حمل و نقل) ایجاد شده است که با استفاده از کامپیوتر عصبی قابل تفکیک، ارائه را نشان داده‌اند. همچنین امکان حدس لینک‌های گم شده (مانند شجره‌نامه خانوادگی) در گراف‌هایی که به صورت تصادفی ایجاد شده‌اند را دارد. روش‌های دیگری که تاکنون مطرح شده‌اند، اقدام به تغییراتی در بخش کنترلر روش NTM کرده اند که عبارت‌اند از Lie Access [31]، RL NTM [32] و Dynamic NTM [33] که برای وظایف کپی و افزودن استفاده شده‌اند. اما تاکنون برای حل وظایف سخت‌تر در تکامل عصبی، بهبود نیافته‌اند و از دقت و سرعت کافی برخوردار نیستند. در مقاله [34] نشان داده‌اند، ماشین تورینگ عصبی جهت تقویت توپولوژی ENTM² در واقع یک نسخه تکاملی از NTM است که در این پژوهش، روش NTM با الگوریتم تکامل عصبی جهت تقویت توپولوژی NEAT³ [35] تکامل داده شد.

¹ Differentiable Neural Computer(DNC)

² Evolving Neural Turing Machine

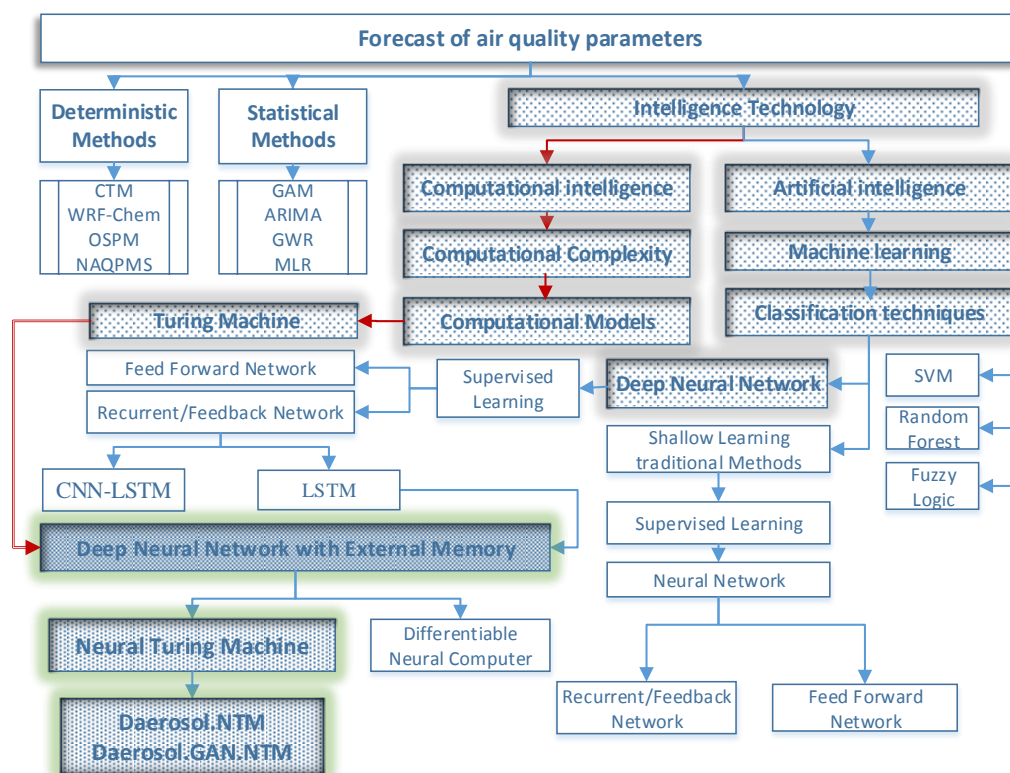
³ NeuroEvolution of Augementing Topologies

درواقع NEAT شکل خاصی از الگوریتم ژنتیک است [36] و برخلاف روش‌های سنتی نیازی به طراحی توپولوژی ANN ندارد، بلکه در عوض توانایی ایجاد و تکامل توپولوژی و وزن‌های ANN را دارد [37]. روش NEAT با جمعیت کوچک شبکه عصبی ساده شروع می‌شود. با افزودن نودها و اتصالات جدید از طریق جهش، پیچیدگی آن افزایش می‌یابد. به‌طور کلی NEAT یک روش تکاملی است که توپولوژی و وزن صحیح یک شبکه را به‌منظور به حداکثر رساندن عملکرد در یک وظیفه پیدا می‌کند [38]. روش ENTM [34] نیز توانایی حل وظیفه‌ی ساده‌ای مثل کپی را دارد و برای اولین بار نسخه دنباله‌داری از double (T-Maze). یک مسئله یادگیری تقویتی را مطرح می‌کند. در وظیفه یادگیری (T-Maze) عامل از حافظه جهت تطبیق رفتار (که به‌طور معمول به شبکه عصبی نیاز دارد) استفاده می‌کند. از جمله مشکلات این روش محاسبات زیاد و محدودیت حافظه است. لذا انتخاب مناسب مدل می‌تواند نقطه قوت این پژوهش در پیش‌بینی پارامترهای کیفی هوا به‌منظور عدم جلوگیری از مشکلات شبکه‌های عمیق که دچار حفظ کردن و ناپدید شدن وزن در هنگام به‌روزرسانی می‌شوند، محسوب گردد. مقایسه روش‌های به‌کارگیری شده در مقاله‌های معرفی‌شده با روش این پژوهش در جدول 2 مشاهده می‌شود. در این جدول دقت و صحت روش‌های بکار گرفته‌شده نسبت به داده‌های آزمون و اعتبارسنجی می‌باشد و با توجه به پارامترهای وابسته پژوهش در مکان‌های مورد مطالعه و اندازه مجموعه داده‌ها و تعداد متغیرها، مورد ارزیابی قرار گرفته است.

2-3-2- بخش ب- پیش‌بینی پارامترهای کیفیت هوا

در سال‌های متمادی با توجه به اهمیت و ضرورت تحقیق در خصوص تأثیر آلودگی هوا بر سلامت انسان و محیط‌زیست، تحقیقات بسیاری انجام پذیرفته است. اساس پژوهش حاضر در خصوص پیش‌بینی پارامترهای کیفی هوا از سال 2015 تا 2020 می‌باشد. اطلاعات مربوط به کیفیت هوا اهمیت زیادی برای حفاظت از سلامت انسان و کنترل آلودگی هوا دارد. گزارش سازمان بهداشت جهانی WHO در سال 2000 نشان می‌دهد که تقریباً $2/5$ تا 11 درصد از مرگ‌ومیر سالیانه در اروپا به علت آلودگی هوا رخ داده است [7]. در سال‌های اخیر افزایش قابل توجه وسایل نقلیه و کارخانه‌ها دیده می‌شود و انتظار می‌رود این روند در آینده نزدیک ادامه یابد. آلودگی هوا نیز تأثیر زیادی بر معماری و محیط‌زیست دارد. آلودگی هوا همچنین باعث ایجاد آلودگی آب در رودخانه‌ها و دریاچه‌ها می‌شود که اثر منفی بر سلامت حیوانات و گیاهان دارد. مشکلات زیست‌محیطی ناشی از افزایش بیش‌ازحد جمعیت در شهرها جدی است. محققان دیدگاه‌های متفاوتی نسبت به رابطه بین شهرنشینی و محیط شهری دارند. برخی از محققان بر این باورند که افزایش شهرنشینی، آلودگی محیط‌زیست شهری را تشدید می‌کند. کاملاً، شهرنشینی زندگی انسان را تغییر داده است. اولاً، مردم از منابع طبیعی برای تولید محصولات مورد نیاز استفاده می‌کنند و در این فرایند آلاینده‌های زیادی تولید می‌کنند. ثانیاً، روند شهرنشینی موجب ایجاد تقاضا برای ساخت‌وساز حمل‌ونقل و زیرساخت شده است که باعث افزایش مصرف انرژی خانوار خواهد شد. افزایش مصرف انرژی باعث تولید آلاینده‌های زیادی می‌شود و در نهایت موجب بدتر شدن محیط شهری می‌گردد [39]. اگر بخواهیم یک تاریخچه مختصری از روند شکل‌گیری مبحث

پیش‌بینی پارامترهای کیفی هوا از ابتدا تا ایده پیشنهادی این تحقیق را بررسی کنیم، می‌توان به توضیحات شکل 2-8، نمودار مایند-مپ این تحقیق اشاره کرد.



شکل 2-8: نقشه ذهنی و جریان اصلی این تحقیق در بین روش‌های پایه

برای تحقیقات بیشتر، همان‌طور که در شکل 2-8 نشان داده شده است، از سه روش گسترده برای نظارت و جمع‌آوری داده‌های آلودگی هوا با استفاده از روش‌های قطعی، روش‌های آماری و روش‌های یادگیری ماشین استفاده می‌شود. در روش قطعی، پیش‌بینی کیفیت هوا با ساخت یک مدل شبیه‌سازی از روند پراکندگی و حمل‌ونقل شیمی جوی صورت می‌گیرد که معمولاً جبرگرایانه دیده می‌شود نمونه‌هایی از این روش‌ها ¹CTMs، ²WRF، ³OSPM، ⁴NAQPMS می‌باشند. در روش‌های آماری که نوع دیگری از رویکردهای پیش‌بینی هوا است، غلظت آلاینده‌ها با استفاده از تعداد زیادی داده مشاهده شده و بر محدودیت‌های روش‌های قطعی غلبه می‌کند و عملکرد پیش‌بینی این روش‌ها محدود است؛ زیرا با غیرخطی بودن دنیای واقعی مغایرت دارد از جمله روش‌های آماری ⁵GAM، ⁶ARIMA، ⁷GWR، ⁸MLR را می‌توان نام برد. به‌عنوان روش‌های جایگزین برای پیش‌بینی کیفیت هوا روش‌هایی مانند مدل‌های یادگیری ماشین، نظیر ⁹SVM، ¹⁰ANNs، ¹¹FL، ¹²RF استفاده شده است. در میان این روش‌ها، شبکه‌های عصبی یکی

¹ Chemical Transport Models (CTMs)
² Weather Research and Forecasting (WRF)
³ Operational Street Pollution Models (OSPM)
⁴ Nested Air Quality Prediction Modeling System (NAQPMS)
⁵ Generalized Additive Models (GAMs),
⁶ Autoregressive Integrated Moving Average (ARIMA)
⁷ Geographically Weighted Regression (GWR)
⁸ Multi-layer Regression (MLR)
⁹ Support Vector Machine (SVM)
¹⁰ Artificial Neural Networks (ANNs)
¹¹ Fuzzy Logic (FL)
¹² Random Forest (RF)

از محبوب‌ترین روش‌ها برای پیش‌بینی کیفیت هوا بوده‌اند[8]. در روش پیشنهادی از روش یادگیری عمیق، ترکیب ماشین تورینگ و شبکه‌های عصبی بازگشتی LSTM و شبکه GAN به همراه یک حافظه خارجی آدرس پذیر، استفاده شده است که قادر است پارامترهای کیفی هوا را زودتر، قبل از وقوع آلودگی ریز گرد با دقت مناسب پیش‌بینی کند. در ادامه مباحث بالا به مرور کارهای شاخص قبلی در زمینه‌ی روش‌های پیش‌بینی پارامترهای کیفی هوا که انجام شده، می‌پردازیم.

در مقاله‌های [5][6]، هدف پیش‌بینی غلظت ذرات جامد PM_{10} و $PM_{2.5}$ است و استفاده از مدل‌های یادگیری عمیق و عملکرد بهتر مدل DLSTM نسبت به DAE و DNN را نشان داده است. مقاله [7]، با در نظر گرفتن الگوی فصلی و تعداد قابل توجهی از داده‌ها، میزان دقیق AQI یک مکان را با استفاده از مدل‌های یادگیری عمیق و مناسب بودن مدل LSTM برای داده‌های سری‌های زمانی را نشان می‌دهد. رویکرد [40] یک مدل ترکیبی مبتنی بر CNN و LSTM با استفاده از فواصل زمانی 24 ساعته (روزانه) برای پیش‌بینی $PM_{2.5}$ در منطقه شهری پکن با استخراج ویژگی‌های مکانی-زمانی داده‌ها پیشنهاد کرد. این مقاله روش‌های یادگیری عمیق مانند LSTM، Bi-LSTM، GRU، Bi-GRU، CNN و یک مدل ترکیبی CNN-LSTM را مقایسه می‌کند. شبکه عصبی کانولوشنال (مدل CNN) در فیلتر کردن ویژگی‌های فضایی استفاده می‌شود. در همان زمان، یک شبکه LSTM برای استخراج ویژگی‌های زمانی استفاده شده است. در پژوهش [9]، هدف پیش‌بینی غلظت ذرات جامد $PM_{2.5}$ است و مدل شبکه عصبی عمیق مورد آزمایش قرار گرفت و برتر بودن مدل DNN را در پیش‌بینی به اثبات رساند. در مقاله [41]، مقدار PM_{10} توسط الگوریتم پرسپترون چندلایه و SVM پیش‌بینی شده است. مقاله [42]، شناسایی شاخص کیفیت هوا AQI در آینده با استفاده از شبکه عصبی مصنوعی به عنوان هدف بیان شده است. در رویکرد [43]، این مقاله به منظور توسعه سیستم پیش‌بینی کننده برای پیش‌بینی زودهنگام شاخص کیفیت هوا AQI انجام گردیده است، در پژوهش [44]، این مقاله ابتدا به ارائه مدل یادگیری عمیق بر روی داده‌های اینترنت اشیا در شهر هوشمند می‌پردازد. دوم، ایجاد یک مدل پیش‌بینی مبتنی بر LSTM را طراحی و پیاده‌سازی کرده است که برای حل مسائل کیفیت هوا آینده در شهرهای هوشمند مفید است. در مقاله [45]، هدف پیش‌بینی میزان CO ، NO_2 ، SO_2 هوای کلان‌شهر تبریز با استفاده از سه نوع شبکه عصبی مصنوعی چندلایه پیش‌خور و چهار مدل الگوریتم آموزشی پس انتشار خطا را بیان کرده است. مقاله [46]، هدف پیش‌بینی شاخص آلودگی هوا AQI با استفاده از مدل رگرسیون چند متغیره است، رویکرد [47]، سعی شده با استفاده از مدل‌های پرسپترون شبکه‌های عصبی مصنوعی و مدل زنجیره مارکوف غلظت PM_{10} پیش‌بینی و تحلیل گردد. مقاله [48]، مدل‌سازی غلظت آلاینده‌های شاخص آلودگی هوا با توجه به عوامل اقلیمی و شاخص‌های پایدار و ناپایدار با استفاده از مدل شبکه عصبی مصنوعی آلاینده‌های PM_{10} و AQI مورد بررسی قرار گرفت.

در جدول 2-2 می‌توان مقایسه روش‌های به کارگیری شده در مقاله‌های معرفی شده با روش این پژوهش را مشاهده کرد.

جدول 2-2: مقایسه روش‌های به‌کارگیری شده در مقاله‌های معرفی شده با روش این پژوهش

منابع	داده ها	اندازه مجموعه داده			تعداد متغیرهای مستقل	روش	پارامترهای ارزیابی شده	دقت	صحت	ریشه میانگین مربعات خطا	میانگین درصد مطلق خطا	حذف داده های از دست رفته	فاصله زمانی قبل و بعد از رویداد
		دوره زمانی	تعداد ایستگاه	حجم نمونه کل									
[40]	داده های کیفیت و هواشناسی (پکن)	1 مارس 2013 تا 28 فوریه 2017	-	-	12	DLSTM, Bi-LSTM, GRU, Bi-GRU, CNN, CNN-LSTM, CNN-GRU,	PM _{2.5} ,	-	-	For DLSTM: PM _{2.5} =16%, For Bi-LSTM: PM _{2.5} =16%, For GRU: PM _{2.5} =17%, For Bi-GRU: PM _{2.5} =17%, For CNN: PM _{2.5} =17%, For CNN-LSTM: PM _{2.5} =15%, For CNN-GRU: PM _{2.5} =17%,	-	-	-

منابع	داده ها	اندازه مجموعه داده			تعداد متغیرهای مستقل	روش	پارامترهای ارزیابی شده	دقت	صحت	ریشه میانگین مربعات خطا	میانگین درصد مطلق خطا	حذف داده های از دست رفته	فاصله زمانی قبل و بعد از رویداد
		دوره زمانی	تعداد ایستگاه	حجم نمونه کل									
[6]	داده های کیفیت و هواشناسی (سنول)	1، ژانویه 2015 تا 31، دسامبر 2018	25، کنترل کیفیت و یک ایستگاه هواشن اسی	-	12	DLSTM, DAE	PM _{2.5} , PM ₁₀	For DLSTM: PM _{2.5} =88 %, PM ₁₀ =89% For DAE: PM _{2.5} =84 %, PM ₁₀ =85%		For DLSTM: PM _{2.5} =11%, PM ₁₀ =11% For DAE: PM _{2.5} =15%, PM ₁₀ =15%	-	-	-
[5]		یک سال	39، کنترل کیفیت و یک ایستگاه هواشن اسی	-	17	DNN, DLSTM	PM _{2.5} , PM ₁₀	-	-	For DNN: PM _{2.5} =6%, PM ₁₀ =6% For DLSTM: PM _{2.5} =5%, PM ₁₀ =5%	-	-	-

منبع	داده ها	اندازه مجموعه داده			تعداد متغیرهای مستقل	روش	پارامترهای ارزیابی شده	دقت	صحت	ریشه میانگین مربعات خطا	میانگین درصد مطلق خطا	حذف داده های از دست رفته	فاصله زمانی قبل و بعد از رویداد
		دوره زمانی	تعداد ایستگاه	حجم نمونه کل									
[9]	داده های کیفی (ووهان)	-	یک ایستگاه کنترل کیفیت		8	DNN, SVM, BP	PM _{2.5}	For DNN: PM _{2.5} = 90% For SVM: PM _{2.5} = 66% For BP: PM _{2.5} = 67%	-	For DNN: PM _{2.5} = 9% For SVM = - For BP = -	-	-	-
[7]	داده های کیفی (پورام دهلی نو)	دو سال	ایستگاه کنترل کیفیت	-	7	DLSTM	AQI	For DLSTM: AQI= 63%	-	For DLSTM: AQI= 37%	-	-	-
[40]	داده های کیفی (مرکز PCB)	دو سال	ایستگاه کنترل کیفیت		8	MLP	PM ₁₀	For MLP: PM ₁₀ = 95%	-	-	-	-	-
[49]	داده های کیفی (چین) http://113.108.142.147:20035/emcpu-blish/	دو سال	-	-	6	ANFIS, AHP	AQI	For ANFIS: AQI=76%, For AHP: AQI=68%	-	-	-	-	-

منابع	داده ها	اندازه مجموعه داده			تعداد متغیرهای مستقل	روش	پارامترهای ارزیابی شده	دقت	صحت	ریشه میانگین مربعات خطا	میانگین درصد مطلق خطا	حذف داده های از دست رفته	فاصله زمانی قبل و بعد از رویداد
		دوره زمانی	تعداد ایستگاه	حجم نمونه کل									
[45]	داده های کیفی و هواشناسی (تهران)	-	ده ایستگاه	-	6	Multivariate regression	AQI	For Multivariate regression: AQI =76%	-	-	-	-	-
[46]	داده های کیفی (مشهد)	دو ماه	-	-	4	MLP	PM ₁₀	For MLP: PM ₁₀ =91%	-	-	-	-	-
مطالعه حاضر	داده های کیفی و هواشناسی (تهران)	بیست سال	چهار ایستگاه هواشناسی و پانزده حسگر آلودگی هوا	58,922	29	DAerosol.GAN.NTM	PM _{2.5} PM ₁₀ AQI TIBAAE	PM _{2.5} =96%, PM ₁₀ =97%, AQI =82%	PM _{2.5} =87%, PM ₁₀ =88%, AQI=75%	PM _{2.5} =4%, PM ₁₀ =3%, AQI =18%	PM _{2.5} =13%, PM ₁₀ =12%, AQI =25%	Using GAN networks	TIBAAE _{before} =96(H) TIBAAE _{after} =24(H)

2-3-3- بخش پ- شبکه متخاصم مولد (GAN)

از آنجایی که هدف اصلی پژوهش حاضر در استفاده از شبکه‌های GAN برای تولید داده جدید با استفاده از یک مدل آموزش دیده شده است. این قابلیت شبکه‌های GAN در بسیاری از حوزه‌های کاربردی مورد استفاده قرار می‌گیرد، از جمله در حوزه‌هایی که توسط محققین دیگر انجام گرفته است، در ادامه ذکر شده است.

استفاده از شبکه‌های GAN می‌تواند در تولید تصاویر با رزولوشن بالا [50][51][52][53] مورد استفاده قرار گیرد و به طور کلی در حوزه‌هایی که نیاز به تولید داده‌های جدید دارند، مانند حوزه معماری و طراحی [54]. همچنین، استفاده از شبکه‌های GAN در تولید تصاویر کارتونی، emoji [55] و تصاویر با سن متفاوت از افراد [56][18] نیز از کاربردهای دیگر است. علاوه بر این، استفاده از شبکه‌های GAN در تبدیل تصاویر از یک فصل به فصل دیگر [57] و تبدیل تصاویر ثابت به ویدئو [58] نیز مورد استفاده قرار می‌گیرد. همچنین، استفاده از شبکه‌های GAN در تبدیل متن به تصویر نیز مورد توجه قرار گرفته است [59][60]. بنابراین، استفاده از شبکه‌های GAN در تولید داده جدید و تبدیل داده‌های موجود به شکل‌های مختلف، در حوزه‌های مختلفی مورد استفاده قرار می‌گیرد و این یکی از قابلیت‌های مهم این شبکه‌ها است.

2-4- جمع‌بندی

در این فصل پس از مقدمه و بیان مبانی نظری به مرور کارهای گذشته پرداختیم، در فصل بعد به ارائه روش‌های پیشنهادی می‌پردازیم و همان‌طور که اشاره شد در روش پیشنهادی از روش یادگیری عمیق، ترکیب ماشین تورینگ و شبکه‌های عصبی بازگشتی LSTM و شبکه GAN به همراه یک حافظه خارجی آدرس پذیر، استفاده شده است که قادر است پارامترهای کیفی هوا را زودتر، قبل از وقوع آلودگی ریز گرد با دقت مناسب پیش‌بینی کند.

فصل سوم

روش پیشنهادی

3-1- مقدمه

شکل 3-1 نشان دهنده چارچوب پیشنهادی در این مطالعه است که شامل دو بخش DAerosol-NTM و DAerosol.GAN.NTM است. در بخش اول، از NTM با کنترل‌کننده مبتنی بر LSTM استفاده می‌شود و در بخش دوم، شبکه GAN برای تولید داده‌های جدید استفاده می‌شود. در هر بخش، مراحل آموزش، آزمایش و اعتبارسنجی وجود دارد.

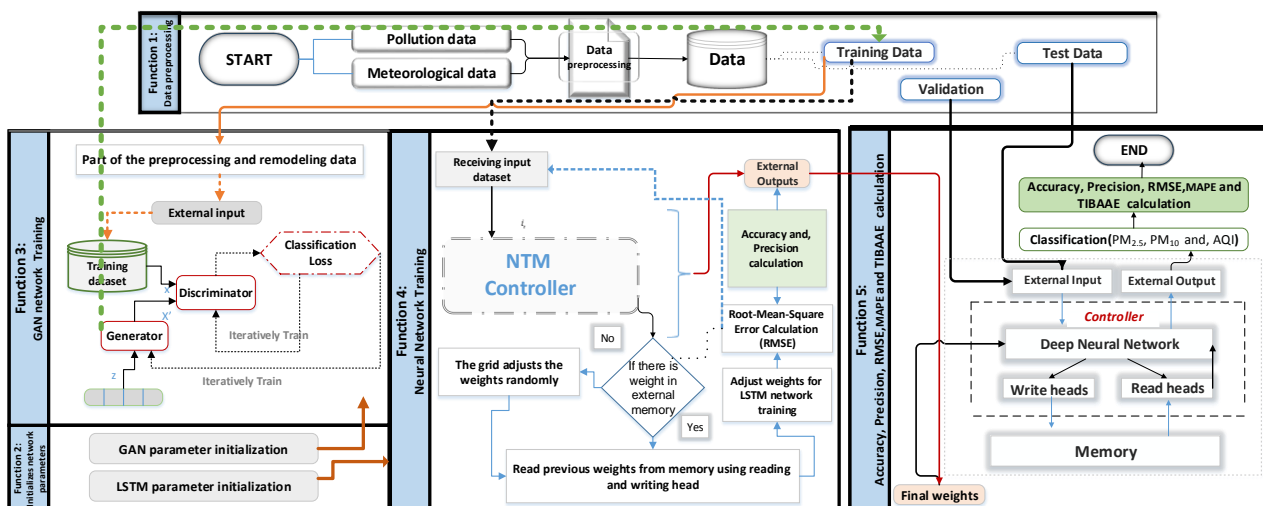
DAerosol-NTM (Deep Aerosol - Neural Turing Machines) یک شبکه عصبی با کنترل‌کننده مبتنی بر LSTM است. در این شبکه، وزن‌های شبکه با استفاده از حافظه خارجی NTM ذخیره و بازیافت می‌شوند. این وزن‌ها در هر چرخه به‌روزرسانی با استفاده از وزن‌های ذخیره شده در حافظه محاسبه می‌شوند. در بخش جریان اطلاعات DAerosol-NTM، عملکرد اصلی وجود دارد که با هم ارتباط دارند: ۱- پیش‌پردازش داده‌های ورودی: در این عملکرد، داده‌های ورودی پیش‌پردازش می‌شوند تا برای شبکه مناسب شوند. ۲-۱ تنظیم پارامترهای اولیه شبکه: پس از پیش‌پردازش داده‌های ورودی، در این عملکرد، پارامترهای اولیه شبکه تنظیم می‌شوند تا شبکه آماده آموزش شود. ۴- خواندن و نوشتن از حافظه: در این عملکرد، شبکه با استفاده از حافظه خارجی NTM و با استفاده از هد خواندن و نوشتن، وزن‌ها را از حافظه خوانده و تنظیم می‌کند. سپس با شروع آموزش شبکه با داده‌های جدید، خروجی شبکه تولید می‌شود و خطای شبکه برای هر ورودی محاسبه می‌شود. ۵- محاسبه معیارهای عملکرد: در این عملکرد، دقت، صحت، MAPE و RMSE برای پیش‌بینی داده‌های آزمایشی و بهترین زمان قبل و بعد از رویداد آتروسل (TIBAAE) محاسبه می‌شود.

طراحی مدل (Deep Aerosol – Generative Adversarial Networks - Neural Turing Machines)

DAerosol.GAN.NTM برای ترمیم داده‌های خراب به منظور بهبود در مدل سازی، بهبود قابل توجهی نسبت به روش‌های پیشین دارد. در این مدل، بعد از تنظیم پارامترهای اولیه در عملکرد 2-2، وظیفه ترمیم مبتنی بر شبکه‌های عصبی داده‌های خراب در عملکرد 3 جمع‌آوری می‌شوند و سپس به عملکرد 4 منتقل می‌شوند [61]. نتایج تجربی نشان می‌دهند که این مدل در مقایسه با رویکردهای پیشین در ترمیم داده‌های خراب، عملکرد بهتری دارد. علاوه بر این، طراحی مدل DAerosol.GAN.NTM بر اساس شبکه‌های GAN است که قادر به تولید داده‌های جدید و مصنوعی هستند. این داده‌های جدید سپس به عنوان بخشی از داده‌های آموزشی برای مدل استفاده می‌شوند تا بهبود در مدل سازی داشته باشیم. به عبارت دیگر، شبکه GAN به عنوان یک سازنده داده‌های جدید عمل می‌کند که به ما امکان می‌دهد داده‌های خراب را با داده‌های جدید جایگزین کنیم.

با توجه به اینکه هر ترکیبی از مدل نمی‌تواند به طور مطلق به مسئله ترمیم داده‌های خراب پاسخ دهد، طراحی مدلی که توانایی کنار هم قراردادن این شبکه‌ها را داشته باشد، به عنوان نوآوری اصلی این چارچوب مطرح است. این مدل توانایی استفاده موازی از شبکه‌ها را با هماهنگی جریان اطلاعات بین آن‌ها به ما می‌دهد. به طور کلی، مدل DAerosol.GAN.NTM با استفاده از شبکه GAN و عملکردهای مختلف، ترمیم داده‌های خراب را بهبود می‌بخشد و نسبت به روش‌های پیشین پیشرفت قابل توجهی را نشان می‌دهد.

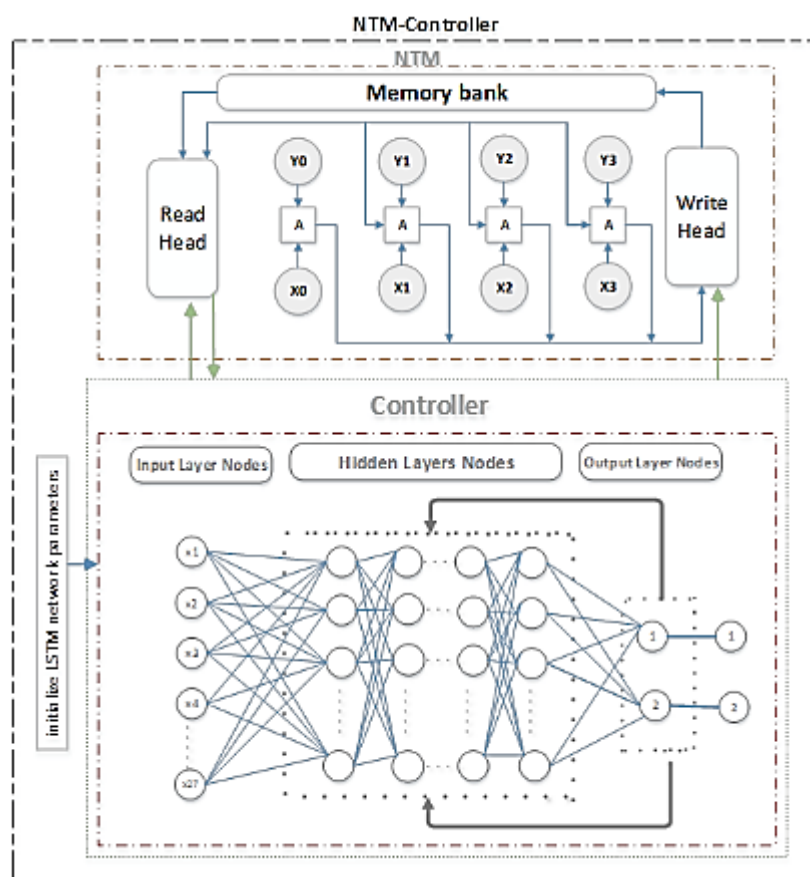
استفاده از شبکه عصبی بازگشتی LSTM در کنترل‌کننده شبکه NTM، برای تجزیه و تحلیل صحیح و دقیق داده‌های سری زمانی استفاده شده است. هر مرحله آموزشی از حافظه خارجی NTM برای ذخیره و بازیابی وزن شبکه استفاده می‌کند.



شکل 1-3: استفاده از یادگیری عمیق و ماشین تورینگ عصبی به همراه شبکه GAN در چارچوب پیش‌بینی آئروسل

شکل 2-3 تفاوت بین شبکه عصبی عمیق LSTM و شبکه DAerosol-NTM توسعه داده شده در این مطالعه را نشان می‌دهد که در استفاده از NTM برای برقراری ارتباط معنایی در طول تمرین مختلف قرار دارد. پس از آموزش شبکه در X_0 و تولید خروجی Y_0 ، وزن‌های شبکه DAerosol-NTM با استفاده از هد نوشتن در حافظه NTM

ذخیره می‌شوند. در زمان t_1 ، شبکه با استفاده از هد خواندن / نوشتن وزن‌های خود را از حافظه بازیابی می‌کند و وزن‌های جدید برای آموزش بیشتر تولید می‌شوند. این فرآیند تکراری تا زمانی که خروجی شبکه به هدف با دقت بالایی نزدیک شود، ادامه می‌یابد. وزن‌های نرمال شده به دست آمده از تکرارهای آموزش قبلی، بر فرآیند آموزش کنونی تأثیر می‌گذارند. علاوه بر این، فرض شده است که یک شبکه عصبی عمیق شامل چندین لایه پنهان با حافظه بیرونی بلندمدت است. کنترل کننده به طور مؤثر این حافظه بلندمدت را مدیریت می‌کند و از دو هد برای عملیات خواندن و نوشتن استفاده می‌کند.



شکل 2-3: ساختار تمرین (DAerosol-NTM)

3-2- عملکرد 1: پیش‌پردازش داده‌ها

شکل 3-3 شامل مراحل پیش‌پردازش داده‌ها در تابع 1 است. پس از درک محیط و داده‌ها، مرحله پاک‌سازی داده‌ها اطلاعات از دست رفته را با اطلاعات صحیح جایگزین می‌کند. داده‌های نویز نیز بر اساس همسایه‌ها صاف می‌شوند و سپس داده‌های پرت شناسایی و از داده‌ها حذف می‌شوند. سپس داده‌های پراکنده از منابع مختلف باهم ترکیب می‌شوند. مرحله تبدیل داده از تکنیک‌های نرمال‌سازی برای انتقال مقادیر به یک محدوده خاص استفاده می‌کند. معادله 3-1 مقادیر را به یک محدوده خاص نشان می‌دهد. این مطالعه همچنین از کارشناسان فنی برای نظارت بر انتخاب و تخصیص ویژگی‌های با اولویت بالا و تأثیر آن‌ها بر پارامترهای هواشناسی در آلودگی هوا استفاده می‌کند.

اعتبار سنجی با استفاده از تکنیک‌های تحلیل همبستگی و حساسیت بررسی می‌شود. در نهایت، داده‌ها با استفاده از تکنیک فشرده‌سازی میانگین فشرده می‌شوند تا پردازش شوند. بخش 4.1 پیش‌پردازش داده‌ها را نیز با جزئیات بیشتری شرح می‌دهد.

$$X_n = (0.9(X - X_{\min}) / (X_{\max} - X_{\min})) + 0.1 \quad (3-1)$$

Function 1: Data preprocessing

Input = Pollution data & Meteorological dataset

Output = Dataset

Description: The combination of two Pollution data & Meteorological data to achieve a single dataset

1. Data cleaning for each one of the datasets (Pollution data & Meteorological data)
 2. Data integration (The combination of two pollution data & Meteorological data)
 3. Data transformation (using Normalization techniques) with (1-3)
 4. Selection of compelling features (using the correlation analysis technique)
 5. Data dimension reduction (using compression techniques)
-

شکل 3-3: پیش‌پردازش مجموعه داده با استفاده از روش‌های DAerosol.GAN.NTM و DAerosol.NTM

3-3- عملکرد 1-2: راه‌اندازی پارامترهای شبکه LSTM

شکل 3-4 تابع مقداردهی اولیه را نشان می‌دهد که مقادیر اولیه شبکه را تنظیم می‌کند. وزن نورون‌ها به‌طور تصادفی اختصاص داده می‌شود. برخی دیگر مانند تعداد نورون‌ها و لایه‌ها با آزمون و خطا ارزیابی می‌شوند. علاوه بر این، نورون‌های لایه ورودی و خروجی شبکه باید به ترتیب متناسب با طول داده‌های ورودی و تعداد کلاس‌هایی باشند که شبکه قرار است داده‌ها را با آن‌ها دسته‌بندی کند.

Function 1-2: Initialize LSTM network parameters

Input: number of layers, number of input nodes, number of hidden nodes, number of output node

Output: The LSTM topology

1. Number of Layers=L
 2. Number of input nodes=Length of sequence vector
 3. Number of hidden nodes=H
 4. Number of output node=number of classes
-

شکل 3-4: شبه کد برای مقداردهی اولیه روش‌های DAerosol.GAN.NTM و DAerosol.NTM

3-4- عملکرد 2-2: تنظیم پارامترهای GAN

شکل 3-5 تابع مقداردهی اولیه را نشان می‌دهد که مقادیر اولیه شبکه را تنظیم می‌کند. برخی از مقادیر، مانند وزن نورون‌ها، به‌طور تصادفی اختصاص داده می‌شوند. از دو بخش شبکه‌های عصبی ژنراتور و تشخیص‌دهنده تشکیل شده است. تعداد نورون‌ها و لایه‌ها با آزمون و خطا ارزیابی شد و بهترین نتایج آزمون به‌عنوان خروجی در نظر گرفته شد. علاوه بر این، تعداد نورون‌ها در لایه ورودی برابر با طول ورودی است. مشکل این است که هیچ متغیر

خروجی وجود ندارد و هدف یافتن الگوهای جالب در داده‌ها است. این مدل‌های اصلاح‌نشده معمولاً به‌عنوان فرم یادگیری بدون نظارت شناخته می‌شوند.

Function 2-2: Initializing the GAN network parameters

Input = number of layers, number of input nodes, number of the hidden node

Output = Topology of GAN (set the heads)

- 1 Number of Layers = L
 - 2 Number of input nodes = length of sequence vector
 - 3 Number of hidden nodes = H
-

شکل 3-5: شبه کد آماده‌سازی شبکه عصبی GAN برای روش DAerosol.GAN.NTM

3-5- عملکرد 3: آموزش شبکه متخاصم مولد (GAN)

شکل 3-6 نشان می‌دهد که در دو فاز ژنراتور (G) و دیسکریمیناتور (D) آموزش داده می‌شود. یک الگوریتم پس انتشار خطا و یک خطای شبکه متمایز (تابع هزینه) در آموزش استفاده می‌شود. هدف از آموزش این مدل‌ها، تولید داده‌های مصنوعی نزدیک به داده‌های واقعی است. روش‌های مختلفی برای تکمیل داده‌های ناقص مانند میانگین، KNN-based و MICE بررسی شده‌اند. با انجام چندین شبیه‌سازی، محققین نتیجه گرفته‌اند که روش GAN برای تکمیل داده‌های ناقص بهترین عملکرد را دارد [61].

فریمورک GAN بر پایه یک بازی min-max دو-بازیکنه است که در آن ژنراتور (G) و دیسکریمیناتور (D) به صورت تکراری آموزش داده می‌شوند تا عملکرد خود در تولید داده‌های مصنوعی شبیه به داده‌های واقعی را بهبود بخشند. هدف دیسکریمیناتور این است که بین داده‌های واقعی و داده‌های تولیدی تفاوت را به درستی تشخیص دهد، در حالی که ژنراتور سعی می‌کند داده‌هایی تولید کند که می‌توانند دیسکریمیناتور را فریب دهند. برای دستیابی به این هدف، فریمورک GAN از یک فرمولاسیون ریاضی استفاده می‌کند که شامل بهینه‌سازی min-max است. دیسکریمیناتور و ژنراتور به عنوان توابعی از ورودی‌های خود مدل می‌شوند، به طوری که ژنراتور نمونه‌های تصادفی را به عنوان ورودی دریافت می‌کند و دیسکریمیناتور هم از داده‌های واقعی و داده‌های تولیدی از ژنراتور به عنوان ورودی استفاده می‌کند.

هدف دیسکریمیناتور این است که داده‌های واقعی را به عنوان "1" و داده‌های تولیدی را به عنوان "0" به درستی برچسب‌گذاری کند. در حالی که ژنراتور سعی می‌کند داده‌هایی تولید کند که می‌توانند دیسکریمیناتور را به گمراهی بیندازند و به عنوان "1" برچسب‌گذاری شوند که در آن \hat{X} و X به ترتیب احتمال پیش‌بینی برچسب X و برچسب واقعی هستند، معادله 2-3. بنابراین، تابع اتلاف برای دیسکریمیناتور را می‌توان مطابق با معادله 3-3 در نظر گرفت.

هدف ژنراتور، تولید نمونه‌هایی مشابه D_{pxq} یعنی D_{pGpzqq} با برچسب یک است. این به شکل ریاضی در معادله 3-4 داده شده است. این کار با کمینه کردن تابع خطای ژنراتور و بیشینه کردن تابع خطای دیسکریمیناتور، با استفاده از تابع خطای $binary\ cross-entropy$ انجام می‌شود.

D سعی می‌کند میانگین لگاریتم احتمال نمونه‌های اصلی و لگاریتم احتمال معکوس نمونه‌های جعلی را بیشینه کند. در حالی که G سعی می‌کند میانگین لگاریتم احتمال معکوس را کمینه کند. این بازی دو نفره $min-max$ با تابع اتلاف طبق معادله 3-5 ادامه می‌یابد.

به عبارت دیگر، فریمورک GAN با آموزش دادن دیسکریمیناتور به توزیع داده‌های واقعی، توزیع داده‌های واقعی را یاد می‌گیرد، و با آموزش دادن ژنراتور به تولید داده‌هایی که با این توزیع هم‌خوانی دارند، داده‌های مصنوعی تولید می‌شوند [61].

(برای مشاهده ساختار شبکه گن به بخش 2-2-4 مبانی نظری مراجعه شود).

$$L(x^{\wedge}, x) = [y * \log(x^{\wedge}) + (1 - x) * \log(1 - x^{\wedge})] \quad (3-2)$$

$$L_D = \log(D(x), 1) + \log(D(G(z)), 0) \quad (3-3)$$

$$L_G = \log(D(G(z)), 1) \quad (3-4)$$

$$\min_G - \max_D V(G; D) = E_{R \sim P_{data}(X)} [\log(D(x))] + E_{Z \sim P_Z(Z)} [\log(1 - D(G(z)))] \quad (3-5)$$

Function 3: Algorithm "GAN" network training

Input = part of (10%) the preprocessing data and their reconstruction

Output = Accuracy=50%

- 1 Discriminator network training,
 - 2 Selecting some random educational data randomly (X),
 - 3 Creating several random noise vectors and producing several counterfeit samples ($G(z)=X^*$),
 - 4 Error calculation (X, X^*) to train discriminator network weights and minimize discriminator network errors (At this stage, the weights of the generating network, are constant)
 - 5 Generator network training (the discriminator's training ratio of 5 to 1 compared to the generator),
 - 6 Creating several random noise vectors and producing several counterfeit samples ($G(z)=X^*$),
 - 7 Error calculation (X^*) to train generator network weights and maximize discriminator network errors,
 - 8 The weights of the discriminator grid are considered constant,
 - 9 Achieving an optimal solution (Nash Equilibrium) in a GAN network that, at best, can detect 50/50.
-

شکل 3-6: شبه کد برای پیاده‌سازی GAN

3-6-عملکرد 4: آموزش شبکه عصبی برای روش‌های DAerosol.NTM و DAerosol.GAN.NTM

هدف از این تابع آموزش شبکه است که در شکل 3-7 نشان داده شده است. در ابتدا این تابع وزن آخرین مرحله را دریافت کرده و شبکه را راه اندازی می کند. همچنین داده های ورودی را به صورت برداری دریافت می کند و خروجی صحیح را تولید می کند. سپس خروجی شبکه را با نتیجه مورد نظر مقایسه می کند تا خطای شبکه مطابق با معادله 3-6 و میانگین درصد مطلق خطا از طریق معادله 3-7 محاسبه شود. سپس وزن شبکه بر این اساس به روز می شود.

Function 4: DAerosol.NTM && DAerosol.GAN.NTM algorithm for network training

Input = Dataset

Output = Accuracy

1. Call Function 1 (data preprocessing)
 2. Initializing GAN network parameters
 3. Call Function 3 (GAN network training)
 4. "Training data" including both "actual data" and unsupervised data generated by the GAN network
 5. Initializing LSTM network parameters;
 6. Repeating the procedure (for each training input)
 7. Decision-making on forgetting gates with Equation (4-2);
 8. Training the LSTM network by using NTM external memory
 9. }
 10. If (the NTM external memory is not empty)
 11. Using read-head for reading previous weights from external memory with Equations (8-2,9-2);
 12. else
 13. Set weights of the network randomly.
 14. Decision-making for output gates using with Equation (5-2);
 15. adjust the output of the neural network training function (value of weights, row of sequence vectors);
 16. Checking the error with Root-Mean-Square deviation and Mean Absolute Percentage Error via with Equations (6-3,7-3);
 17. Using write-head for writing best weights to external Memory with Equations (10-2,11-2);
 18. }
 19. Ending loop
 20. return (Train accuracy; Train precision) with Equations (8-3,9-3);
-

شکل 3-7: شبه کد اجرای ترکیب شبکه GAN با NTM با کنترل کننده شبکه عصبی عمیق LSTM

3-7- عملکرد 5: دقت، صحت، RMSE، MAPE، و محاسبه TIBAAE

این بخش پارامترهای اساسی در ارزیابی پیش بینی از جمله RMSE، MAPE، دقت، صحت و پارامتر جدید TIBAE را معرفی می کند. RMSE ریشه میانگین مربعات خطا (RMSE) است که بر اساس خروجی شناخته شده و مقادیر خروجی ماشین در طول آموزش محاسبه می شود و بر اساس معادله 3-6 بر اساس درصد بیان می شود. MAPE میانگین درصد مطلق خطا (MAPE) است که اندازه گیری دقت پیش بینی یک روش پیش بینی در آمار که بر اساس معادله 3-7 بر اساس درصد بیان می شود. معمولاً می گوید دقت نسبتی است که به عنوان درصد پیش بینی

صحیح برای داده‌های آزمون تعریف می‌شود که می‌توان با تقسیم تعداد پیش‌بینی‌های دقیق بر کل پیش‌بینی‌ها مطابق با معادله 3-8 آن را محاسبه کرد. صحت به‌عنوان کسری از نمونه‌های مرتبط در میان کل پیش‌بینی‌شده در یک کلاس خاص تعریف می‌شود. خروجی ماشین با خروجی شناخته‌شده برای ارزیابی صحت شبکه مطابق با معادله 3-9 مقایسه می‌شود.


$$RMSE = ((\frac{1}{n} \times \sum_{i=1}^{lengthofinput} (known.Output[i] - Machine.Output[i])^2)^{1/2} \quad (3-6)$$

$$MAPE = ((\frac{1}{n} \times \sum_{i=1}^{lengthofinput} (\frac{1}{Known.Output[i]} \times (Known.Output[i] - Machine.Output[i]))) \times 100) \quad (3-7)$$

$$Accuracy = 1 - ((\frac{1}{n} \times \sum_{i=1}^{lengthofinput} (known.Output[i] - Machine.Output[i])^2)^{1/2} \quad (3-8)$$

$$Precision = 1 - ((\frac{1}{n} \times \sum_{i=1}^{lengthofinput} (\frac{1}{Known.Output[i]} \times (Known.Output[i] - Machine.Output[i]))) \times 100) \quad (3-9)$$

شکل 3-8 پارامتر TIBAAE را معرفی می‌کند که مدت‌زمان قبل از رویداد آئروسول را توصیف می‌کند. روزهای بعد چقدر قابل پیش‌بینی است؟ به‌عنوان مثال، با داشتن داده‌های یک روز قبل از رویداد آئروسول که با آن دقت رویداد آئروسول در یک/دو/سه، چهار، پنج و غیره روز آینده اتفاق می‌افتد. یا با داشتن داده‌های دو روز قبل از رویداد آئروسول که با چه دقتی رویداد آئروسول در یک/دو/سه/چهار/پنج و غیره روز آینده اتفاق می‌افتد.



شکل 3-8: داده‌های یک روز تا پنج روز قبل از رویداد، احتمال چهار روز بعد، پنج روز بعد وجود دارد

شکل 3-9 رویکرد محاسبه آموزش، اعتبار سنجی و دقت پیش‌بینی آزمون، صحت، RMSE، MAPE و TIBAAE را نشان می‌دهد. وقوع ریزگردها یک روز بعد، دو روز بعد، سه روز بعد،

Function 5: Validation and Test Evaluation

Input = Validation and Test dataset

Output = Classification accuracy, precision, RMSE, MAPE, TIBAAE;

1 for each testing or validation input, do the following:

2 set the testing or validation dataset as an input to the trained LSTM network;

3 get LSTM network output;

4 end for

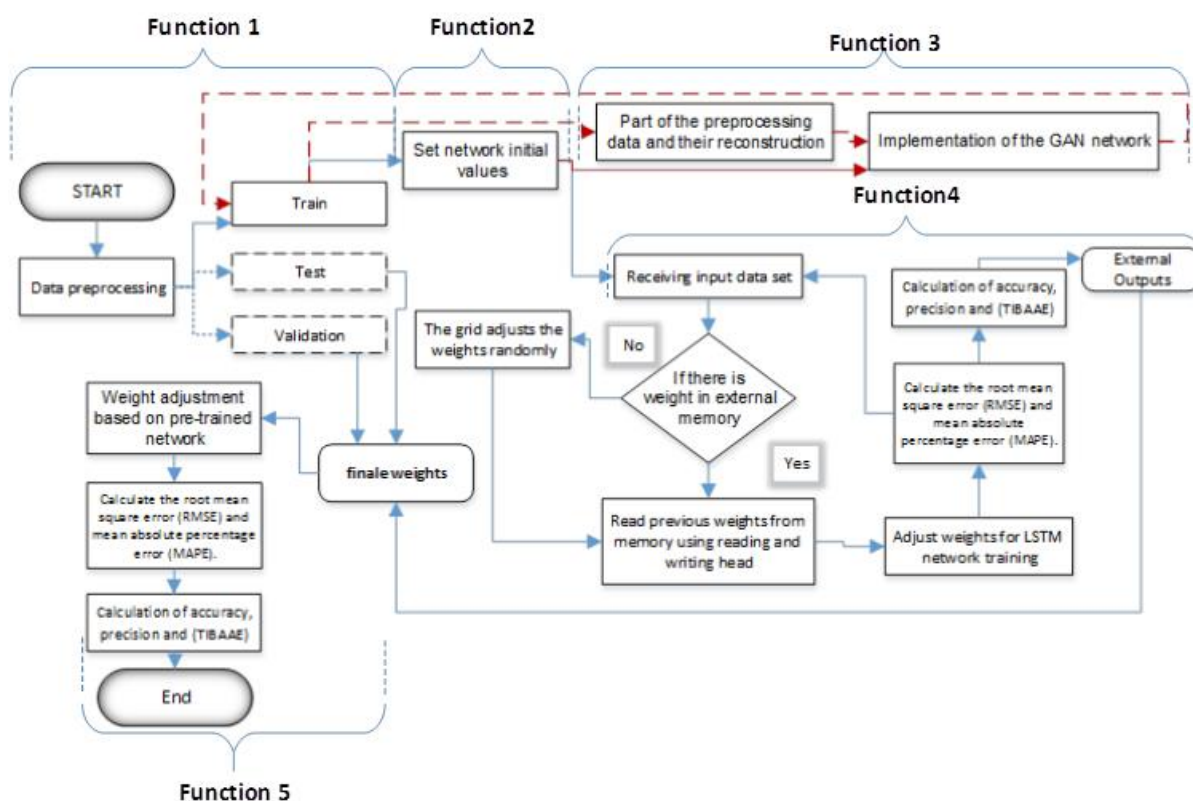
5 Calculate accuracy, precision, RMSE, MAPE, and TIBAAE;

6 Return (accuracy, precision, RMSE, MAPE, TIBAAE);

شکل 3-9: شبه کد محاسبه دقت، صحت، RMSE، MAPE و TIBAAE مورد استفاده در DAerosol.NTM و

DAerosol.GAN.NTM

8-3- جریان اطلاعات در چارچوب پیشنهادی



شکل 3-10: نمودار جریان در چارچوب پیشنهادی

دو الگوریتم آموزش شبکه DAerosol.NTM و DAerosol.GAN.NTM در شبه کد بالا در تابع 4 و شکل

7-3 بیان شده است. تنها قسمت متمایز آن DAerosol.GAN.NTM با روش DAerosol.NTM (خطوط 2 تا، شبه

کد 4) است. شبکه‌ای با ساختار مشابه الگوریتم DAerosol.NTM در کنار شبکه GAN و LSTM استفاده شده

است. در الگوریتم DAerosol.GAN.NTM، داده‌های ورودی ابتدا پیش‌پردازش شده و با استفاده از تابع 1 برای تناسب با شبکه عصبی (خط 1، شبه کد) اصلاح می‌شوند. پس از آماده‌سازی داده‌ها، تابع 2-2 (خط 2، شبه کد) باید پارامترهای اولیه شبکه GAN را تنظیم کند. ابتدا فرض می‌کنیم که 10/100 داده گم‌شده یا خراب است و به‌عنوان ورودی وارد شبکه GAN می‌شویم (خط 3، شبه کد). داده‌های آموزشی، از جمله داده‌های واقعی و بدون نظارت تولیدشده توسط شبکه GAN، ادغام می‌شوند (خط 4، شبه کد). سپس برای اجرای شبکه NTM، پارامترهای اصلی شبکه LSTM باید با استفاده از تابع 1-2 (خط 5، شبه کد) برای آموزش شبکه (شبه کد خط 8) تنظیم شوند. این الگوریتم با توجه به ساختار شبکه، وزن‌های شبکه را از روی حافظه خارجی توسط هد خوانده‌شده خوانده و در شبکه تنظیم می‌کند، اما باید بررسی شود که آیا وزنی در حافظه وجود دارد یا خیر. از همان وزن‌های تصادفی استفاده می‌شود. در غیر این صورت، وزن‌ها از حافظه خارجی خوانده می‌شوند و در شبکه (شبه کد خطوط 10 تا 13) تنظیم می‌شوند. زمان آموزش شبکه LSTM با اعمال تابع 4 (شبه کد خطوط 14 و 15) و محاسبه خطای شبکه (شبه کد خط 16) است. در نهایت دقت عملیات شبکه با استفاده از تابع 5 (شبه کد خط 20) به دست می‌آید.

3-9- مطالعه موردی

در روش پیشنهادی DAerosol.GAN.NTM، از دو بخش GAN و DAerosol.NTM تشکیل شده است. با استفاده از بخشی از مجموعه داده‌های اصلی در این تحقیق به عنوان نمونه داده‌های واقعی بررسی شده است. در شبکه GAN، شبکه دارای یک لایه پنهان و یک لایه خروجی است که خروجی داده در شبکه GAN است. در بخش تفکیک‌کننده، شبکه شامل یک لایه پنهان و یک لایه خروجی است که در لایه خروجی تعیین می‌شود که داده واقعی یا مصنوعی است. هر یک از این دو بخش، Generator و Discriminator، یک شبکه عصبی هستند. روش "DAerosol.NTM" نشان می‌دهد که چگونه شبکه عصبی کنترل‌کننده NTM که یک شبکه LSTM است، می‌تواند داده‌های آلودگی هوا را دسته‌بندی کند. تعداد تکرارها در این تحقیق 4000 دور است. همچنین فرض شده است که یک شبکه عصبی عمیق با چندین لایه پنهان و با حافظه بیرونی بلندمدت است. کنترل‌کننده، این حافظه بلندمدت را مدیریت می‌کند و همچنین دو هد برای خواندن و نوشتن استفاده می‌شود. تکرار متقابل تکنیکی است که در آموزش شبکه عصبی بیشتر به کار می‌رود.

در ادامه نحوه‌ی پیاده‌سازی مطالعه موردی مطابق با فلوچارت شکل 10-3 به صورت مرحله‌به‌مرحله بیان خواهد شد.

-مرحله 1: فرآیند آماده‌سازی داده‌ها

-مرحله 2: تنظیم پارامترهای شبکه GAN

-مرحله 3: آموزش شبکه GAN مطابق با عملکرد 3.

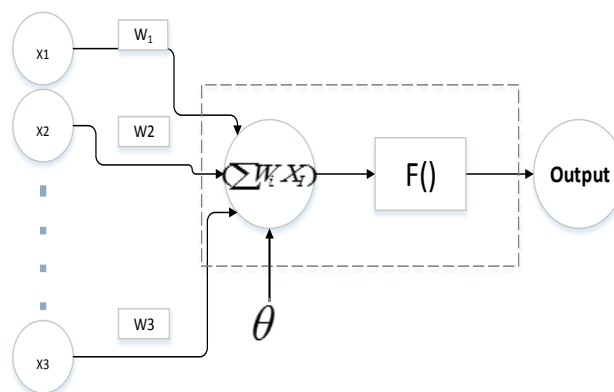
-مرحله 4: آماده‌سازی داده‌های آموزشی، از جمله داده‌های واقعی و بدون نظارت تولیدشده توسط شبکه GAN.

-مرحله 5: خواندن داده‌های آموزشی از ورودی خارجی

- مرحله 6: خواندن وزن‌های قبلی ذخیره‌شده در حافظه NTM به شرط خالی نبودن حافظه خارجی (2-8 و 2-9).
نکته: این مرحله در روش شبکه عصبی عمیق LSTM بدون حافظه خارجی رخ نمی‌دهد.
- مرحله 7: ادغام وضعیت شبکه قبلی، وزن‌های ذخیره‌شده قبلی و ورودی جدید
[آخرین وزن از حافظه + داده ورودی جدید (سیگنال) + آخرین وضعیت شبکه] = $Input_{t+1}$
- مرحله 8: به‌روزرسانی وزن شبکه.
- مرحله 9: شبکه آموزش را با داده‌های جدید برای تولید خروجی از طریق معادله 3-10 آغاز می‌کند.

$$Y = f\left(\sum_{i=1}^N W_i X_i\right) \quad (3-10)$$

ساختار آموزش شبکه در شکل 3-11 نشان داده‌شده است [41]:



شکل 3-11: ساختار آموزش شبکه [41]

- مرحله 10: محاسبه خطا با انحراف ریشه میانگین مربعات خطا و میانگین درصد مطلق خطا از طریق (معادله 3-6، معادله 3-7).
- مرحله 11: وزن‌ها را در حافظه خارجی ذخیره کنید، زیرا این وزن‌ها از طریق هد نوشتن به حافظه منتقل می‌شوند.
نکته: این مرحله در روش شبکه عصبی عمیق LSTM بدون حافظه خارجی رخ نمی‌دهد.
- مرحله 12: رفتن به مرحله 6.
- مرحله 13: محاسبه خروجی شبکه از شبکه آموزش‌دیده برای هر داده.
- مرحله 14: محاسبه دقت و صحت از طریق خروجی شبکه و خروجی موردنظر (هدف).

فصل چهارم

ارزیابی و نتایج روش پیشنهادی

4-1- مقدمه

در این مطالعه، پس از جمع‌آوری داده‌های آلودگی هوا و هواشناسی، به دلیل قابل پیش‌بینی بودن شاخص‌های هواشناسی، ابتدا منابع علمی و تحقیقات قبلی مرور شد و با توجه به نظر متخصصان در حوزه هواشناسی و کنترل کیفیت هوا، عوامل مؤثر در پیش‌بینی آلودگی هوا استخراج شده است، پس از پیش‌پردازش داده‌ها به طراحی و راه‌اندازی آزمایش‌های مربوطه پرداخته شده است.

4-2- مجموعه داده تجربی، محیط و طراحی

4-2-1- مجموعه داده

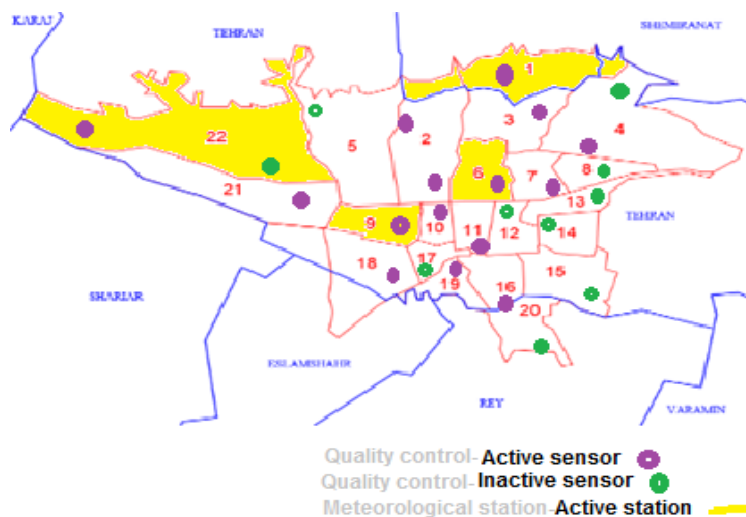
به منظور انجام داده‌کاوی از متدولوژی [62] CRISP-DM در مراحل پیش‌پردازش داده‌ها استفاده می‌شود. این روش یک روش جامع برای پردازش داده‌ها است و چرخه عمر پیش‌پردازش داده‌ها را به شش مرحله تقسیم می‌کند، همان‌طور که در شکل 4-1 نشان داده شده است.



شکل 4-1: مراحل پیش پردازش داده‌ها

4-2-1-1-درک محیط

با توجه به فقدان داده‌های استاندارد در مورد اقلیم، آلودگی و شرایط مختلف اقلیمی و جغرافیایی، پژوهش حاضر تنها بر پارامترهای اندازه‌گیری شده با استفاده از داده‌های شهر تهران در ایران تمرکز دارد. طبق برآورد سال 2018 سازمان ملل، تهران سی و هشتمین شهر پرجمعیت جهان، پرجمعیت‌ترین شهر غرب آسیا، دومین کلان‌شهر پرجمعیت خاورمیانه و پرجمعیت‌ترین شهر و پایتخت ایران است [63][64]. طبق رتبه‌بندی جهانی کیفیت هوا، تهران معمولاً در بین ده شهر آلوده جهان قرار دارد [65]. تهران پایتخت در دامنه جنوبی رشته‌کوه البرز، بین دودره کوهستانی و کویری با حدود 730 کیلومترمربع واقع شده است. شهرداری تهران برای مدیریت بهتر شهر، شهر را به ۲۲ منطقه شهرداری و ۱۲۲ منطقه شهری تقسیم کرده است. در بخش وزارت کشور، شهر تهران در مرکز استان تهران قرار دارد. از شمال با شهرستان‌های کرج و شمیرانات، از شرق به شهرستان دماوند، از جنوب به شهرستان‌های ورامین، ری و اسلامشهر و از غرب با شهرستان‌های شهریار و کرج همسایه است [66].



شکل 4-2: مناطق شهری تهران [66]

4-2-1-2-درک داده‌ها

نمای جزئی از مجموعه داده به گفته کارشناسان حوزه هواشناسی و کنترل کیفیت هوا، عوامل مؤثر در پیش‌بینی آلودگی هوا شرایط آسمان مانند پوشش، نوع، لایه و ارتفاع ابرها، دید افقی، فشار، جهت و سرعت باد، رطوبت نسبی،

دما، مونوکسید کربن، ازن، دی اکسید نیتروژن و دی اکسید گوگرد [67]. تجزیه و تحلیل داده ها نشان داد که $PM_{2.5}$ و PM_{10} دارای بالاترین AQI در بین سایر آلاینده ها هستند [3]. جدول 1-4 بخش کوچکی از مجموعه داده را نشان می دهد و جدول 2-4 محدوده پارامترهای جمع آوری شده را نشان می دهد [68]. علاوه بر این، داده های بین (0 و 1) نرمال شده است [42].

جدول 1-4: نمونه کوچکی از مجموعه داده های مورد استفاده در آزمایش ها

Air quality index	Solid particles with a diameter less than or equal to 2.5 mm	Solid particles with a diameter less than or equal to 10 mm	Sulfur dioxide	Nitrogen dioxide	Carbon monoxide	Ozone	QNH pressure	steam pressure	Wet temperature	Relative humidity	The base height of the second cloud layer	The second type of cloud layer	The amount of coverage of the second layer of the cloud	The base height of the first cloud layer	Type the first layer of the cloud	The amount of coverage of the first layer of the cloud	Medium layer cloud	Bottom layer cloud	The amount of cloud is the lowest layer	Station pressure	Sea level pressure	Dew point	Temperature	wind speed	wind direction	Cloudiness	Horizontal view	The lowest visible cloud	
AQI	PM 2.5	PM 10	SO2	NO2	CO	O3	pqn h	ew	twet	u	hl2	tl2	nl2	hl1	tl1	nl1	cm	cl	nh	p0	p	td	t	ff	dd	n	vv	h	DATE
0.49	0.71	0.54	1	1	1	1	0.94	0.13	0.12	0.12	0.38	0.1	0.1	0.44	0.11	0.1	0.1	0.1	0.1	0.3	0.15	0.1	0.1	0.1	0.12	0.1	0.46	0.45	43589.25
0.22	0.15	0.22	0.13	0.18	0.1	0.1	0.1	0.1	0.1	0.1	0.16	0.1	0.1	0.33	0.1	0.1	0.1	0.1	0.1	1	1	1	1	1	1	1	0.31	0.41	43589.29
0.19	0.14	0.19	0.1	0.18	0.1	0.1	0.11	0.13	0.12	0.1	0.16	0.1	0.1	0.33	0.1	0.1	0.1	0.1	0.1	1	1	1	1	1	1	1	0.31	0.41	43589.33
0.18	0.14	0.17	0.1	0.16	0.1	0.1	0.93	0.13	0.12	0.13	0.19	0.1	0.1	0.4	0.1	0.1	0.1	0.1	0.3	0.14	0.1	1	0.1	0.1	0.14	0.55	0.45	0.31	43589.38
0.155	0.13	0.17	0.1	0.14	0.1	0.1	0.15	0.1	0.1	0.1	0.16	0.1	0.1	0.33	0.1	0.1	0.1	0.1	0.1	1	1	1	1	1	1	1	0.31	0.41	43589.42
0.49	0.71	0.54	1	1	1	1	0.95	0.13	0.12	0.17	0.19	0.1	0.1	0.4	0.1	0.1	0.1	0.1	0.3	0.15	0.1	0.1	0.1	0.1	0.21	0.32	0.45	0.32	43589.5
0.49	0.71	0.54	1	1	1	1	0.94	0.13	0.12	0.15	0.19	0.1	0.1	0.4	0.1	0.1	0.1	0.1	0.3	0.15	0.1	0.1	0.1	0.1	0.12	0.55	0.45	0.55	43589.63

جدول 2-4: محدوده متغیرهای آلودگی هوا

توضیحات پارامتر	مقیاس	پارامترها	مینیموم	ماکزیموم	میانگین	انحراف معیار
پایین ترین ابر قابل مشاهده	متر	h	50	2500	1275	0.039982348
نمای افقی	درجه	W	100	20000	10050	0.103439528
ابری	درجه	n	2	3172	1587	0.409721572
جهت باد	درجه	dd	10	2428.631	1219.3155	0.378808213
سرعت باد	درجه	ff	1	1943.608	972.304	0.409732491
درجه حرارت	درجه	t	-9.8	1625.968	808.083892	0.402200747
نقطه شبنم	درجه	td	-17.7	1394.558	688.4290375	0.403780867
فشار سطح دریا	kg/cm2	p	989.1679	1346.518	1167.843169	0.385220176
فشار ایستگاه	درجه	p0	761.6	1293.615	1027.607462	0.325946986
مقدار ابر کمترین لایه است	درجه	nh	761.6	1164.305	962.9526135	0.409606825
ابر لایه پایین	درجه	cl	1	1058.625	529.8126735	0.409200627
ابر لایه متوسط	درجه	cm	1	970.6095	485.8047451	0.408983303
میزان پوشش لایه اول ابر	درجه	nl1	1	895.9941	448.4970519	0.409823982
اولین لایه ابر	کیلومتر	tl1	1	832.4384	416.7191842	0.407124661
ارتفاع پایه اولین لایه ابر	متر	hl1	90	3000	1545	0.038858835

توضیحات پارامتر	مقیاس	پارامترها	مینیموم	ماکزیموم	میانگین	انحراف معیار
میزان پوشش لایه دوم ابر	میلی بار	nl2	1	794.466	397.7329872	0.408709075
نوع دوم لایه ابری	کیلومتر	tl2	2	747.9518	374.9758996	0.408854975
ارتفاع پایه لایه ابر دوم	متر	hl2	240	9000	4620	0.090861262
رطوبت نسبی	درجه سلسیوس	u	5	790.8312	397.9156215	0.388401697
دمای مرطوب	درجه	twet	10.2	751.9397	370.8698612	0.399058489
فشار بخار	درجه	ew	-18.855	716.4769	348.8105916	0.395297729
QNH فشار	درجه	pqn	730.1052	1034.4	882.2525861	0.385501341
اوزن	ppb	O3	1	660.1358	330.5679177	0.400348919
مونوکسید کربن	ppm	CO	0.1	601.2626	300.6813031	0.408890217
دی اکسید نیتروژن	ppb	NO2	1	555.443	278.2215109	0.380254769
دی اکسید گوگرد	ppb	SO2	1	513.9647	257.4823508	0.404108716
شاخص کیفیت هوا	خوب، متوسط، ناسالم برای گروه های حساس، ناسالم، بسیار ناسالم، خطرناک	AQI	11	985	498	0.148421883
ذرات جامد با قطر کمتر یا مساوی 10 میلی متر	ug/m3	PM ₁₀	1	985	493	0.170669391
ذرات جامد با قطر کمتر یا مساوی 2.5 میلی متر	ug/m3	PM _{2.5}	1	675	338	0.257377418

4-2-1-3- پاک سازی داده ها

مرکز کنترل کیفیت شهر تهران با انتخاب 15 حسگر فعال (از بین 25 حسگر) مجموعه داده های آلودگی هوا را جمع آوری کرد. برخی از حسگرها به دلیل کمبود داده ها، خرابی و نگهداری حسگرها حذف شدند. در نهایت 15 حسگر آلودگی هوا و چهار ایستگاه هواشناسی در نقاط مختلف شهر تهران مورد بررسی قرار گرفت. مجموعه داده مناسب از 30 دسامبر 1999 تا 4 می 2019 متغیر است. این مجموعه داده شامل 882735 رکورد آلودگی هوا و 226330 رکورد هواشناسی (1109065 رکورد) است. چهار ایستگاه هواشناسی منتخب و پانزده حسگر فعال مناطق در معرض آلودگی هوا در جدول 3-4 آمده است.

جدول 3-4: نام نمونه‌های آماری منتخب

ردیف	مناطق در معرض آلودگی هوا	ایستگاه های هواشناسی
1	ناحیه 1 - اقدسیه	منطقه 1 - شمیرانات
2	منطقه 2 - شریف	منطقه 6 - ژئوفیزیک
3	منطقه 2 - شهرداری	منطقه 9 - مهرآباد
4	منطقه 3 - دروس	منطقه 22 - چیتگر
5	منطقه 4 - شهرداری	
6	منطقه 6 - تربیت مدرس	
7	منطقه 7 - ستاده بوهران	
8	منطقه 9 - شهرداری	
9	منطقه 10 - شهرداری	
10	منطقه 11 - شهرداری	
11	منطقه 16 - شهرداری	
12	منطقه 18 - شهرداری	
13	منطقه 19 - شهرداری	
14	منطقه 21 - شهرداری	
15	منطقه 22 - شهرداری	



4-2-1-3- آمادہ سازی داده‌ها

4-2-1-3-1- طبقه‌بندی و برآورد AQI نواحی مربوطه

این بخش میانگین شاخص کیفیت هوای AQI را برای همه دسته‌های در نظر گرفته شده برای کل شهر تهران بررسی می‌کند. نمودارهای شکل 3-4 تجزیه و تحلیل اولیه داده‌ها و همبستگی بین شاخص کیفیت هوا (AQI) و شاخص‌های هواشناسی را برای زمان‌ها و دوره‌های مختلف نشان می‌دهد. در نهایت، یک مدل یادگیری عمیق با داده‌های ساعتی برای پیش‌بینی آلودگی هوای شهر تهران به کار گرفته شد. از آنجایی که نرم‌افزار متلب فقط برای اعداد به راحتی اعمال می‌شود، داده‌های هر روز مانند جدول 4-4 کدگذاری می‌شود.



جدول 4-4: اعداد در نظر گرفته شده برای روزهای هفته در جدول داده‌ها

شماره	روزهای هفته
1	دوشنبه
2	سه شنبه
3	چهارشنبه
4	پنج شنبه
5	جمعه
6	شنبه
7	یک شنبه



الف: میانگین AQI برای 24 ساعت شبانه‌روز برای بیست سال متوالی

ب: میانگین AQI برای شش روز قبل از هر تعطیل رسمی برای بیست سال متوالی



ج: میانگین AQI برای شش روز قبل از هر آخر هفته برای بیست سال متوالی

د: میانگین AQI برای هر ماه از سال برای بیست سال متوالی

شکل 3-4: میانگین شاخص کیفیت هوای AQI کلیه دسته‌های مورد مطالعه در شهر تهران

شکل 3-4-الف: میانگین AQI را برای روزهای 24 ساعته برای بیست سال متوالی نشان می‌دهد که در آن بیست نمودار برای هرروز ترسیم‌شده است (درمجموع 140 نمودار). محور x ساعات روز (0، 3، 6، 9، 12، 15، 18، 21 و 24) و محور y میانگین شاخص AQI را نشان می‌دهد. همان‌طور که مشاهده می‌شود ساعت 21 آلوده‌ترین زمان شبانه‌روز است و کمترین آلودگی در شبانه‌روز در ساعت 2:30 بامداد وجود دارد و آلودگی از ظهر به بعد افزایش می‌یابد و در ساعت 21 به اوج خود می‌رسد.

شکل 3-4-ب: تمام تعطیلات رسمی و میانگین آلودگی روزانه را تا یک هفته قبل از تعطیلات نشان می‌دهد. با فرض حدود 27 روز تعطیل رسمی در سال، 540 نمودار برای 20 سال متوالی ترسیم شد ($540 = 27 \times 20$). (شکل 3-4-ب) تمام این نمودارها را خلاصه می‌کند. همان‌طور که مشاهده می‌شود، کاهش آلودگی از شش روز قبل از تعطیلات رسمی شروع می‌شود اما قبل از تعطیلات رسمی به حداقل مقدار خود می‌رسد. بااین‌حال، قبل از تعطیلات

رسمی، آلودگی دوباره بالا می‌رود. به عبارت دیگر جمعیت هوا درست قبل از تعطیلات رسمی کاهش می‌یابد اما در ساعات پایانی تعطیلات افزایش می‌یابد.

شکل 3-4-ج: میانگین سطح آلاینده‌ها را در تعطیلات آخر هفته در طول سال تا یک هفته قبل از تعطیلات نشان می‌دهد. با فرض 52 روز برای تعطیلات آخر هفته در سال، 1040 نمودار برای 20 سال متوالی ترسیم شد. این نمودارها در شکل (شکل 3-4-ج) خلاصه شده است. همان‌طور که مشاهده می‌شود در روزهای آخر هفته آلودگی کاهش نمی‌یابد، اما با شیب نسبتاً کمی افزایش می‌یابد.

شکل 3-4-د: میانگین آلودگی ماهانه را برای کل سال نشان می‌دهد. در یک سال 12 ماه وجود دارد، سپس 20 امتیاز در ماه برای 20 سال متوالی مشخص می‌شود. آلوده‌ترین ماه‌ها ژانویه، اکتبر و دسامبر هستند که آلودگی هوا عمدتاً از اوایل پاییز تا اواسط زمستان افزایش می‌یابد. تغییرات آلودگی هوا در طول سال‌ها ثابت است مگر اینکه اتفاق خارق‌العاده‌ای رخ دهد.

4-2-1-3-2- یکپارچه‌سازی داده‌ها

سازمان هواشناسی تهران چهار ایستگاه معرفی می‌کند. مناطق مربوط به هر ایستگاه و نواحی مجاور طبق شکل 4-2 دسته‌بندی شده‌اند که ایستگاه‌های هواشناسی با سنسورهای کنترل کیفیت می‌باشند. طبق گزارش سازمان جهانی هواشناسی (WMO-1160)، هر ایستگاه هواشناسی در یک سطح صاف حدود 150 کیلومتر را پوشش می‌دهد (WMO, 2017)؛ بنابراین، نزدیک‌ترین همسایگان با توجه به طول جغرافیایی، طول جغرافیایی و ارتفاع (GIS) سیستم اطلاعات جغرافیایی انتخاب می‌شوند. جدول 4-5 طبقه‌بندی مناطق را از نظر آلودگی هوا در ایستگاه‌های هواشناسی نشان می‌دهد: ایستگاه شمیرانات در منطقه 1 (رده 1)، ایستگاه ژئوفیزیک در منطقه 6 (رده 2)، ایستگاه مهرآباد در منطقه 9 (رده 3) و ایستگاه چیتگر در منطقه 22 (رده 4). داده‌های آلودگی هوا از آن مناطق نیز برای به دست آوردن داده‌های واحد برای هر یک به‌طور میانگین محاسبه شد. شایان‌ذکر است که برخی مناطق به دلیل مجاورت با دو یا سه ایستگاه هواشناسی به‌طور هم‌زمان در چند دسته قرار گرفتند. هر دسته با مناطق مرتبط آن در جدول زیر فهرست شده است.

جدول 5-4: دسته‌بندی مناطق از نظر ایستگاه‌های هواشناسی

نام ایستگاه‌ها			
شمیرانات،	ژنوبیزیک،	مهرآباد،	چیتگر،
دسته 1	دسته 2	دسته 3	دسته 4
1 منطقه 1	2 منطقه 2	9 منطقه 9	21 منطقه 21
2 منطقه 3	3 منطقه 3	10 منطقه 10	22 منطقه 22
3 منطقه 4	6 منطقه 6	16 منطقه 16	-
4 -	7 منطقه 7	18 منطقه 18	-
5 -	8 منطقه 8	19 منطقه 19	-
6 -	10 منطقه 10	21 منطقه 21	-
7 -	11 منطقه 11	2 منطقه 2	-

4-2-1-3-3- کاهش ابعاد داده

داده‌های آلودگی هوا هر ساعت تولید می‌شود که باید با داده‌های هواشناسی تولیدشده هر سه ساعت یک‌بار هماهنگ شود. به همین دلیل است که این داده‌ها باید از ساعتی به میانگین هر سه ساعت تغییر کند. سپس پس از ادغام داده‌های هواشناسی با داده‌های کنترل کیفیت مربوطه، مجموعه داده کل شامل 58921 (نمونه) با 82 (ویژگی) است. سپس زیرمجموعه مجموعه داده از سال 2013 تا 2020 انتخاب شد که شامل 10000 رکورد بود زیرا این دوره ارتقاء حسگر کمتری با از دست دادن داده‌های جزئی داشت.

4-2-1-3-4- انتخاب و تخصیص ویژگی داده و تعیین درجه همبستگی

با مشارکت چند متخصص فنی، 29 ویژگی از بین 82 پارامتر هواشناسی مؤثر بر آلودگی هوا انتخاب شد. ضریب همبستگی ابزاری آماری برای تعیین نوع و درجه رابطه بین یک متغیر کمی با متغیر دیگر است. ضریب همبستگی یکی از معیارهایی است که برای تعیین همبستگی بین دو متغیر استفاده می‌شود. ضریب همبستگی شدت رابطه و نوع رابطه (مستقیم یا معکوس) را نشان می‌دهد. این ضریب بین 1- و 1 است و در صورت عدم وجود رابطه بین دو متغیر برابر با صفر است. جدول 6-4 ضریب همبستگی متغیرهای مستقل و وابسته را نشان می‌دهد. هر چه ضریب همبستگی به یک نزدیکتر باشد، رابطه بین متغیرها قوی‌تر است. هر چه ضریب همبستگی به صفر نزدیکتر باشد، رابطه بین متغیرها ضعیف‌تر است. ضریب همبستگی مثبت نشان‌دهنده رابطه مستقیم و ضریب همبستگی منفی نشان‌دهنده رابطه معکوس بین آنها است. این مشاهدات یک همبستگی مستقیم بین داده‌های کنترل کیفیت و یک همبستگی غیرمستقیم بین داده‌های هواشناسی را نشان می‌دهد.

جدول 6-4: میزان همبستگی بین متغیرهای مستقل و متغیرهای وابسته

توضیحات پارامتر	پارامتر	همبستگی PM ₁₀	همبستگی PM _{2.5}	همبستگی AQI
پایین ترین ابر قابل مشاهده	h	-0.626856278	-0.59053065178	-0.6697409903
نمای افقی	w	-0.607703276	-0.57248446361	-0.6492776859
ابری	n	-0.623519478	-0.58738665652	-0.6661759105
جهت باد	dd	-0.558102351	-0.52575119044	-0.5962834462
سرعت باد	ff	-0.537909738	-0.50672655177	-0.5747094481
درجه حرارت	t	-0.527803925	-0.49720533264	-0.5639122357
نقطه شبنم	td	-0.253686353	-0.23896763935	-0.2710416335
فشار سطح دریا	p	-0.648549046	-0.61097019671	-0.6929178131
فشار ایستگاه	p0	-0.648429866	-0.61085789546	-0.6927904738
مقدار ابر کمترین لایه است	nh	-0.564882591	-0.53213933215	-0.6035275445
ابر لایه پایین	cl	-0.580665947	-0.54701005421	-0.6203906691
ابر لایه متوسط	cm	-0.552014289	-0.520016228	-0.5897788765
میزان پوشش لایه اول ابر	nl1	-0.565542989	-0.5327614680	-0.6042330393
اولین لایه ابر	tl1	-0.632773011	-0.5941054055	-0.6760625894
ارتفاع پایه اولین لایه ابر	hl1	-0.639093125	-0.6020605133	-0.6828149926
میزان پوشش لایه دوم ابر	nl2	-0.565368337	-0.5325969809	-0.6040465128
نوع دوم لایه ابری	tl2	-0.590450388	-0.5562288318	-0.6308444865
ارتفاع پایه لایه ابر دوم	hl2	-0.561194828	-0.5286648232	-0.5995874856
رطوبت نسبی	u	-0.562479899	-0.5298755763	-0.6009604690
دمای مرطوب	twet	-0.530023709	-0.4992966861	-0.5662838703
فشار بخار	ew	-0.588278379	-0.5541823374	-0.6285238308
QNH فشار	pqn	-0.648566165	-0.6109863247	-0.6929361010
ازن	O3	0.212247926	0.0937665708	0.2439902903
مونوکسید کربن	CO	0.508057475	0.5595096392	0.5435975215
دی اکسید نیتروژن	NO2	0.535740491	0.6306802232	0.6179278878
دی اکسید گوگرد	SO2	0.465257284	0.5112756430	0.5090234275
ذرات جامد با قطر کمتر یا مساوی 10 میلی متر	PM ₁₀	1	0.799675092	0.9799183616
ذرات جامد با قطر کمتر یا مساوی 2.5 میلی متر	PM _{2.5}		1	0.797171295
شاخص کیفیت هوا	AQI			1

4-2-1-3-5- تجزیه و تحلیل حساسیت

تحلیل حساسیت به معنای محاسبه و تخمین رفتار سیستم است؛ یعنی اینکه چگونه خروجی سیستم به مقادیر متغیرهای مستقلی که ورودی آن سیستم هستند حساس است. جدول 7-4 نسبت متغیرهای ورودی به خروجی

(ضریب تأثیر) را برای ذرات $PM_{2.5}$ و PM_{10} محاسبه می‌کند. برای محاسبه ضریب تأثیر در این مقاله روش زیر اجرا شده است:

- 1) تمامی پارامترهای ورودی بر روی شبکه اعمال می‌شود و پس از آموزش شبکه، خطای به‌دست‌آمده را E_k می‌نامند (خطای شبکه برای زمانی که همه ورودی‌ها وجود دارند).
- 2) با حذف هر یک از پارامترهای ورودی در هر اجرا، شبکه آموزش‌دیده با اعمال پارامترهای دیگر اجرا می‌شود. درواقع، E_p خطای شبکه است زمانی که فقط ورودی p حذف شده است.
- 3) معادله $(E_p - E_k)/E_k$ ضریب تأثیر را محاسبه می‌کند که نشان می‌دهد پارامتر ورودی حذف‌شده چگونه بر شبکه تأثیر می‌گذارد.

جدول 4-8 و جدول 4-9 تجزیه و تحلیل حساسیت را برای هر دو $PM_{2.5}$ و PM_{10} نشان می‌دهد. در مرحله اول، طبق جدول 4-7، ویژگی‌ها از حداکثر درصد ضربه به حداقل درصد ضربه به ترتیب نزولی مرتب شدند. در تجزیه و تحلیل حساسیت برای $PM_{2.5}$ ، ویژگی‌ها به ترتیب نزولی شامل PM_{10} ، NO_2 ، p ، pqn ، $h1$ ، $tl1$ ، h ، n ، v ، ew ، $tl2$ ، Co ، cl ، $n1$ ، $n2$ ، nh ، u ، $h2$ ، dd ، cm ، SO_2 ، ff ، td ، td ، O_3 و برای PM_{10} شامل $h1$ ، $tl1$ ، h ، n ، v ، ew ، $tl2$ ، cl ، $n1$ ، $n2$ ، nh ، u ، $h2$ ، dd ، cm ، ff ، NO_2 ، td ، td ، CO ، SO_2 ، O_3 ، سپس آنالیز حساسیت برای بررسی صحت از نظر همگنی اجرا شد. برای این منظور، همه متغیرهای مستقل به‌طور هم‌زمان به مدل کم‌عمق LSTM اضافه شدند. سپس متغیرهایی که اثرات جزئی بیشتری داشتند به تدریج یکی پس از دیگری از معادله حذف شدند تا به حداکثر مقدار رسید. قسمت‌های برجسته (پررنگ) ویژگی‌هایی را نشان می‌دهد که بیشترین تأثیر را روی مدل داشته‌اند.

جدول 4-7: درصد تأثیر متغیرهای ورودی بر خروجی

ضریب تأثیر	خروجی متغیر ورودی		ضریب تأثیر	خروجی متغیر ورودی	
	$PM_{2.5}$	ذرات جامد با قطر کمتر یا مساوی 2.5 میلی متر		PM_{10}	ذرات جامد با قطر کمتر یا مساوی 10 میلی متر
0.799671345	PM_{10}	ذرات جامد با قطر کمتر یا مساوی 10 میلی متر	0.648566165	pqn	فشار QNH
0.630680223	NO_2	دی اکسید نیتروژن	0.648549046	p	فشار سطح دریا
0.610986325	pqn	فشار QNH	0.648429866	$p0$	فشار ایستگاه
0.610970197	p	فشار سطح دریا	0.639093125	$h1$	ارتفاع پایه اولین لایه ابر
0.610857895	$p0$	فشار ایستگاه	0.632773011	$tl1$	اولین لایه ابر
0.602060513	$h1$	ارتفاع پایه اولین لایه ابر	0.626856278	h	پایین ترین ابر قابل مشاهده
0.596105606	$tl1$	اولین لایه ابر	0.623519478	n	ابری
0.590530652	h	پایین ترین ابر قابل مشاهده	0.607032760	w	نمای افقی

ضرب تاثیر	خروجی متغیر ورودی		ضرب تاثیر	خروجی متغیر ورودی	
	PM _{2.5}	ذرات جامد با قطر کمتر یا مساوی 2.5 میلی متر		PM ₁₀	ذرات جامد با قطر کمتر یا مساوی 10 میلی متر
0.587386657	n	ابری	0.590450388	tl2	نوع دوم لایه ابری
0.572484464	w	نمای افقی	0.588278379	ew	فشار بخار
0.559509639	CO	مونوکسید کربن	0.580665947	cl	ابر لایه پایین
0.556228832	tl2	نوع دوم لایه ابری	0.565542989	nl1	میزان پوشش لایه اول ابر
0.554182337	ew	فشار بخار	0.565368337	nl2	میزان پوشش لایه دوم ابر
0.547010054	cl	ابر لایه پایین	0.564882591	nh	مقدار ابر کمترین لایه است
0.532761468	nl1	میزان پوشش لایه اول ابر	0.562479899	u	رطوبت نسبی
0.532596981	nl2	میزان پوشش لایه دوم ابر	0.561194828	hl2	ارتفاع پایه لایه ابر دوم
0.532139332	nh	مقدار ابر کمترین لایه است	0.558102351	dd	جهت باد
0.529875576	u	رطوبت نسبی	0.552014289	cm	ابر لایه متوسط
0.528664823	hl2	ارتفاع پایه لایه ابر دوم	0.537909738	ff	سرعت باد
0.52575119	dd	جهت باد	0.535740491	NO2	دی اکسید نیتروژن
0.520015223	cm	ابر لایه متوسط	0.530023709	twet	دمای مرطوب
0.511275643	SO2	دی اکسید گوگرد	0.527803925	t	درجه حرارت
0.506726552	ff	سرعت باد	0.508057475	CO	Carbon monoxide
0.499296686	twet	دمای مرطوب	0.465257284	SO2	دی اکسید گوگرد
0.497205333	t	درجه حرارت	0.253686353	td	نقطه شبنم
0.238967639	td	نقطه شبنم	0.212247926	O3	اوزن
0.093766571	O3	اوزن	0	PM _{2.5}	ذرات جامد با قطر کمتر یا مساوی 2.5 میلی متر
0	AQI	شاخص کیفیت هوا	0	AQI	شاخص کیفیت هوا

جدول 4-9: تجزیه و تحلیل حساسیت برای PM10

Scenarios	Ozone	Dew point	Sulfur dioxide	Carbon monoxide	Temperature	Wet temperature	Nitrogen dioxide	Wind speed	Medium layer cloud	Wind direction	The base height of The second cloud layer	Relative humidity	The amount of cloud is The lowest layer	The amount of coverage of the second layer of	The amount of coverage of the first layer of the	Bottom layer cloud	Steam pressure	The second type of cloud layer	Horizontal view	Cloudiness	The lowest visible cloud	Type the first layer of the cloud	The base height of the first cloud layer	Station pressure	Steam pressure	QNH pressure	Results (PM10)
	O3	td	SO2	CO	t	twet	NO2	ff	cm	dd	hl2	u	nh	nl2	nl1	cl	ew	tl2	vv	n	h	tl1	hl1	p0	p	pqnh	
1	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.7648
2	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.7593
3	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.9232
4	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.2580
5	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.9448
6	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.6445
7	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.5125
8	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.3420
9	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.0001
10	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.9656
11	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.1302
12	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.3664
13	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.9469
14	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.7841
15	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.3938
16	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.7538
17	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.2453
18	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	✓	0.9437
19	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	✓	✓	0.3188
20	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	✓	0.7841
21	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	0.3008
22	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	✓	0.5483
23	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	✓	0.2618
24	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	✓	0.2411
25	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	✓	0.0026
26	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	*	✓	0.2936

4-2-2- محیط آزمایش

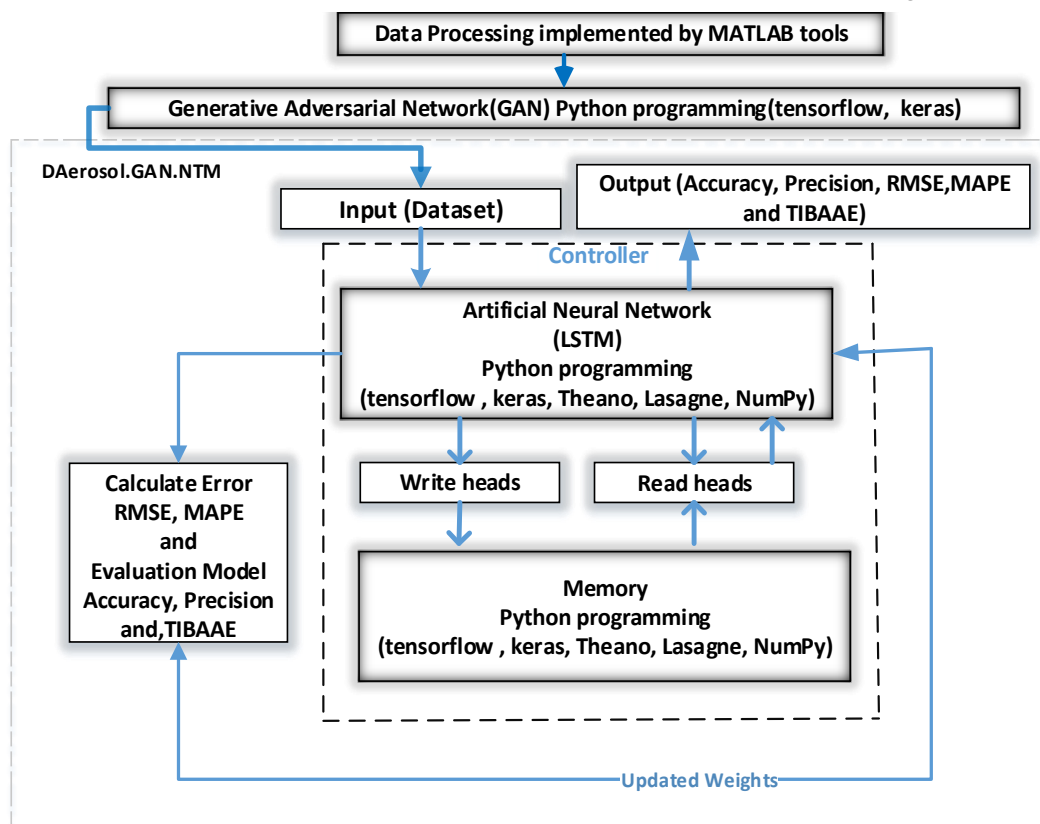
شکل 4-4 مرحله پیش پردازش داده ها را با نرم افزار [69] Matlab R2018a و محیط آزمایشی پیاده سازی شده در محیط Anaconda تحت زبان برنامه نویسی Python 3.6 نشان می دهد [70]. برای اجرا از یک کامپیوتر رومیزی با 8 گیگابایت حافظه، پردازنده Core7 و گرافیک GeForce435m استفاده شده است. کتابخانه Keras [70]، که از چارچوب Tensorflow مبتنی بر GPU استفاده می کند [71]، یک پلت فرم کدگذاری برای Google Colab و Spyder است [72] که شبکه های عصبی عمیق را پیاده سازی می کند. برخی از کتابخانه های مورد نیاز برای پیاده سازی NTM به شرح زیر است:

(1) Theano [71][73] یک کتابخانه پایتون است که به ما امکان ارزیابی عملیات ریاضی از جمله آرایه های چندبعدی را می دهد.

(2) Lasagne [73] یک کتابخانه سبک وزن برای ساخت و آموزش شبکه های عصبی در Theano است.

(3) NumPy عددی پایتون است، یک کتابخانه پایتون منبع باز که تقریباً در هر زمینه ای از علم و مهندسی استفاده می شود.

لازم به ذکر است که تنها تفاوت این محیط آزمایشی با شبکه های عصبی عمیق معمول در استفاده و پیاده سازی ماشین تورینگ عصبی (NTM) است.



شکل 4-4: محیط آزمایشی

3-2-4- طراحی و راه اندازی آزمایش ها

این پژوهش از روش اعتبارسنجی متقابل [68] برای سنجش کارایی مدل استفاده می کند. مجموعه داده آموزشی به طور تصادفی به k پوشه (زیرپوشه) با همان اندازه تقسیم می شود که در میان آن ها تاهای $K-1$ به عنوان آموزش و یک برابر به عنوان اعتبار سنجی در نظر گرفته می شود. به طور کلی، 60٪ از مجموعه داده برای آموزش، 20٪ برای اعتبارسنجی متقابل برای جلوگیری از برازش بیش از حد و 20٪ برای آزمایش استفاده می شود. جدول 10-4 و جدول 11-4 طراحی و راه اندازی آزمایشی را نشان می دهد. آزمایش ها به شرح زیر توصیف می شوند:

آزمایش-1: برای ارزیابی DAerosol.NTM در مقابل مقالات پایه با 58921 نمونه برای ارزیابی دقت پیش بینی، صحت، RMSE و MAPE پارامترهای $PM_{2.5}$ ، PM_{10} و AQI.

آزمایش 2: برای ارزیابی DAerosol.GAN.NTM در مقابل DAerosol.NTM با 10000 نمونه برای ارزیابی دقت پیش بینی، صحت، RMSE و MAPE پارامترهای $PM_{2.5}$ ، PM_{10} و AQI است.

آزمایش-3: DAerosol.GAN.NTM را در برابر DLSTM و DAerosol.NTM برحسب فاصله زمانی قبل و بعد از رویداد آئروسول (TIBAAE) در نظر می گیرد.

جدول 10-4: طراحی آزمایش ها

شماره آزمایش	شرح آزمایش	مجموعه داده	پارامترهای ارزیابی شده	مقداردهی اولیه پارامتر	پشتیبانی از فرضیه
آزمایش 1	مقایسه DAerosol.NTM با مقالات تحقیقاتی پایه [[5][6][7][9][40]]	مجموعه داده ارائه شده (آموزش، آزمون و اعتبارسنجی) با 58921 نمونه	ارزیابی دقت پیش بینی، صحت، RMSE و MAPE برای $PM_{2.5}$ ، PM_{10} و AQI	مقداردهی اولیه پارامتر	فرضیه 1
آزمای 2	مقایسه DAerosol.GAN.NTM و DAerosol.NTM	مجموعه داده ارائه شده (آموزش، آزمون و اعتبارسنجی) با 10000 نمونه	ارزیابی دقت پیش بینی، صحت، RMSE و MAPE برای $PM_{2.5}$ ، PM_{10} و AQI	مقداردهی اولیه پارامتر	فرضیه 2
آزمایش 3	مقایسه فاصله زمانی قبل و بعد از پیش بینی رویداد آئروسول (TIBAAE) برای DAerosol.GAN.NTM و DAerosol.NTM و DLSTM [[5][6][7][9]]	مجموعه داده ارائه شده (آموزش، آزمون و اعتبارسنجی) با 10000 نمونه	ارزیابی TIBAAE برای $PM_{2.5}$ ، PM_{10} و AQI	با استفاده از پارامترهای تعیین شده در آزمایشهای قبلی	

جدول 11-4: تنظیم آزمایش ها

پارامترهای تنظیم	روش
Controller=feedforward, Memory size=128, Learning rate= 10^{-4} , Iterations=4000, Error=0	Neural Turing Machine (NTM)
Backpropagation Algorithm, Topology=Generator&&Discriminator Neural Networks	Generative Adversarial Network (GAN)
4-layer, Activation function= tanh, [20, 15, 9, 6] hidden neurons	Long Short-Term Memory (LSTM)
Feedforward net, Activation function= ReLU, Topology=9-layer [45,45,45, ..., 45]	Neural Network MLP


4-2-4-آزمایش ها

4-2-4-1-آزمایش 1: ارزیابی DAerosol.NTM پیشنهادی در مقایسه با مقالات پایه از نظر $PM_{2.5}$ ، PM_{10} و AQI

به دلیل در دسترس نبودن داده های مورد استفاده در مقالات پایه [7][9][5][6] و [40] این مطالعه کنونی روش های پایه را روی مجموعه داده ارائه شده برای ارزیابی $PM_{2.5}$ ، PM_{10} و AQI که در جدول 4-12، جدول 4-13 و جدول 4-14 توضیح داده شده است، اجرا می کند. نمودارهای میله ای در شکل 4-5، شکل 4-6 و شکل 4-7، جدول 4-12، جدول 4-13 و جدول 4-14 را نشان می دهد و از چگونگی پیش بینی موفقیت آمیز مدل پیشنهادی $PM_{2.5}$ ، PM_{10} و AQI در چهار منطقه هدف در تهران در مقایسه با مدل های پایه.

جدول 4-12: مقایسه DAerosol.NTM و مقالات پایه بر حسب $PM_{2.5}$

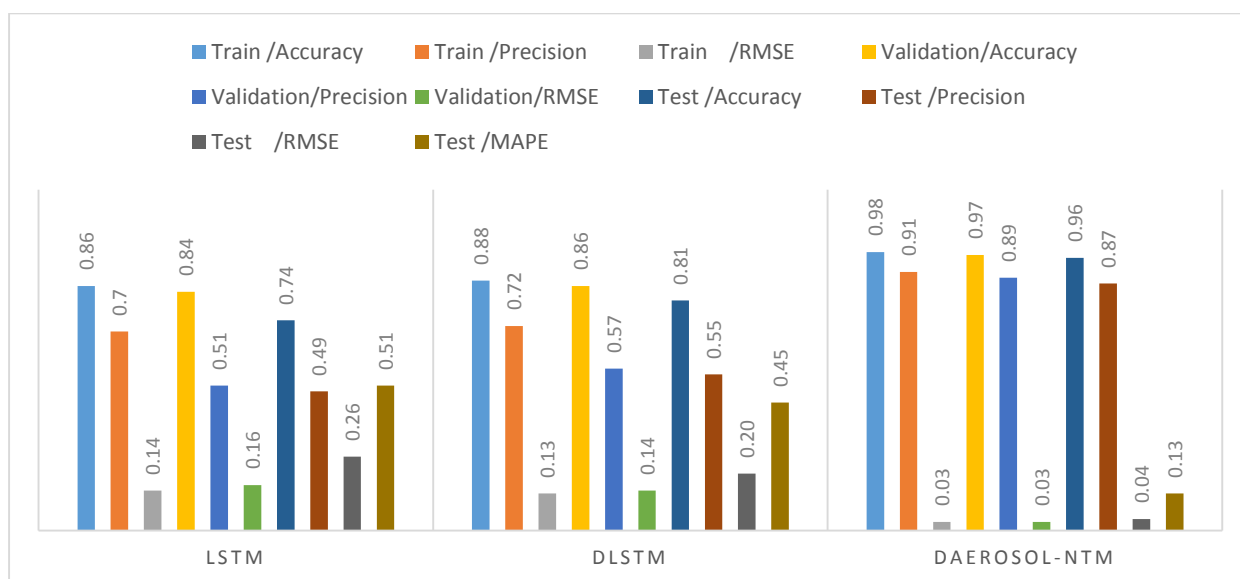
تست				اعتبارسنجی			آموزش			روش	پارامتر اندازه گیری
MAPE	RMSE	MAE	MAE	RMSE	MAE	MAE	RMSE	MAE	MAE		
0.55	0.28	0.45	0.72	0.21	0.48	0.79	0.20	0.59	0.80	MLP	$PM_{2.5}$ [9]
0.51	0.26	0.49	0.74	0.18	0.50	0.82	0.13	0.85	0.87	DNN (MLP)	$PM_{2.5}$ [9]
0.52	0.27	0.48	0.73	0.16	0.50	0.84	0.15	0.69	0.85	LSTM	$PM_{2.5}$ [6] [5]
0.45	0.20	0.55	0.80	0.14	0.56	0.86	0.13	0.71	0.87	DLSTM	$PM_{2.5}$ [6] [5]
0.44	0.20	0.56	0.80	0.14	0.57	0.86	0.12	0.73	0.88	CNN-LSTM	$PM_{2.5}$
0.14	0.05	0.86	0.95	0.03	0.88	0.96	0.03	0.90	0.97	DAerosol.NTM	$PM_{2.5}$ (مطالعه حاضر)



شکل 4-5: مقایسه نمودار میله ای DAerosol.NTM و مقالات پایه بر حسب PM_{2.5}

جدول 4-13: مقایسه DAerosol.NTM و مقالات پایه بر حسب PM₁₀


تست		اعتبار سنجی		آموزش		روش	پارامتر اندازه گیری
MAPE	RMSE	دقت	دقت	RMSE	دقت		
0.51	0.26	0.49	0.74	0.16	0.51	0.84	PM ₁₀
0.45	0.20	0.55	0.81	0.14	0.57	0.86	[6]
0.44	0.19	0.56	0.81	0.14	0.57	0.86	PM ₁₀
							PM ₁₀
0.13	0.04	0.87	0.96	0.03	0.89	0.97	(مطالعه حاضر)



شکل 4-6: مقایسه نمودار میله ای DAerosol.NTM و مقالات پایه بر حسب PM₁₀

جدول 4-14: مقایسه DAerosol.NTM و مقالات پایه بر حسب AQI

تست				اعتبارسنجی			آموزش			روش	پارامتر اندازه گیری
MAPE	RMSE	دقت	دقت	RMSE	دقت	دقت	RMSE	دقت	دقت		
0.56	0.30	0.44	0.70	0.23	0.46	0.77	0.21	0.57	0.79	LSTM	AQI [7] AQI
0.52	0.25	0.48	0.75	0.17	0.49	0.83	0.15	0.50	0.85	DLSTM	
0.51	0.25	0.49	0.76	0.17	0.51	0.83	0.14	0.60	0.86	CNN- LSTM	
0.28	0.19	0.72	0.81	0.12	0.81	0.88	0.02	0.94	0.98	Daerosol.NT M	AQI (مطالعه حاضر)



شکل 4-7: مقایسه نمودار میله ای DAerosol.NTM و مقالات پایه بر حسب AQI

4-2-4-2-2: ارزیابی DAerosol.GAN.NTM پیشنهادی در مقایسه با DAerosol.NTM از نظر

PM_{2.5}، PM₁₀ و AQI

تنظیم پارامترهای شبکه GAN زمان بر بود و به صورت آزمون و خطا انجام شد. در مطالعه حاضر، درصد داده‌های آلودگی گمشده که مستقیماً بر برآوردهای AQI تأثیر می‌گذارد 0.1 از کل داده‌های آموزشی بود. در نهایت، با انجام این آزمون، دقت پیش‌بینی افزایش یافت و خروجی نسبت به روش پایه در جدول 4-15 (DAerosol.NTM) و جدول 4-16 (DAerosol.GAN.NTM) افزایش یافت. با توجه به آزمایش‌های مختلف انجام شده بر روی داده‌ها در این مطالعه، تعداد داده‌های از دست رفته به عنوان آزمون و خطا به طور کلی نباید از 10/100 داده‌های واقعی تجاوز کند زیرا ارزش داده‌های واقعی بسیار مهم خواهد بود. اهمیت این موضوع در مرحله بعدی نشان داده خواهد شد که

با استفاده از شبکه GAN داده‌های بدون برچسب را برای روزهای آینده تولید می‌کند و زمان وقوع آلودگی AQI را که حداقل 24 ساعت و حداکثر 120 ساعت آینده را شامل می‌شود، تخمین می‌زند.

جدول 4-15: نتایج پیش‌بینی داده‌های آلودگی هوا در روش DAerosol.NTM

پارامتر اندازه‌گیری		روش			آموزش			اعتبارسنجی		تست	
اندازه‌گیری	روش	MAPE	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE	RMSE
PM _{2.5}	DAerosol.NTM	0.14	0.03	0.86	0.95	0.04	0.85	0.94	0.03	0.86	0.95
PM ₁₀	M	0.13	0.03	0.87	0.96	0.02	0.86	0.96	0.03	0.87	0.96
AQI		0.28	0.10	0.72	0.81	0.18	0.79	0.85	0.01	0.72	0.81

جدول 4-16: نتایج پیش‌بینی داده‌های آلودگی هوا در روش DAerosol.GAN.NTM

پارامتر اندازه‌گیری		روش			آموزش			اعتبارسنجی		تست	
اندازه‌گیری	روش	MAPE	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE	RMSE
PM _{2.5}	DAerosol.GAN.NTM	0.12	0.02	0.88	0.96	0.02	0.88	0.96	0.02	0.88	0.96
PM ₁₀		0.11	0.02	0.89	0.97	0.02	0.89	0.97	0.02	0.89	0.97
AQI		0.06	0.02	0.94	0.97	0.02	0.93	0.97	0.01	0.94	0.97

4-2-4-3-آزمایش-3: مقایسه فاصله زمانی قبل و بعد از پیش‌بینی رویداد آئروسول (TIBAAE)

DLSTM و DAerosol.NTM با DAerosol.GAN.NTM

آئروسول را می‌توان روزانه (24 ساعت) و ساعتی پیش‌بینی کرد. با این حال، معمولاً ساعتی انتظار نمی‌رود [76][75][74] و اداره کل هواشناسی [77] عمدتاً روزانه بیش از ساعت را در نظر می‌گیرد.

این مقاله همچنین پیش‌بینی روزانه را برای نشان دادن نتایج در جدول 4-17، جدول 4-18 و جدول 4-19 اعمال می‌کند. فاصله زمانی قبل از پیش‌بینی رویداد آئروسول برای بیست و چهار ساعت آینده با در نظر گرفتن داده‌های پنج روز گذشته تا یک روز قبل به دست آمده است. رویداد نمودار میله‌ای در شکل 4-8 غلظت آئروسول و شاخص کنترل کیفیت هوا در آینده ($TIBAAE_{after=24(H)}$) را نشان می‌دهد که با دقت قابل قبولی برای چهار روز قبل از وقوع آئروسول ($TIBAAE_{before=96(H)}$) با استفاده از مدل‌های DLSTM-NTM و DAerosol پیش‌بینی شده بود.

جدول 4-17: پیش‌بینی یک روزه بعدی $PM_{2.5}$ آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آتروسول

پارامتر اندازه گیری	روش	آموزش			اعتبارسنجی			تست			Prediction interval (TIBAAE _{after} = 24(H))
		RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	
$PM_{2.5}$	DLSTM	0.83	0.52	0.17	0.81	0.52	0.19	0.79	0.49	0.21	TIBAAE _{before} =120(H)
		0.88	0.53	0.12	0.86	0.54	0.14	0.82	0.52	0.18	TIBAAE _{before} =96(H)
		0.81	0.50	0.19	0.80	0.50	0.20	0.76	0.47	0.24	TIBAAE _{before} =72(H)
		0.80	0.49	0.20	0.78	0.49	0.22	0.73	0.47	0.27	TIBAAE _{before} =48(H)
		0.77	0.47	0.23	0.77	0.48	0.23	0.71	0.46	0.29	TIBAAE _{before} =24(H)
$PM_{2.5}$	DAerosol.NTM	0.96	0.94	0.04	0.96	0.94	0.04	0.95	0.87	0.05	TIBAAE _{before} =120(H)
		0.97	0.95	0.03	0.97	0.95	0.03	0.96	0.90	0.04	TIBAAE _{before} =96(H)
		0.96	0.94	0.04	0.96	0.93	0.04	0.95	0.87	0.05	TIBAAE _{before} =72(H)
		0.95	0.92	0.05	0.95	0.93	0.05	0.93	0.85	0.07	TIBAAE _{before} =48(H)
		0.95	0.90	0.05	0.94	0.92	0.06	0.92	0.84	0.08	TIBAAE _{before} =24(H)


جدول 4-18: پیش‌بینی یک روزه بعدی PM_{10} آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آتروسول

پارامتر اندازه گیری	روش	آموزش			اعتبارسنجی			تست			Prediction interval (TIBAAE _{after} = 24(H))
		RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	
PM_{10}	DLSTM	0.85	0.55	0.15	0.84	0.54	0.16	0.79	0.51	0.21	TIBAAE _{before} =120(H)
		0.90	0.57	0.10	0.89	0.55	0.11	0.85	0.54	0.15	TIBAAE _{before} =96(H)
		0.86	0.55	0.14	0.85	0.53	0.15	0.79	0.52	0.21	TIBAAE _{before} =72(H)
		0.84	0.52	0.16	0.80	0.51	0.20	0.75	0.49	0.25	TIBAAE _{before} =48(H)
		0.80	0.51	0.20	0.79	0.50	0.21	0.73	0.47	0.27	TIBAAE _{before} =24(H)
PM_{10}	DAerosol.NTM	0.97	0.95	0.04	0.96	0.95	0.03	0.95	0.89	0.05	TIBAAE _{before} =120(H)
		0.98	0.96	0.02	0.98	0.96	0.02	0.96	0.90	0.04	TIBAAE _{before} =96(H)
		0.96	0.94	0.04	0.96	0.95	0.04	0.94	0.86	0.06	TIBAAE _{before} =72(H)
		0.95	0.93	0.05	0.95	0.94	0.05	0.93	0.85	0.07	TIBAAE _{before} =48(H)
		0.94	0.92	0.06	0.94	0.92	0.06	0.93	0.84	0.07	TIBAAE _{before} =24(H)

جدول 194-4: پیش‌بینی یک روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت)

وقوع آئروسول

پارامتر اندازه گیری	روش	آموزش			اعتبارسنجی			تست			Prediction interval (TIBAAE _{after} = 24(H))
		RMSE	دقت	فشار	RMSE	دقت	فشار	MAPE	RMSE	دقت	
AQI	DLSTM	0.16	0.84	0.53	0.18	0.82	0.53	0.50	0.20	0.50	TIBAAE _{before} =120(H)
		0.11	0.89	0.54	0.13	0.87	0.55	0.47	0.17	0.53	TIBAAE _{before} =96(H)
		0.17	0.83	0.52	0.19	0.81	0.52	0.51	0.22	0.49	TIBAAE _{before} =72(H)
		0.18	0.82	0.51	0.21	0.79	0.50	0.51	0.25	0.49	TIBAAE _{before} =48(H)
		0.21	0.79	0.50	0.22	0.78	0.50	0.52	0.27	0.48	TIBAAE _{before} =24(H)
DAerosol.NTM	DAerosol.NTM	0.04	0.97	0.95	0.03	0.97	0.95	0.12	0.05	0.88	TIBAAE _{before} =120(H)
		0.02	0.98	0.96	0.02	0.98	0.96	0.10	0.04	0.90	TIBAAE _{before} =96(H)
		0.03	0.95	0.95	0.04	0.96	0.95	0.13	0.05	0.87	TIBAAE _{before} =72(H)
		0.05	0.93	0.93	0.05	0.95	0.93	0.14	0.06	0.86	TIBAAE _{before} =48(H)
		0.06	0.90	0.90	0.06	0.94	0.92	0.15	0.07	0.85	TIBAAE _{before} =24(H)



شکل 4-8: مقایسه TIBAAE_{before}=96(H) و TIBAAE_{after}=24(H) برای DAerosol.NTM با DLSTM با پیش‌بینی روزانه غلظت آئروسول بر اساس PM_{2.5}، PM₁₀ و شاخص کنترل کیفیت (AQI)

از آنجایی که AQI تمرکز اصلی این تحقیق است، از این پس آزمایش‌ها با AQI ادامه خواهد یافت. پس از تولید داده‌های بدون نظارت با استفاده از داده‌های یک تا پنج روز گذشته توسط شبکه GAN، تمامی آلاینده‌ها شامل CO، SO₂، O₃، PM_{2.5}، PM₁₀ و NO₂ در یک بازه زمانی مشخص به مدت حداقل سه ساعت و حداکثر 24 ساعت

آینده آلاینده‌هایی با بالاترین غلظت در نهایت مقدار AQI را تعیین می‌کنند. سپس داده‌های تولیدشده به‌عنوان داده‌های جدید وارد شبکه NTM می‌شود که قبلاً آموزش‌های لازم در زمینه پیش‌بینی را دیده است و سپس دقت، صحت، RMSE و MAPE طبقه‌بندی را ارزیابی می‌کند. همان‌طور که در جدول 4-20 و (داده‌های ساعتی) و جدول 4-21 (داده‌های روزانه) نشان داده شده است، غلظت شاخص کنترل کیفیت هوای آینده با دقت قابل قبول‌تری در چهار روز قبل از وقوع آئروسول با استفاده از شبکه ترکیبی GAN و NTM پیش‌بینی شده است.

جدول 4-20: نتایج پیش‌بینی حداقل $TIBAAE_{after}=3(H)$ و حداکثر $TIBAAE_{after}=24(H)$ داده‌های آلودگی هوا بر اساس $TIBAAE_{before}=24(H)$ تا $(120H)$ در چارچوب پیشنهادی.

پارامتر اندازه گیری	روش	تست				زمان بر حسب ساعت	Prediction interval (TIBAAE _{after} = 24(H))	
		/MAPE	RSME	صحت	دقت			
	DAerosol.GAN.NT M	AQI	3 AM	0.07	0.04	0.93	0.95	TIBAAE _{before} =120(H)
			6 AM	0.07	0.04	0.93	0.94	
			9 AM	0.09	0.11	0.91	0.89	
			12 Afternoon	0.09	0.12	0.91	0.88	
			15 PM	0.09	0.13	0.91	0.87	
			18 PM	0.1	0.12	0.90	0.87	
			21 PM	0.1	0.14	0.90	0.85	
			00 PM	0.11	0.14	0.89	0.84	
			3 AM	0.05	0.02	0.95	0.97	
			6 AM	0.06	0.03	0.94	0.96	
			9 AM	0.07	0.10	0.93	0.92	TIBAAE _{before} =96(H)
			12 Afternoon	0.08	0.11	0.92	0.89	
			15 PM	0.08	0.11	0.92	0.89	
			18 PM	0.09	0.12	0.91	0.88	
			21 PM	0.1	0.14	0.90	0.86	
			00 PM	0.1	0.14	0.90	0.86	
			3 AM	0.07	0.02	0.93	0.97	
			6 AM	0.07	0.03	0.93	0.96	
			9 AM	0.09	0.12	0.91	0.87	
			12 Afternoon	0.1	0.12	0.90	0.87	
			15 PM	0.1	0.13	0.90	0.86	TIBAAE _{before} =72(H)
			18 PM	0.11	0.13	0.89	0.86	
			21 PM	0.12	0.15	0.88	0.84	
			00 PM	0.13	0.16	0.87	0.83	
			3 AM	0.07	0.04	0.93	0.95	
			6 AM	0.08	0.05	0.92	0.94	
			9 AM	0.11	0.14	0.89	0.85	
			12 Afternoon	0.11	0.15	0.89	0.84	
			15 PM	0.12	0.15	0.88	0.84	

Prediction interval (TIBAAE _{after} = 24(H))	زمان بر حسب ساعت	تست				روش	پارامتر اندازه گیری
		/MAPE	RSME	صحت	دقت		
TIBAAE _{before} =24(H)	18 PM	0.12	0.15	0.88	0.84		
	21 PM	0.14	0.18	0.86	0.81		
	00 PM	0.15	0.18	0.85	0.81		
	3 AM	0.1	0.04	0.90	0.95		
	6 AM	0.11	0.05	0.89	0.94		
	9 AM	0.15	0.18	0.85	0.81		
	12 Afternoon	0.15	0.18	0.85	0.81		
	3 PM	0.16	0.18	0.84	0.81		
	6 PM	0.16	0.18	0.84	0.81		
	9 PM	0.18	0.21	0.82	0.78		
	00 PM	0.19	0.21	0.81	0.78		

جدول 4-21: پیش‌بینی یک روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت) وقوع آئروسل

Prediction interval (TIBAAE _{after} = 24(H))	تست				روش	پارامتر اندازه گیری
	MAPE	RMSE	صحت	دقت		
TIBAAE _{before} =120(H)	0.07	0.05	0.93	0.95	DAerosol.GAN.NTM	AQI
TIBAAE _{before} =96(H)	0.05	0.03	0.95	0.97		
TIBAAE _{before} =72(H)	0.07	0.04	0.93	0.96		
TIBAAE _{before} =48(H)	0.07	0.05	0.93	0.95		
TIBAAE _{before} =24(H)	0.10	0.05	0.90	0.95		

در ادامه جدول 4-21 بالا، جدول 4-22، جدول 4-23، جدول 4-24 و جدول 4-25 فاصله زمانی قبل از پیش‌بینی شاخص کنترل کیفیت آینده (AQI) را برای 48 تا 120 ساعت بعدی با در نظر گرفتن داده‌های پنج روز گذشته نشان می‌دهد. به یک روز قبل نتایج نشان می‌دهد که هر چه از بیست و چهار ساعت به 120 ساعت آینده نزدیک‌تر می‌شویم، دقت و صحت کاهش می‌یابد و خطای پیش‌بینی افزایش می‌یابد.

جدول 22-4: پیش‌بینی دو روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت)

وقوع آئروسل

Prediction interval (TIBAAE _{after} = 48(H))	تست				روش	پارامتر اندازه گیری
	MAPE	RMSE	صحت	دقت		
TIBAAE _{before} =120(H)	0.08	0.06	0.92	0.94	DAerosol.GAN.NTM	AQI
TIBAAE _{before} =96(H)	0.06	0.04	0.94	0.96		
TIBAAE _{before} =72(H)	0.08	0.05	0.92	0.95		
TIBAAE _{before} =48(H)	0.08	0.06	0.92	0.94		
TIBAAE _{before} =24(H)	0.10	0.06	0.90	0.94		

جدول 23-4: پیش‌بینی سه روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت)

وقوع آئروسل

Prediction interval (TIBAAE _{after} = 72(H))	تست				روش	پارامتر اندازه گیری
	MAPE	RMSE	صحت	دقت		
TIBAAE _{before} =120(H)	0.10	0.07	0.90	0.93	DAerosol.GAN.NTM	AQI
TIBAAE _{before} =96(H)	0.08	0.06	0.92	0.94		
TIBAAE _{before} =72(H)	0.09	0.07	0.91	0.93		
TIBAAE _{before} =48(H)	0.10	0.08	0.90	0.92		
TIBAAE _{before} =24(H)	0.10	0.09	0.90	0.91		

جدول 24-4: پیش‌بینی چهارروزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت)

وقوع آئروسل

Prediction interval (TIBAAE _{after} = 96(H))	تست				روش	پارامتر اندازه گیری
	MAPE	RMSE	صحت	دقت		
TIBAAE _{before} =120(H)	0.11	0.09	0.89	0.91	DAerosol.GAN.NTM	AQI
TIBAAE _{before} =96(H)	0.09	0.07	0.91	0.93		
TIBAAE _{before} =72(H)	0.10	0.09	0.90	0.91		
TIBAAE _{before} =48(H)	0.10	0.10	0.90	0.90		
TIBAAE _{before} =24(H)	0.12	0.10	0.88	0.90		

جدول 25-4: پیش‌بینی پنج روزه بعدی شاخص کنترل کیفیت AQI آینده بر اساس ساعات قبل از (24 ساعت تا 120 ساعت)

وقوع آئروسل

Prediction interval (TIBAAE _{after} = 120(H))	تست				روش	پارامتر اندازه گیری
	MAPE	RMSE	صحت	دقت		
TIBAAE _{before} =120(H)	0.13	0.10	0.87	0.90	DAerosol.GAN.NTM	AQI
TIBAAE _{before} =96(H)	0.11	0.09	0.89	0.91		
TIBAAE _{before} =72(H)	0.12	0.11	0.88	0.89		
TIBAAE _{before} =48(H)	0.13	0.12	0.87	0.88		
TIBAAE _{before} =24(H)	0.13	0.14	0.87	0.86		

4-2- بحث تجربی

پژوهش حاضر از داده‌های اقلیمی و آلودگی شهر تهران در ایران استفاده کرد. چارچوب پیشنهادی DAerosol.GAN.NTM پارامترهای $PM_{2.5}$ ، PM_{10} ، AQI و TIBAAE را بررسی کرد.

آزمایش-1 که از فرضیه اول در جدول 26-4 پشتیبانی می‌کند، می‌تواند پیش‌بینی دقت/صحت/MAPE/RMSE و PM_{10} و $PM_{2.5}$ شاخص کنترل کیفیت AQI را به دلیل در نظر گرفتن سابقه طولانی اطلاعات هواشناسی در حافظه خارجی بهبود بخشد.

شبکه عصبی یادگیری عمیق چارچوب ارائه‌شده DAerosol.NTM، در مقایسه با مقالات پایه [5][9][6]، به‌طور قابل‌توجهی دقت را 14-31٪، صحت 50-91٪، ریشه میانگین مربعات خطا (RMSE) با 24-85٪، و میانگین درصد مطلق خطا (MAPE) با 46-75٪ افزایش داد.

آزمایش-2 که از فرضیه دوم در جدول 27-4 پشتیبانی می‌کند، یعنی بهبود روش DAerosol.GAN.NTM در مقایسه با DAerosol.NTM.

چارچوب ارائه‌شده DAerosol.GAN.NTM، در مقایسه با DAerosol.NTM، دقت را به‌طور قابل‌توجهی 19-30٪، صحت با 2-30٪، (RMSE) با 33-80٪ و (MAPE) را با 14-78٪ افزایش داد.

جدول 28-4، آزمایش-3 فرضیه دوم را در مورد TIBAAE پشتیبانی می‌کند. با توجه به داده‌های چهار روز گذشته (TIBAAE_{before})، DAerosol.GAN.NTM می‌تواند بیست و چهار ساعت آینده (TIBAAE_{after}) را با بهترین نتیجه پیش‌بینی کند.

در مقایسه با DAerosol.NTM که قبلاً بهترین نتایج را گزارش کرده بود، DAerosol.GAN.NTM به‌طور قابل‌توجهی TIBAAE (دقت) را 1-18٪، TIBAAE (صحت) 5-33٪، TIBAAE (RMSE) را 16-58٪ و TIBAAE (MAPE) با 33-68٪ افزایش داد.

جدول 26-4: خلاصه نتایج تجربی (آزمایش-1) در حمایت از فرضیه-1

روش																				
MLP				DNN (MLP)				LSTM				DLSTM				DAerosol.NTM				پارامتر اندازه گیری
خروجی از داده های تست																				
دقت	صحت	RMSE	MAPE	دقت	صحت	RMSE	MAPE	دقت	صحت	RMSE	MAPE	دقت	صحت	RMSE	MAPE	دقت	صحت	RMSE	MAPE	
0.72	0.45	0.28	0.55	0.74	0.49	0.26	0.51	0.73	0.48	0.27	0.52	0.80	0.55	0.20	0.45	0.95	0.86	0.05	0.14	PM _{2.5}
0.73	0.46	0.28	0.54	0.75	0.51	0.25	0.49	0.74	0.49	0.26	0.51	0.81	0.55	0.20	0.45	0.96	0.87	0.04	0.13	PM ₁₀
0.69	0.44	0.31	0.56	0.71	0.47	0.29	0.53	0.70	0.46	0.30	0.54	0.75	0.48	0.25	0.52	0.81	0.72	0.19	0.28	AOI

جدول 27-4: خلاصه نتایج تجربی (آزمایش-2) در حمایت از فرضیه-2

روش							
DAerosol.NTM				DAerosol.GAN.NTM			
پارامتر اندازه گیری	خروجی از داده های تست						
	دقت	صحت	RMSE	MAPE	دقت	صحت	RMSE
	0.96	0.88	0.02	0.12	0.95	0.86	0.03
	0.97	0.89	0.02	0.11	0.96	0.87	0.03
	0.97	0.94	0.02	0.06	0.81	0.72	0.10
PM _{2.5}							
PM ₁₀							
AOI							

جدول 28-4: خلاصه نتایج تجربی (آزمایش-3) در حمایت از فرضیه-3

[illegible]

فصل پنجم

نتیجه‌گیری و پژوهش‌های آینده

5-1- نتیجه‌گیری

این مطالعه DAerosol.GAN.NTM (آئروسل عمیق - شبکه‌های متخاصم مولد - ماشین‌های تورینگ عصبی)، یک چارچوب ترکیبی GAN و NTM برای پیش‌بینی دقیق فعالیت آئروسل از نظر مقادیر AQI و شش آلاینده اصلی SO_2 ، NO_2 ، $PM_{2.5}$ ، PM_{10} و O_3 و CO ارائه کرد. در مقایسه با چهار مطالعه پایه [7][9][5][6] با استفاده از LSTM، DNN، MLP و Deep LSTM (DLSTM)، DAerosol.NTM به‌طور قابل‌توجهی دقت را 14-31٪، صحت را 50-91٪، ریشه میانگین مربعات خطا (RMSE) را با 24-85٪، و میانگین درصد خطای مطلق (MAPE) را با 46-75٪ افزایش داد. علاوه بر این، در مقایسه با DAerosol.NTM، دقت را تا 19٪، صحت را تا 30٪، RMSE را تا 80٪ و MAPE را تا 78٪ بهبود بخشید. در نهایت، با توجه به داده‌های چهار روز گذشته (TIBAAE_{before})، DAerosol.GAN.NTM توانست بیست و چهار ساعت آینده (TIBAAE_{after}) را با بهترین نتیجه پیش‌بینی کند.

در مقایسه با DAerosol.NTM که قبلاً بهترین نتایج را گزارش کرده بود، DAerosol.GAN.NTM به‌طور قابل‌توجهی TIBAAE (دقت) را 1-18٪، (صحت) 5-33٪، TIBAAE (RMSE) را 16-58٪ و TIBAAE (MAPE) با 33-68٪ افزایش داد.

درواقع، چارچوب ارائه‌شده می‌تواند از ویژگی‌های ذخیره‌سازی خارجی NTM در استفاده از داده‌های تا ۲۰ سال در مورد آلاینده‌ها و ذرات معلق و همچنین بیست و دو متغیر مستقل به‌دست‌آمده از ایستگاه‌های هواشناسی متعدد در مناطق مختلف تهران استفاده کند. این توانایی به DAerosol.GAN.NTM اجازه می‌دهد تا اولین روشی است که

آلودگی هوا و مقادیر ضعیف AQI را 24 تا 120 ساعت قبل و بعد از آن پیش‌بینی می‌کند، بهتر از DAerosol.NTM روش برتر در پیش‌بینی کیفیت هوای پیشرفته است.

از آنجایی که محیط‌های نامطلوب با کیفیت هوا می‌تواند به‌طور قابل‌توجهی مانع حرکت اقتصادی-اجتماعی شود، برخی از کاستی‌های ارزیابی‌شده این مطالعه باید ارائه شود. اولاً، بر شرایط جوی و جغرافیایی تهران، ایران تمرکز دارد که در درجه اول به دلیل عدم وجود منابع داده استاندارد در سراسر جهان است. شرکای جهانی و نهادهای دولتی تلاش‌ها و پروژه‌های جمع‌آوری داده‌ها را برای اجرای مدل‌های مشابه در سایر محیط‌های شهری اجرا خواهند کرد. دوم اینکه داده‌های خام در مطالعات پایه قبلی در دسترس نبودند و هیچ مقایسه مستقیمی بین روش‌های داده‌شده و DAerosol.GAN.NTM در موقعیت جغرافیایی دقیق انجام نشد. در نهایت، داده‌های بازایی شده از ایستگاه‌های هواشناسی و کیفیت هوای تهران ناقص بوده و یا همه ایستگاه‌ها باهم در دسترس نبودند که از وسعت مطالعه ما کاسته است.

5-2- پیشنهادات

چندین رویکرد را می‌توان برای افزایش دقت و صحت چارچوب پیشنهادی در جهت پیاده‌سازی بکاربرد که می‌تواند آن را به ابزاری حیاتی در مقابله با نگرانی‌های پیش‌بینی کیفیت هوا در زندگی واقعی تبدیل کند. یکی از این رویکردها استفاده از مدل‌های یادگیری ماشین مشتق‌شده از NTM است که معماری حافظه را اصلاح می‌کنند و مدل‌های کامپیوتر عصبی را تولید می‌کنند که DNC ها می‌توانند از هم جدا شوند و قوی‌تر از مدل‌های NTM عمل کنند. این رویکرد می‌تواند باعث بهبود دقت و صحت پیش‌بینی‌های چارچوب پیشنهادی شود. رویکرد دیگری که می‌توان به کار برد، ترکیب شبکه‌های GAN با مدل‌های مبتنی بر DNC است. این رویکرد می‌تواند معماری حافظه را تغییر دهد و امکان پیش‌بینی پارامترهای آلودگی را فراهم کند. با ترکیب این دو روش، می‌توان به دقت و صحت بیشتری در پیش‌بینی دست یافت.

رویکرد دیگری که می‌توان به کار برد، تکامل شبکه عصبی کنترل با استفاده از الگوریتم‌های PSO و NEAT است. این رویکرد می‌تواند مدل‌های مبتنی بر NTM و DNC را بهینه کند و باعث بهبود دقت و صحت پیش‌بینی‌ها شود.

در نهایت، مطالعه پیچیدگی زمانی چارچوب DAerosol.NTM و وظایف جدید مرتبط با آئروسول می‌تواند NTM و DNC را غنی کند. با بررسی وظایف جدید و پیچیده مرتبط با آئروسول و پیش‌بینی کیفیت هوا، می‌توان به دقت و صحت بیشتری در پیش‌بینی‌های DAerosol.GAN.NTM دست یافت.

- [1] Y. Qin, Y. Yin, Z. Wu, and L. Shi, "An observational study of atmospheric aerosol in Shijiazhuang area," *2010 2nd IITA Int. Conf. Geosci. Remote Sensing, IITA-GRS 2010*, vol. 2, pp. 328–331, 2010, doi: 10.1109/IITA-GRS.2010.5604099.
- [2] M. Nakata, I. Sano, and S. Mukai, "Relation between aerosol characteristics and impact factor on climate and environment," *Int. Geosci. Remote Sens. Symp.*, vol. 2015- November, pp. 2342–2345, Nov. 2015, doi: 10.1109/IGARSS.2015.7326278.
- [3] S. Zhu, X. Lian, H. Liu, J. Hu, Y. Wang, and J. Che, "Daily air quality index forecasting with hybrid models: A case in China," *Environ. Pollut.*, vol. 231, pp. 1232–1244, 2017, doi: 10.1016/j.envpol.2017.08.069.
- [4] A. A. Diro and N. Chilamkurti, "Distributed attack detection scheme using deep learning approach for Internet of Things," *Futur. Gener. Comput. Syst.*, vol. 82, pp. 761–768, 2018, doi: 10.1016/j.future.2017.08.043.
- [5] S. Kim, J. M. Lee, J. Lee, and J. Seo, "Deep-dust: Predicting concentrations of fine dust in Seoul using LSTM," *arXiv Prepr. arXiv1901.10106*, pp. 8–10, 2019.
- [6] T. Xayasouk, H. M. Lee, and G. Lee, "Air pollution prediction using long short-term memory (LSTM) and deep autoencoder (DAE) models," *Sustain.*, vol. 12, no. 6, Mar. 2020, doi: 10.3390/su12062570.
- [7] S. Sharma, Arjun and Mitra, Anirban and Sharma, Sumit and Roy, "Estimation of Air Quality Index from Seasonal Trends Using Deep," *Int. Conf. Artif. Neural Networks*, pp. 511–521, 2018, doi: 10.1007/978-3-030-01424-7.
- [8] J. Ma, Jun and Cheng, Jack CP and Lin, Changqing and Tan, Yi and Zhang, "Improving air quality prediction accuracy at larger temporal resolutions using deep learning and transfer learning techniques," *Atmos. Environ.*, vol. 214, p. 116885, 2019, doi: 10.1016/j.atmosenv.2019.116885.
- [9] Y. Pengfei, H. Juanjuan, L. Xiaoming, and Z. Kai, "Industrial Air Pollution Prediction Using Deep Neural Network," in *Communications in Computer and Information Science*, 2018, vol. 951, pp. 173–185, doi: 10.1007/978-981-13-2826-8_16.
- [10] X. Li, L. Peng, Y. Hu, J. Shao, and T. Chi, "Deep learning architecture for air quality predictions," *Environ. Sci. Pollut. Res.*, vol. 23, no. 22, pp. 22408–22417, Nov. 2016, doi: 10.1007/s11356-016-7812-9.
- [11] I. Kök, M. U. Şimşek, and S. Özdemir, "A deep learning model for air quality prediction in smart cities," in *Proceedings - 2017 IEEE International Conference on Big Data, Big Data 2017*, 2017, vol. 2018-Janua, pp. 1983–1990, doi: 10.1109/BigData.2017.8258144.
- [12] M. S. Jassim and G. Coskuner, "Assessment of spatial variations of particulate matter (PM10 and PM2.5) in Bahrain identified by air quality index (AQI)," *Arab. J. Geosci.*, vol. 10, no. 1, pp. 1–14, Jan. 2017, doi: 10.1007/s12517-016-2808-9.
- [13] S. Hochreiter and J. Uergen Schmidhuber, "Long Shortterm Memory," *Neural Comput.*, vol. 9, no. 8, p. 17351780, 1997.
- [14] M. Mohammadi, A. Al-Fuqaha, M. Guizani, and J. S. Oh, "Semisupervised Deep Reinforcement Learning in Support of IoT and Smart City Services," *IEEE Internet Things J.*, vol. 5, no. 2, pp. 624–635, 2018, doi: 10.1109/JIOT.2017.2712560.
- [15] F. A. Gers, N. N. Schraudolph, and J. Schmidhuber, "Learning precise timing with LSTM recurrent networks," *J. Mach. Learn. Res.*, vol. 3, no. 1, pp. 115–143, 2003, doi: 10.1162/153244303768966139.
- [16] Y. Yao, Kaisheng and Peng, Baolin and Zhang, Yu and Yu, Dong and Zweig, Geoffrey

- and Shi, "SPOKEN LANGUAGE UNDERSTANDING USING LONG SHORT-TERM MEMORY NEURAL NETWORKS," in *2014 IEEE Spoken Language Technology Workshop (SLT)*, 2014, pp. 189--194.
- [17] G. Graves, Alex and Mohamed, Abdel-rahman and Hinton, "SPEECH RECOGNITION WITH DEEP RECURRENT NEURAL NETWORKS," in *2013 IEEE international conference on acoustics, speech and signal processing*, 2013, pp. 6645--6649.
- [18] M. Sheng, Z. Ma, H. Jia, Q. Mao, and M. Dong, "Face Aging with Conditional Generative Adversarial Network Guided by Ranking-CNN," *Proc. - 3rd Int. Conf. Multimed. Inf. Process. Retrieval, MIPR 2020*, pp. 314--319, 2020, doi: 10.1109/MIPR49039.2020.00071.
- [19] S. M. Faradonbe and F. Safi-Esfahani, "A classifier task based on Neural Turing Machine and particle swarm algorithm," *Neurocomputing*, vol. 396, pp. 133--152, Apr. 2020, doi: 10.1016/j.neucom.2018.07.097.
- [20] B. Boloukian and F. Safi-Esfahani, "Recognition of words from brain-generated signals of speech-impaired people: Application of autoencoders as a neural Turing machine controller in deep neural networks," *Neural Networks*, vol. 121, pp. 186--207, 2020, doi: 10.1016/j.neunet.2019.07.012.
- [21] Y. Gulcehre, Caglar and Chandar, Sarath and Cho, Kyunghyun and Bengio, "Dynamic Neural Turing Machine with Soft and Hard Addressing Schemes," *arXiv Prepr. arXiv1607.00036*, Jun. 2016.
- [22] A. M. Turing, *MIND A QUARTERLY REVIEW OF PSYCHOLOGY AND PHILOSOPHY I.-COMPUTING MACHINERY AND INTELLIGENCE*. Springer, 1950.
- [23] H. T. Siegelmann and E. D. Sontag, "Turing computability with neural nets," *Appl. Math. Lett.*, vol. 4, no. 6, pp. 77--80, Jan. 1991, doi: 10.1016/0893-9659(91)90080-F.
- [24] H.-J. Han, Woo-jin and Cha, Sang-chang and Ha, "Method and apparatus for multi-layered video encoding and decoding," 01-Jun-2006.
- [25] A. Graves, G. Wayne, and I. Danihelka, "Neural Turing Machines," *arXiv Prepr. arXiv1410.5401*, pp. 1--26, 2014.
- [26] S. Malekmohammadi Faradonbeh and F. Safi-Esfahani, "A review on Neural Turing Machine," *arXiv. arXiv*, 10-Apr-2019.
- [27] A. Baddeley, "Working memory and executive control," *Philos. Trans. R. Soc. London. Ser. B Biol. Sci.*, vol. 351, no. 1346, pp. 1397--1404, Oct. 1996, doi: 10.1098/rstb.1996.0123.
- [28] Z. C. Lipton, J. Berkowitz, and C. Elkan, "A Critical Review of Recurrent Neural Networks for Sequence Learning," *arXiv Prepr. arXiv1506.00019*, May 2015.
- [29] T. Weston, Jason and Bordes, Antoine and Chopra, Sumit and Rush, Alexander M and van Merriëboer, Bart and Joulin, Armand and Mikolov, "Towards AI-complete question answering: A set of prerequisite toy tasks," in *4th International Conference on Learning Representations, ICLR 2016 - Conference Track Proceedings*, 2016.
- [30] J. and others Graves, Alex and Wayne, Greg and Reynolds, Malcolm and Harley, Tim and Danihelka, Ivo and Grabska-Barwińska, Agnieszka and Colmenarejo, Sergio Gómez and Grefenstette, Edward and Ramalho, Tiago and Agapiou, "Hybrid computing using a neural network with dynamic external memory," *Nature*, vol. 538, no. 7626, pp. 471--476, Oct. 2016, doi: 10.1038/nature20101.
- [31] G. Yang and A. M. Rush, "Lie-access neural turing machines," in *5th International Conference on Learning Representations, ICLR 2017 - Conference Track Proceedings*, 2019.

- [32] W. Zaremba and I. Sutskever, "Reinforcement Learning Neural Turing Machines - Revised," *arXiv Prepr. arXiv1505.00521*, May 2015.
- [33] C. Gulcehre, S. Chandar, K. Cho, and Y. Bengio, "Dynamic neural turing machine with continuous and discrete addressing schemes," *Neural Comput.*, vol. 30, no. 4, pp. 857–884, Apr. 2018, doi: 10.1162/NECO_a_01060.
- [34] R. B. Greve, E. J. Jacobsen, and S. Risi, "Evolving neural turing machines for reward-based learning," in *GECCO 2016 - Proceedings of the 2016 Genetic and Evolutionary Computation Conference*, 2016, pp. 117–124, doi: 10.1145/2908812.2908930.
- [35] K. O. Stanley and R. Miikkulainen, "Evolving neural networks through augmenting topologies %J Evolutionary Computation," *Evolutionary Computation*, vol. 10, no. 2, pp. 99–127, 2002.
- [36] G. Stein, A. J. Gonzalez, and C. Barham, "Machines that learn and teach seamlessly," *IEEE Trans. Learn. Technol.*, vol. 6, no. 4, pp. 389–402, Oct. 2013, doi: 10.1109/TLT.2013.32.
- [37] J. Zhao and G. Peng, "NEAT versus PSO for evolving autonomous multi-agents coordination on pursuit-evasion problem," in *Lecture Notes in Electrical Engineering*, 2011, vol. 133 LNEE, no. VOL. 2, pp. 711–717, doi: 10.1007/978-3-642-25992-0_95.
- [38] P. Verbancsics and J. Harguess, "Generative NeuroEvolution for Deep Learning," *arXiv Prepr. arXiv1312.5355*, 2013.
- [39] B. Lin and J. Zhu, "Changes in urban air quality during urbanization in China," *J. Clean. Prod.*, vol. 188, pp. 312–321, 2018, doi: 10.1016/j.jclepro.2018.03.293.
- [40] A. Bekkar, B. Hssina, S. Douzi, and K. Douzi, "Air-pollution prediction in smart city, deep learning approach," *J. Big Data*, vol. 8, no. 1, pp. 1–21, 2021, doi: 10.1186/s40537-021-00548-1.
- [41] A. Akhtar, S. Masood, C. Gupta, and A. Masood, "Prediction and analysis of pollution levels in delhi using multilayer perceptron," *Adv. Intell. Syst. Comput.*, vol. 542, pp. 563–572, 2018, doi: 10.1007/978-981-10-3223-3_54.
- [42] R. Raturi and J. R. Prasad, "Recognition of Future Air Quality Index Using Artificial Neural Network," *Int. Res. J. Eng. Technol.*, vol. 5, pp. 2395--0056, 2018.
- [43] J. Wang, X. Zhang, Z. Guo, and H. Lu, "Developing an early-warning system for air quality prediction and assessment of cities in China," *Expert Syst. Appl.*, vol. 84, pp. 102–116, 2017, doi: 10.1016/j.eswa.2017.04.059.
- [44] I. Kök, M. U. Şimşek, and S. Özdemir, "A deep learning model for air quality prediction in smart cities," in *Proceedings - 2017 IEEE International Conference on Big Data, Big Data 2017*, 2017, vol. 2018-Janua, pp. 1983–1990, doi: 10.1109/BigData.2017.8258144.
- [45] s. Beheshti Far and b. Kafi Khosroshahi, "Study of the ability of various types of artificial neural networks in predicting the amount of CO, NO2, SO2 pollutants in the metropolitan area of Tabriz," in the Fourth International Conference on Planning and Management, 2017.
- [46] R. Shams et al. World, "Assessing the accuracy of multiple regression model in forecasting air quality index (AQI) in Tehran," in the International Conference on New Research in Civil Engineering, Urban Management and Environment, 2017.
- [47] H. Zangouei and Asdaleh Fardi, "Prediction of PM10 contamination in Mashhad using MLP artificial neural networks and Markov chain model," *Journal of Applied Research in Geographical Sciences*, vol. 17, no. 47, pp. 39–59, 2017.
- [48] R. Farhadi, M. Hadavifar et al., "Prediction of air pollutant concentrations in Tehran based on climatic factors using artificial neural network," in the National Conference

- on Research and Technology Findings in Natural and Agricultural Ecosystems, 2016.
- [49] J. Wang, X. Zhang, Z. Guo, and H. Lu, "Developing an early-warning system for air quality prediction and assessment of cities in China," *Expert Syst. Appl.*, vol. 84, pp. 102–116, Oct. 2017, doi: 10.1016/j.eswa.2017.04.059.
 - [50] Y. B. Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, "Generative Adversarial Nets," *Adv. Neural Inf. Process. Syst.*, pp. 2672–2680, 2014.
 - [51] A. Radford, L. Metz, and S. Chintala, "Unsupervised representation learning with deep convolutional generative adversarial networks," *4th Int. Conf. Learn. Represent. ICLR 2016 - Conf. Track Proc.*, pp. 1–16, 2016.
 - [52] T. Karras, T. Aila, S. Laine, and J. Lehtinen, "Progressive Growing of GANs for Improved Quality, Stability, and Variation," *arXiv Prepr. arXiv1710.10196*, Oct. 2017.
 - [53] Y. Jin, J. Zhang, M. Li, Y. Tian, H. Zhu, and Z. Fang, "Towards the Automatic Anime Characters Creation with Generative Adversarial Networks," *arXiv Prepr. arXiv1708.05509*, Aug. 2017.
 - [54] S. Vasu, N. Thekke Madam, and A. N. Rajagopalan, "Analyzing perception-distortion tradeoff using enhanced perceptual super-resolution network," *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 11133 LNCS, pp. 114–131, 2019, doi: 10.1007/978-3-030-11021-5_8.
 - [55] Y. Taigman, A. Polyak, and L. Wolf, "Unsupervised cross-domain image generation," in *5th International Conference on Learning Representations, ICLR 2017 - Conference Track Proceedings*, 2017.
 - [56] J.-L. D. Grigory Antipov, Moez Baccouche, "FACE AGING WITH CONDITIONAL GENERATIVE ADVERSARIAL NETWORKS Moez Baccouche Orange Labs , 4 rue Clos Courtel , 35512 Cesson-S ' evign ' e , France," *Int. Conf. image proceeding*, pp. 2089–2093, 2017.
 - [57] J.-Y. Zhu, T. Park, P. Isola, A. A. Efros, and B. A. Research, "Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks Monet Photos," *Proc. IEEE Int. Conf. Comput. Vis.*, pp. 2223–2232, 2017.
 - [58] E. Zakharov, A. Shysheya, E. Burkov, and V. Lempitsky, "Few-shot adversarial learning of realistic neural talking head models," *arXiv/Proceedings IEEE Int. Conf. Comput. Vis.*, pp. 9459–9468, 2019.
 - [59] D. N. Zhang, Han and Xu, Tao and Li, Hongsheng and Zhang, Shaoting and Wang, Xiaogang and Huang, Xiaolei and Metaxas, "StackGAN: Text to Photo-realistic Image Synthesis with Stacked Generative Adversarial Networks," *Proc. IEEE Int. Conf. Comput. Vis.*, pp. 5907–5915, 2017.
 - [60] Z. Zheng, L. Zheng, and Y. Yang, "Unlabeled Samples Generated by GAN Improve the Person Re-Identification Baseline in Vitro," *Cvpr/Proceedings IEEE Int. Conf. Comput. Vis.*, pp. 3754–3762, 2017.
 - [61] K. Sarda, A. Yerudkar, and C. Del Vecchio, "Missing Data Imputation for Real Time-series Data in a Steel Industry using Generative Adversarial Networks," in *IECON Proceedings (Industrial Electronics Conference)*, 2021, vol. 2021-October, doi: 10.1109/IECON48115.2021.9589716.
 - [62] A. Azevedo and M. F. Santos, "KDD, semma and CRISP-DM: A parallel overview," in *MCCSIS'08 - IADIS Multi Conference on Computer Science and Information Systems; Proceedings of Informatics 2008 and Data Mining 2008*, 2008, pp. 182–185.
 - [63] A. Castillo Esparcia and S. López Gómez, "Public opinion about climate change in United States, partisan view and media coverage of the 2019 United Nations climate

change conference (COP 25) in Madrid,” *Sustain.*, vol. 13, no. 7, 2021, doi: 10.3390/su13073926.

- [64] Organización de las Naciones Unidas, *World Urbanization Prospects 2018*. 2018.
- [65] V. Hosseini and H. Shahbazi, “Urban Air Pollution in Iran,” *Iran. Stud.*, vol. 49, no. 6, pp. 1029–1046, Nov. 2016, doi: 10.1080/00210862.2016.1241587.
- [66] H. Nazmfar, A. Saredeh, A. Eshgi, and B. Feizizadeh, “Vulnerability evaluation of urban buildings to various earthquake intensities: a case study of the municipal zone 9 of Tehran,” *Hum. Ecol. Risk Assess. An Int. J.*, vol. 25, no. 1–2, pp. 455–474, Feb. 2019, doi: 10.1080/10807039.2018.1556086.
- [67] D. Vallero, “Fundamentals of Air Pollution - Daniel Vallero - Google Books,” *Academic Press*, 2014. [Online]. Available: <https://books.google.com/books?hl=en&lr=&id=iFcXAwAAQBAJ&oi=fnd&pg=PP1&dq=According+to+experts+in+the+field+of+meteorology+and+air+quality+control,+influential+factors+in+predicting+air+pollution+are+sky+conditions+such+as+cover,+type,+layer,+and+height+o.> [Accessed: 15-Jul-2022].
- [68] R. Mohammadpour, Z. Asaie, M. R. Shojaeian, and M. Sadeghzadeh, “A hybrid of ANN and CLA to predict rainfall,” *Arab. J. Geosci.*, vol. 11, no. 18, 2018, doi: 10.1007/s12517-018-3804-z.
- [69] P. Kim, *MATLAB Deep Learning*. Apress, 2017.
- [70] P. Zocca, Valentino and Spacagna, Gianmario and Slater, Daniel and Roelants, *Python Deep Learning - Valentino Zocca, Gianmario Spacagna, Daniel Slater, Peter Roelants - Google Books*. Packt Publishing Ltd, 2017.
- [71] J. Brownlee, *Deep Learning With Python Develop Deep Learning Models On Theano And TensorFlow Using Keras i Deep Learning With Python*. 2016.
- [72] V. Vasilev, Ivan and Slater, Daniel and Spacagna, Gianmario and Roelants, Peter and Zocca, *Python Deep Learning: Exploring deep learning techniques and neural network ... - Ivan Vasilev, Daniel Slater, Gianmario Spacagna, Peter Roelants, Valentino Zocca - Google Books*. 2019.
- [73] Jason Brownlee, “Deep Learning With Python: Develop Deep Learning Models on Theano and ... - Jason Brownlee - Google SÁCH,” 2020. [Online]. Available: https://books.google.com.vn/books?hl=vi&lr=&id=K-ipDwAAQBAJ&oi=fnd&pg=PP1&dq=Deep+learning+with+Python:+develop+deep+learning+models+on+Theano+and+TensorFlow+using+Keras&ots=oqSp1H1iAv&sig=GljecgTwQ1aLP8uAeINCSSMzFNo&redir_esc=y#v=onepage&q=Deep+learning+with+Python%3A+develop+deep+learning+models+on+Theano+and+TensorFlow+using+Keras&f=false.
- [74] Q. Wu and H. Lin, “A novel optimal-hybrid model for daily air quality index prediction considering air pollutant factors,” *Sci. Total Environ.*, vol. 683, pp. 808–821, Sep. 2019, doi: 10.1016/j.scitotenv.2019.05.288.
- [75] A. Jamal and R. N. Nodehi, “A R T I C L E I N F O R M A T I O N PREDICTING AIR QUALITY INDEX BASED ON METEOROLOGICAL DATA: A COMPARISON OF REGRESSION ANALYSIS, ARTIFICIAL NEURAL NETWORKS AND DECISION TREE,” Nov. 2017.
- [76] K. Hossain, Emam and Shariff, Mohd Arafath Uddin and Hossain, Mohammad Shahadat and Andersson, “A Novel Deep Learning Approach to Predict Air Quality Index,” in *Proceedings of International Conference on Trends in Computational and Cognitive Engineering*, 2020, pp. 367–381.
- [77] L. J. Battan, “Fundamentals of meteorology,” *Fundam. Meteorol.*, 1979, doi:

10.1007/978-3-030-52655-9.

Abstract

In urban areas of different countries, the issue of suspended particles (aerosols) and their effects on human health is concerning. Aerosol particles with sizes ranging from 1 nanometer to 100 micrometers easily penetrate biological tissues and may be accompanied by toxic gas and mineral compounds such as carbon monoxide, ozone, nitrogen dioxide, and sulfur dioxide. Aerosol particles have various environmental, economic, health, and social impacts that need to be controlled to improve people's quality of life. In this study, we introduce the DAerosol.GAN.NTM deep learning framework that uses the latest advances in neural Turing machines (NTM) to access external memory as a deep learning framework and focuses on changes in network structure using a GAN network. Compared to four baseline studies including multi-layer perceptron, deep neural networks, long short-term memory-deep neural networks, the DAerosol-NTM method has superiority and DAerosol.GAN.NTM improves prediction accuracy by 1-19%, precision by 30-2%, root mean square error (RMSE) by 80-33%, and mean absolute percentage error (MAPE) by 78-14% compared to DAerosol-NTM. The most notable feature is the ability of DAerosol.GAN.NTM to store up to 20 years of suspended particle data in external memory, making it the first model capable of predicting an increase in aerosol pollution in the future (24 to 120 hours). This model provides predictions of aerosol events in the future based on the optimal time interval before and after the aerosol event (TIBAAE) and reduces the negative effects of toxic aerosol storms on urban communities and economies in real-time environments.

Keywords: Neural Turing Machines (NTM); Generative Adversarial Networks (GAN); Deep Learning (DL); *Air Quality Index (AQI)*; Particulate Matter 2.5 (PM_{2.5}); Particulate Matter 10 (PM₁₀); Aerosol;



**Islamic Azad University
Najafabad Branch
Faculty of Computer Engineering**

A Thesis Submitted in Partial Fulfillment of the Requirements for the Degree of
Ph.D. in Computer Engineering

Title:

**The forecast of the parameters of weather quality by using deep learning
and Neural Turing Machine**

By

Zahra Sadat Asaee Moammam

Supervisors

Faramarz Safiesfahani, PhD

Seyed Ali Mirjalili, PhD

Month and Year